

Lista 1: dos dados à previsão

Probabilidade, distribuições, esperança condicional e BLP

FLS 6183 - Métodos Quantitativos de Pesquisa II

Conteúdo até a Aula 3 | Revisão de 5 de setembro de 2026

O que você vai investigar

Um resumo descreve bem os dados? Mais informação melhora a previsão? Você começará com a população dos municípios brasileiros e, depois, retomará as votações de Brasil e China na Assembleia Geral das Nações Unidas (AGNU). O percurso vai da importação e da descrição à comparação de previsores.

Ao terminar, você deverá conseguir validar uma base, interpretar momentos, distinguir probabilidades marginais e condicionais, simular uma variável binária e comparar a função de esperança condicional (CEF) com o melhor preditor linear (BLP).

Organização e entrega

- Resolva os **exercícios 1 a 9**.
- Trabalhe em três sessões: importação e descrição (1 a 4), probabilidade e previsão (5 e 6), BLP, exemplo não linear e síntese aplicada (7 a 9). As estimativas de tempo em cada bloco servem apenas para organizar o estudo.
- Entregue pelo Moodle o PDF, a fonte `.Rmd` ou `.qmd` e um script `.R` com os cálculos. O documento deve carregar os resultados do script. Informe os integrantes conforme a modalidade de entrega anunciada no Moodle.
- Apresente código, resultados selecionados e interpretação. Evite imprimir bases completas. Numere todas as figuras e tabelas e inclua legenda, unidade de medida e fonte.
- Execute o trabalho em uma sessão nova do R antes de entregar. Use caminhos relativos e mantenha os arquivos de entrada intactos.
- Consulte o Moodle para prazo e modalidade de entrega. Esta revisão não estabelece uma nova data.

Arquivos e apoio

Na pasta `dados/` do pacote estão dois arquivos:

- `populacao_municipios_2020.csv`;
- `brasil_convergencia_china_1997_2016.csv`.

O primeiro contém estimativas do IBGE para 1º de julho de 2020; o segundo é o recorte didático usado nas Aulas 2 e 3. Use as cópias fornecidas, sem baixar novamente as bases.

Tenha à mão os slides e os scripts das Aulas 2 e 3. Use explicitamente `dplyr::select()` ao selecionar colunas. Caso recorra ao tutor, registre a sua tentativa, o diagnóstico e a verificação da solução. Você deve conseguir explicar os comandos e as conclusões que entregar.

Critério de qualidade: cada resposta deve mostrar o que foi calculado, em quais observações se baseia e o que o resultado permite concluir.

1. Importar é também verificar

Sessão 1, exercícios 1 a 4: aproximadamente 90 a 120 minutos.

Importe `dados/populacao_municipios_2020.csv` para `pop2020`.

- Registre a primeira tentativa, mesmo se o comando rodar e produzir um resultado inesperado. Examine dimensões, nomes, tipos e algumas linhas. Se houver problema, formule uma hipótese, teste-a e explique a correção.
- Valide os seguintes critérios: 5.570 linhas, três variáveis (`uf`, `nome_munic`, `populacao`), 27 UFs, ausência de valores faltantes, população numérica e positiva e unicidade do par UF-nome do município. Verifique também a preservação de acentos e apóstrofes e eventuais problemas registrados pelo importador.
- Explique a unidade de análise e a data de referência. Por que não basta verificar se há 5.570 linhas? Por que nomes de municípios, sozinhos, não são uma chave segura para a base nacional?
- Crie uma cópia de trabalho: selecione as três colunas com `dplyr::select()`, renomeie `nome_munic` para `municipio` e use `tolower()` para converter seus nomes em minúsculas. Preserve o objeto importado.

Produto: diagnóstico breve e uma tabela numerada de verificações, com critério, resultado observado e conclusão.

2. Qual município estamos descrevendo?

Crie um objeto com os municípios de São Paulo, mantendo a base nacional. Neste exercício, defina Z como a população de um município paulista escolhido com chances iguais. Se houver n municípios, chame de z_i a população do município na linha i e de $\bar{z}$ a média desses valores. No R, você pode usar `z <- sp$populacao` para representar os valores observados.

- Quantos municípios há? Identifique o de menor população e os com mais de um milhão de habitantes. Apresente nomes e populações em uma tabela.
- Calcule média, mediana, desvio-padrão e variância da população municipal. Informe a unidade de cada medida. Explique a diferença entre a população média de um município e a população total do estado.
- Recalcule a média com a soma das populações dividida pelo número de municípios. A qual experimento aleatório essa média corresponde: escolher um município com chances iguais ou escolher um morador com chances iguais? Justifique sem efetuar uma nova ponderação.
- Para os valores observados $z_1, \dots, z_n$ definidos acima, compare $v_n = n^{-1} \sum_i (z_i - \bar{z})^2$ com `var(z)`. Qual denominador o R usa? Verifique a relação entre os dois resultados. Use v_n quando tratar esta base como uma distribuição empírica com pesos iguais.

Pausa de interpretação: uma estatística correta pode responder à pergunta errada se a unidade de análise ou a ponderação estiverem erradas.

3. Centro, dispersão e forma

Continue usando os municípios de São Paulo.

- Produza uma figura com três painéis: distribuição da população de todos os municípios; distribuição dos municípios com menos de 50 mil habitantes; distribuição de $\log(\text{populacao})$ para todos os municípios. Use histogramas ou densidades. Identifique as unidades e a população incluída em cada painel; não trate densidade como contagem.
- Quantos municípios têm menos de 50 mil habitantes? Qual é sua proporção entre os municípios paulistas? Compare as distribuições e explique a diferença entre excluir municípios e transformar a escala.
- Qual medida, média ou mediana, descreve melhor um município típico neste caso? Justifique com a figura e os números. A outra medida deixa de ser útil? Dê um exemplo de pergunta para a qual ela seria útil.
- Defina $W = Z/1000$, a população em milhares de habitantes. Antes de calcular, preveja como mudarão a média, o desvio-padrão e a variância. Verifique suas previsões no R e explicita as unidades resultantes.

Atenção à escala: o logaritmo natural exige valores positivos e muda as distâncias entre valores. Ele não altera quantos municípios existem.

4. Médias condicionais e média nacional

Retome todos os municípios brasileiros. Agora Z representa a população de um município escolhido com chances iguais e U representa sua UF.

- Use `group_by()` e `summarise()` para obter o número de municípios, a população total e a população média municipal em cada UF. Ordene a tabela pela média e identifique as UFs nos dois extremos.
- Interprete $E[Z \mid U = u]$. Uma UF com maior média municipal tem necessariamente maior população total? Sustente sua resposta com as colunas da tabela, sem confundir estado com município.
- Reconstrua a média nacional usando as médias por UF ponderadas pela proporção de municípios de cada UF. Compare com a média nacional direta e com a média simples das 27 médias. Explique qual delas corresponde a escolher um município brasileiro com chances iguais.

Conexão com a Aula 3: o item c é uma aplicação da Lei da Esperança Iterada. As médias condicionais precisam ser combinadas com os pesos da distribuição da variável em que condicionamos.

5. Dos votos às probabilidades e à simulação

Sessão 2, exercícios 5 e 6: aproximadamente 90 a 120 minutos.

Importe a base da AGNU com `data.table::fread()`, como no laboratório. Uma linha representa uma votação nominal com os votos de Brasil e China observados. Defina $Y = \text{convergente}$, que vale 1 se os votos coincidem e 0 caso contrário; e $X = \text{pos_2009}$, que vale 0 em 1997–2008 e 1 em 2009–2016.

Convenção para os exercícios 5 a 9: trate as 1.762 linhas válidas como uma distribuição empírica em que cada votação recebe o mesmo peso, $1/1.762$. Assim, probabilidades, esperanças e erros quadráticos médios são calculados como médias sobre essas linhas. Não é necessário sortear uma linha nem simular as votações reais; a simulação pedida no item 5e é uma atividade separada. As medidas referem-se a essas observações, não a uma população futura desconhecida.

- Verifique a unicidade de `rcid`, ausentes nas variáveis usadas, anos entre 1997 e 2016, consistência entre `data` e `ano`, entre ano e período e valores 0/1 de X e Y . Confira também se Y corresponde à igualdade dos dois votos. O ponto de conferência é **1.762 linhas válidas**. Não elimine linhas silenciosamente para atingir esse número. A coluna `voto_importante` não será usada; seus valores ausentes não justificam excluir votações.
- Construa uma tabela 2×2 de contagens de (X, Y) e, em seguida, a distribuição conjunta dividindo todas as células pelo total geral. Obtenha as duas distribuições marginais somando as células adequadas.
- Calcule $\Pr(Y = 1 \mid X = 0)$, $\Pr(Y = 1 \mid X = 1)$ e $\Pr(X = 1 \mid Y = 1)$. Escreva em palavras a pergunta respondida por cada quantidade. Indique o denominador usado em cada caso.
- Calcule $p = E[Y]$, $E[Y^2]$, $V(Y)$ e o desvio-padrão diretamente dos dados. Verifique $E[Y^2] = E[Y]$ e $V(Y) = p(1 - p)$. Use denominador n para a variância.
- Antes de simular**, preveja o centro de uma sequência de valores 0/1 com probabilidade p de valer 1. Fixe `set.seed(6183)` e gere 10.000 valores com `rbinom(10000, size = 1, prob = p)`. Compare a frequência de 1 e a variância empírica dos primeiros 100, primeiros 1.000 e todos os valores com p e $p(1 - p)$. Por que não precisam ser exatamente iguais?

Duas distinções: aumentar a sequência não garante aproximação monotônica em cada realização. A simulação cria sorteios independentes por construção; isso não demonstra independência entre as votações reais.

6. Qual informação melhora a previsão?

Defina $m(x) = E[Y | X = x]$. O número $m(0)$ é a média de Y no primeiro período; $m(X)$ atribui a cada linha a média do seu período. Para uma regra g , o erro quadrático médio é

$$\text{EQM}(g) = \frac{1}{n} \sum_{i=1}^n (Y_i - g(X_i))^2.$$

- Apresente uma tabela por período com número de votações, convergências e $m(x)$. Calcule a diferença entre períodos em **pontos percentuais**. Explique a distinção entre a função m , o número $m(1)$ e a variável aleatória $m(X)$.
- Reconstrua $E[Y]$ com $m(0) \Pr(X = 0) + m(1) \Pr(X = 1)$. Por que a média simples das duas médias condicionais geralmente falha?
- Antes de executar**, ordene do menor para o maior EQM os previsores: constante 0,5; constante 1; média geral; média do período. Calcule os quatro EQMs nas mesmas 1.762 linhas e confira sua previsão. Use `left_join()` para devolver a média de cada período às linhas; confira que a junção preservou o número de linhas e não gerou ausentes.
- Defina $e_i = Y_i - m(X_i)$. Verifique a média de e_i em cada período e no conjunto. Explique por que esses desvios têm média condicional zero.
- Complete o argumento usando a Lei da Esperança Iterada (dica: condicione primeiro em X ; quais fatores passam a ser constantes?): $E[(Y - m(X))(m(X) - g(X))] = 0$. Explique por que isso implica

$$\text{EQM}(g) = \text{EQM}(m) + E[(m(X) - g(X))^2].$$

Em palavras, o que torna a CEF o melhor preditor sob perda quadrática?

Produto: uma tabela de EQMs e um parágrafo distinguindo ser o melhor preditor de produzir uma grande melhora. Quantifique a redução absoluta do EQM ao passar da média geral à média por período.

Limite da análise: as médias foram construídas e avaliadas nos mesmos dados. Um EQM menor aqui não garante melhor previsão de novas votações e não identifica um efeito causal de 2009.

7. O que ganhamos e perdemos com uma reta?

Sessão 3, exercícios 7 a 9: aproximadamente 120 a 150 minutos.

O melhor preditor linear (BLP) usa $g(X) = \alpha + \beta X$, com

$$\beta = \frac{\text{Cov}(X, Y)}{V(X)}, \quad \alpha = E[Y] - \beta E[X],$$

quando $V(X) > 0$. α é o intercepto e β é a mudança na previsão quando X aumenta uma unidade.

- Trabalhe com os valores observados x_i e y_i de X e Y . Primeiro, escreva as fórmulas que `cov(x, y)` e `var(x)` usam, defina $\bar{x}$ e $\bar{y}$ e indique o denominador de cada fórmula. Depois, calcule a covariância e a correlação e explique, em palavras, o que cada medida resume. Por fim, explique por que podemos escrever o quociente `cov(x, y) / var(x)` sem mostrar o tamanho n da base: embora cada fórmula dependa de n e use o denominador $n - 1$, esse fator é o mesmo e se cancela no quociente acima.
- Calcule α e β pelas fórmulas, **sem usar `lm()`**. Obtenha $g(0)$ e $g(1)$ e compare com $m(0)$ e $m(1)$. Mostre que $\beta = m(1) - m(0)$ e interprete a inclinação em pontos percentuais.
- Verifique que a reta passa por $(E[X], E[Y])$. Explique por que, com X binária, dois coeficientes bastam para reproduzir os dois centros condicionais. Compare o EQM do BLP com o da CEF por período.

Pausa: a seção seguinte usa uma distribuição conhecida para separar covariância, independência, CEF e BLP. Não pede estimação de MQO, erros-padrão, testes de hipótese ou interpretação causal.

8. Covariância zero não implica independência

Considere o experimento aleatório em que a variável aleatória A assume $-1, 0$ e 1 , cada um com probabilidade $1/3$. Defina a variável aleatória $B = A^2$. Todas as probabilidades e esperanças desta questão referem-se a essa distribuição exata; não é necessário simular.

- Faça uma tabela com os valores possíveis de (A, B) e suas probabilidades. Calcule $E[B | A = a]$ para cada $a \in \{-1, 0, 1\}$, escreva a função $m(a) = E[B | A = a]$ e calcule o EQM de $m(A)$. Por que esse preditor acerta todos os valores neste exemplo?
- Calcule $E[A]$, $E[B]$ e $\text{Cov}(A, B)$. Mostre cada etapa da soma e explique por que a covariância é zero.
- Calcule o BLP $g(A) = \alpha + \beta A$ usando $\beta = \text{Cov}(A, B)/V(A)$ e $\alpha = E[B] - \beta E[A]$. Encontre $g(-1)$, $g(0)$ e $g(1)$; depois, calcule seu EQM e compare-o com o EQM da CEF. O que essa comparação ensina sobre uma reta quando a relação entre as variáveis não é linear?
- A e B são independentes? Calcule $\Pr(B = 0 | A = 0)$ e $\Pr(B = 0)$ e use a comparação para justificar sua resposta. Não conclua independência apenas porque a covariância é zero.
- Ainda no exemplo, defina $u = B - (\alpha + \beta A)$. Compare $E[u]$ e $\text{Cov}(A, u)$ com $E[u | A = a]$. Explique por que as propriedades dos desvios do BLP são mais fracas que as da CEF.

Pausa: covariância zero descreve ausência de associação linear, não independência. A CEF pode capturar uma relação que o BLP não captura.

9. Tema e período: mais detalhe, quais limites?

Retome a AGNU. Agora T é a coluna **tema**. Trate cada texto completo dessa coluna como uma categoria, inclusive combinações separadas por ponto e vírgula. Assim, cada votação pertence a exatamente uma categoria nesta análise. Mantenha a categoria sem codificação temática.

- Calcule a CEF empírica $E[Y | T, X]$ e o número de votações para cada célula tema-período. Confira que a soma das contagens é 1.762. Identifique a menor célula e explique a fragilidade de uma média baseada em poucas observações.
- Construa uma figura comparando as duas médias de cada tema, usando somente temas com pelo menos 30 votações **em cada um dos dois períodos**. Escolha pontos pareados ou diferenças em pontos percentuais. Informe o filtro na legenda e use eixos que deixem clara a comparação.
- Devolva **todas** as médias tema-período às 1.762 linhas e calcule o EQM. O filtro do gráfico não deve restringir esta avaliação. Compare com os EQMs da média geral e da CEF por período. Explique por que subdividir grupos não aumenta o EQM quando as médias são calculadas e avaliadas nas mesmas linhas.
- Se uma votação com dois temas passar a ocupar duas linhas, uma em cada tema, o que acontece com a unidade de análise e com a soma das contagens? Explique por que esse procedimento não pode ser usado silenciosamente na comparação de EQMs do item c.
- Escolha um tema exibido e escreva **100 a 150 palavras** respondendo: como a convergência varia entre períodos? Inclua as duas médias, a diferença em pontos percentuais, os dois denominadores, o ganho preditivo geral de incluir tema e duas limitações: a avaliação nos mesmos dados e a ausência de identificação causal.

Antes de entregar: releia o parágrafo sem olhar o código. Ele informa qual comparação foi feita, em quais observações e com quais limites?

Conferência final do trabalho

- Os arquivos originais continuam intactos e os caminhos são relativos.
- As verificações de dados aparecem antes dos resultados.
- Todas as tabelas e figuras têm número, legenda e fonte.
- Probabilidades, proporções e pontos percentuais estão distinguidos.
- O script completo roda em uma sessão nova e gera os resultados do PDF.

Materiais de referência

Aronow e Miller (2019), *Foundations of Agnostic Statistics*, capítulo 1 e seções 2.1–2.2.5; slides e laboratórios das Aulas 2 e 3. Dados municipais: IBGE, estimativas para 1º de julho de 2020, arquivo didático preservado. Votações: base didática AGNA, construída a partir de `unvotes` 0.3.0, recorte Brasil-China, 1997–2016.