

Lista 2: enxergar e estimar uma regressão

Scatterplot, `lm()`, escalas, intercepto e simulação

FLS 6183 - Métodos Quantitativos de Pesquisa II

Aula 5 | 2026

O que você vai fazer

Esta lista concentra-se no uso e na interpretação de **regressão bivariada**. Você fará um gráfico de dispersão (*scatterplot*), ajustará retas com `lm()`, mudará a origem e a escala das variáveis, examinará resíduos e simulará dados cuja relação populacional é conhecida. O conjunto aplicado resume a convergência dos votos de Brasil e China na Assembleia Geral das Nações Unidas (AGNU), de 1997 a 2016.

Organização e entrega

- Resolva os **quatro exercícios**. Tempo de trabalho sugerido: 35 + 40 + 35 + 50 minutos, aproximadamente 2h40 no total. O roteiro é deliberadamente mais curto que a Lista 1.
- Entregue pelo Moodle um PDF, a fonte `.Rmd` ou `.qmd` e o script `.R` dos cálculos. O documento deve importar os resultados do script. Consulte o Moodle para prazo e modalidade de entrega; este arquivo não fixa uma data.
- Use caminhos relativos. Não altere o arquivo em `dados/`. Faça tabelas apenas quando ajudarem a resposta; para cada figura, informe número, eixos, unidade, denominador e fonte. Execute tudo em uma sessão nova do R.
- Extraia de `lm()` os coeficientes, valores ajustados e resíduos. Ainda não é preciso interpretar valores-p, testes ou intervalos de confiança.

Dados para os exercícios 1 a 3

O arquivo `dados/convergencia_anual_1997_2016.csv` tem **20 linhas: uma por ano**. `n_resolucoes_validas` é o número de votações com votos observados de Brasil e China; `n_convergentes` conta as votações em que os dois votos coincidem; `taxa_media_convergencia` é a razão entre essas duas colunas. No total, as taxas usam 1.762 votações válidas. A taxa é uma **proporção**, de zero a um. Sua origem está documentada em `dados/PROVENIENCIA.md`.

1. Ver os dados, ajustar a reta e interpretá-la

Tempo sugerido: 35 minutos.

- Importe o CSV com `read.csv()`. Confira 20 anos distintos, sequência de 1997 a 2016, ausência de valores faltantes nas quatro colunas, taxas entre zero e um, denominadores positivos e soma dos denominadores igual a 1.762.
- Faça um **scatterplot** da taxa anual no eixo vertical e do ano no horizontal. Cada ponto representa um ano. Descreva a direção geral, a dispersão e um aspecto que a reta poderá deixar de representar.
- Rode `modelo_ano <- lm(taxa_media_convergencia ~ ano, data = dados)`. Use `coef(modelo_ano)` e `abline(modelo_ano)` para acrescentar a reta ao gráfico. Interprete o intercepto matematicamente e explique por que ele tem pouca utilidade substantiva. Interprete a inclinação em **pontos percentuais por ano**. A inclinação descreve associação linear, não um efeito causal da passagem do tempo.
- Obtenha a previsão para 2016 e compare-a à taxa observada nesse ano. Indique o sinal do resíduo de 2016. Diga qual é a diferença entre a previsão pela reta e a observação efetiva.

2. Mudar a origem e a escala sem mudar os dados

Tempo sugerido: 40 minutos.

- Defina `anos_desde_1997 = ano - 1997` e `anos_desde_2009 = ano - 2009`. Ajuste `modelo_1997 <- lm(taxa_media_convergencia ~ anos_desde_1997, data = dados)` e um modelo análogo com `anos_desde_2009`. Compare-os a `modelo_ano`. Quais coeficientes mudam? Confira com `fitted()` se as previsões para cada um dos 20 anos mudam. Explique algebricamente por que o intercepto da parametrização centrada em 2009 é o intercepto da parametrização centrada em 1997 mais 12 vezes a inclinação.
- Qual intercepto é mais útil para comunicar o caso da AGNU: o da regressão com `ano` bruto, o centrado em 1997 ou o centrado em 2009? Justifique e dê **outro exemplo** de pesquisa em que centrar um preditor torna o intercepto substantivamente interpretável.
- Padronize `anos_desde_1997` e `taxa_media_convergencia` separadamente: subtraia a média amostral e divida pelo desvio-padrão amostral. Use `as.numeric(scale(...))` para criar `x_z` e `y_z`. Ajuste `lm(y_z ~ x_z, data = dados)`. Interprete a inclinação em desvios-padrão de Y por desvio-padrão de X ; compare-a com `cor(dados$x_z, dados$y_z)`.
- Faça um segundo scatterplot com os eixos padronizados e a nova reta. Compare-o visualmente ao gráfico original. Explique uma situação em que a padronização ajuda a comparar relações medidas em escalas diferentes e uma informação que ela esconde se as unidades originais não forem apresentadas junto.

3. Intercepto e resíduos

Tempo sugerido: 35 minutos.

- Compare `modelo_1997`, com **intercepto**, a `modelo_sem_intercepto <- lm(taxa_media_convergencia ~ 0 + anos_desde_1997, data = dados)`. Desenhe as duas retas no mesmo scatterplot, usando os valores ajustados em função do ano. Por qual ponto o segundo modelo é obrigado a passar? Por que essa restrição é substantivamente estranha para este caso?
- Calcule para os dois modelos a média dos resíduos e a soma dos quadrados dos resíduos. Com intercepto, a média amostral dos resíduos deve ser zero até precisão numérica; sem intercepto, isso não é garantido. Confira com `mean(resid(modelo_1997))` e `mean(resid(modelo_sem_intercepto))`.
- Mostre o motivo algébrico. Para $S(a, b) = \sum_{i=1}^n (Y_i - a - bX_i)^2$, derive a condição de primeira ordem em a e conclua que $\sum_i \hat{e}_i = 0$ quando o intercepto é estimado. O que resta dessa demonstração quando a regressão impõe $a = 0$?
- Agora considere uma **equação populacional** $Y = \alpha + \beta X + u$, com $E[|u|] < \infty$ e $E[u] = m$. Defina $\alpha^* = \alpha + m$ e $u^* = u - m$. Verifique que a equação para Y não mudou e que $E[u^*] = 0$. Isso explica por que podemos normalizar a **média incondicional** do erro para zero ao incluir um intercepto. A normalização também garante $E[u^* | X] = 0$? Explique. Distinga u^* , que é populacional, dos resíduos calculados por `lm()` na amostra.

4. Simular quando a população é conhecida

Tempo sugerido: 50 minutos.

Você construirá uma população por uma regra conhecida:

$$X \sim N(10, 3^2), \quad u \sim N(0, 2^2) \text{ independente de } X, \quad Y = 5 + 1,5X + u.$$

Nessa população, a inclinação da projeção linear de Y em X é 1,5 e o intercepto é 5. No R, gere amostras com `rnorm()`.

- Use `set.seed(6183)` e gere **uma amostra de 40 pares** (X, Y) conforme a regra acima. Faça o scatterplot, rode `modelo_sim <- lm(Y ~ X)` e desenhe a reta estimada. Compare os coeficientes estimados a 5 e 1,5. Por que não se espera igualdade exata numa amostra finita?
- Calcule `mean(u)` para os 40 erros gerados e `mean(resid(modelo_sim))` para a regressão com intercepto. Explique por que esses números podem ser diferentes, embora o erro tenha média populacional zero.
- Gere **100 amostras independentes** de tamanho 40 com a mesma regra e guarde as 100 inclinações estimadas por `lm()`. Faça um histograma das inclinações e marque 1,5 no eixo horizontal. Informe a média e o intervalo entre a menor e a maior inclinação simulada. Uma média das estimativas próxima de 1,5 exige que cada estimativa seja igual a 1,5? Não interprete o intervalo como intervalo de confiança.
- Neste processo, $X = 0$ fica longe do centro da distribuição de X . Refaça uma das regressões com `X_c = X - 10`. Qual é o novo intercepto populacional e qual é sua interpretação? Diga quando você preferiria comunicar coeficientes em unidades originais e quando acrescentaria uma versão padronizada.