

Aula 3: esperança condicional e previsão

CEF, melhores preditores e melhores preditores lineares

FLS 6183 - Métodos Quantitativos de Pesquisa II

2 de setembro de 2026

Mapa conceitual: da média à previsão

Pergunta

Como a esperança de Y muda quando conhecemos X ?

Por que importa?

Condicionar permite descrever heterogeneidade e construir previsões melhores.

Conexão com a Aula 2

Já sabemos resumir Y por esperança, variância, EQM, covariância e correlação.

Ao final

Você saberá calcular e interpretar a função de esperança condicional (CEF), o preditor ótimo e o melhor preditor linear (BLP), sem confundi-los com causalidade.

Um problema concreto do projeto AGNA

Para cada votação nominal válida i do Brasil:

$$Y_i = \begin{cases} 1, & \text{se Brasil e China votaram da mesma forma;} \\ 0, & \text{caso contrário.} \end{cases}$$

Podemos usar como informação:

- X_i : período, com 0 para 1997-2008 e 1 para 2009-2016;
- T_i : tema da votação.

Pergunta de hoje

O que período e tema nos dizem sobre o valor esperado e a previsão de Y_i ?

Quatro perguntas que não são equivalentes

Descrição

Qual é a convergência média observada?

Associação

A convergência média difere entre valores de X ?

Previsão

Que valor de Y devemos prever depois de observar X ?

Identificação causal

Qual seria Y sob valores alternativos de uma intervenção?

CEF e BLP respondem a perguntas de **associação** e **previsão**; não identificam efeitos causais por si sós.

Condicionar muda a distribuição relevante

Sem observar X , usamos a distribuição marginal de Y .

Ao observar $X = x$, descartamos casos incompatíveis com x e usamos a distribuição condicional:

$$\Pr(Y = y \mid X = x) \quad \text{no caso discreto.}$$

Intuição

Não perguntamos mais “onde está o centro de Y ?”. Perguntamos “onde está o centro de Y entre os casos com $X = x$?”

Esperança condicional: definição em palavras

Definição

A esperança condicional de Y dado $X = x$ é o centro da distribuição de Y entre realizações em que X assume o valor x .

Se X é binária, existem dois centros:

$$E[Y \mid X = 0] \quad \text{e} \quad E[Y \mid X = 1].$$

Definição formal no caso discreto

Para x no suporte de X :

$$E[Y \mid X = x] = \sum_{y \in \text{Supp}(Y)} y \Pr(Y = y \mid X = x).$$

Onde:

- X e Y representam as variáveis aleatórias;
- x e y representam valores particulares que essas variáveis podem assumir;
- $\Pr(Y = y \mid X = x)$ é a probabilidade condicional de $Y = y$.

No caso contínuo, a soma é substituída por uma integral sobre y .

Média condicional ao período pré-2009

Entre 1997 e 2008, há 1.080 pares válidos: 849 convergentes e 231 divergentes.

$$\begin{aligned}E[Y \mid X = 0] &= 0 \Pr(Y = 0 \mid X = 0) + 1 \Pr(Y = 1 \mid X = 0) \\&= 0 \left(\frac{231}{1080} \right) + 1 \left(\frac{849}{1080} \right) \\&= 0,7861.\end{aligned}$$

Interpretação

Na distribuição empírica observada, a convergência média pré-2009 é 78,6%.

Média condicional ao período pós-2009

Entre 2009 e 2016, há 682 pares válidos: 563 convergentes e 119 divergentes.

$$\begin{aligned} E[Y \mid X = 1] &= 0 \Pr(Y = 0 \mid X = 1) + 1 \Pr(Y = 1 \mid X = 1) \\ &= 0 \left(\frac{119}{682} \right) + 1 \left(\frac{563}{682} \right) \\ &= 0,8255. \end{aligned}$$

Interpretação

Na distribuição empírica observada, a convergência média pós-2009 é 82,6%.

A CEF é uma função

O suporte de X , $\text{Supp}(X)$, é o conjunto de valores que X pode assumir. Defina:

$$m : \text{Supp}(X) \longrightarrow \mathbb{R}, \quad m(x) = E[Y \mid X = x].$$

Para o indicador de período:

$$m(x) = \begin{cases} 0,7861, & x = 0; \\ 0,8255, & x = 1. \end{cases}$$

Função e valor da função

m é a função. Já $m(x)$ é o número obtido quando avaliamos essa função em um valor fixo x .

Avaliar a CEF em X produz uma variável aleatória

Em vez de fixar a entrada em x , podemos avaliar a função na própria variável aleatória X :

$$m(X) = \begin{cases} m(0) = 0,7861, & \text{se } X = 0; \\ m(1) = 0,8255, & \text{se } X = 1. \end{cases}$$

Convenção de notação

Escrevemos $E[Y | X] = m(X)$. O objeto é uma variável aleatória porque seu valor depende do valor aleatório assumido por X .

Portanto, não é apenas omitir “ $X = x$ ” do condicionante: mudamos de um valor fixo, $m(x)$, para uma função avaliada na variável aleatória, $m(X)$.

As médias condicionais observadas no AGNA

Tabela 1: Média condicional observada da convergência Brasil-China por período, 1997-2016.

Período	Pares válidos	Convergentes	Média condicional
1997-2008	1080	849	78,6%
2009-2016	682	563	82,6%

Diferença associacional

$m(1) - m(0) = 0,8255 - 0,7861 = 0,0394$, ou 3,9 pontos percentuais.

O que a CEF permite interpretar

Proposição a demonstrar

Sob perda quadrática, a CEF é o melhor preditor de Y entre todas as funções de X . A prova virá adiante.

Ela também organiza comparações:

$$m(1) - m(0) = E[Y \mid X = 1] - E[Y \mid X = 0].$$

Erro a evitar

A diferença condicional não é automaticamente o efeito causal de entrar no período pós-2009. Temas votados, agenda e outras condições também mudaram.

Esperança iterada: recompor o centro geral

Podemos recuperar a esperança marginal (ou esperança não condicional) a partir da CEF:

$$E[Y] = E[E[Y \mid X]] .$$

Intuição

Primeiro encontramos o centro de Y dentro de cada valor de X . Depois calculamos a esperança dessa nova variável, $m(X)$, segundo a distribuição de X .

Não é necessário que X cause Y . Essa igualdade é a Lei da Esperança Iterada, uma propriedade da esperança.

Esperança iterada: derivação, passo 1

No caso discreto, começamos pela definição marginal:

$$\begin{aligned} E[Y] &= \sum_y y \Pr(Y = y) \\ &= \sum_y y \sum_x \Pr(X = x, Y = y) \\ &= \sum_x \sum_y y \Pr(X = x, Y = y). \end{aligned}$$

Passo usado

Somar as probabilidades conjuntas sobre todos os valores de x produz $\Pr(Y = y)$.

Por que podemos trocar a ordem das somas?

No exemplo do AGNA, X e Y são binárias. Portanto, as duas somas têm um número finito de termos:

$$\sum_y \sum_x y \Pr(X = x, Y = y) = \sum_x \sum_y y \Pr(X = x, Y = y).$$

Ideia

Somamos exatamente os mesmos termos; apenas mudamos a ordem em que eles são agrupados.

Mais geralmente, se $E[|Y|] < \infty$, a convergência absoluta permite trocar a ordem das somas.

Esperança iterada: derivação, passo 2

Use $\Pr(X = x, Y = y) = \Pr(Y = y \mid X = x) \Pr(X = x)$:

$$\begin{aligned} E[Y] &= \sum_x \sum_y y \Pr(Y = y \mid X = x) \Pr(X = x) \\ &= \sum_x \underbrace{\left[\sum_y y \Pr(Y = y \mid X = x) \right]}_{E[Y \mid X=x]} \Pr(X = x) \\ &= E[E[Y \mid X]]. \end{aligned}$$

O termo entre colchetes é a CEF avaliada em x .

Checagem numérica da esperança iterada

No AGNA, $\Pr(X = 0) = 1080/1762$ e $\Pr(X = 1) = 682/1762$.

$$\begin{aligned} E[E[Y \mid X]] &= 0,7861 \left(\frac{1080}{1762} \right) + 0,8255 \left(\frac{682}{1762} \right) \\ &= 0,8014 \\ &= \frac{1412}{1762} = E[Y]. \end{aligned}$$

Leitura

A convergência geral de 80,1% combina os centros dos dois períodos segundo a frequência observada de cada período.

O desvio em torno da CEF tem centro condicional zero

Defina o desvio da CEF:

$$\varepsilon = Y - E[Y | X].$$

Então:

$$\begin{aligned} E[\varepsilon | X] &= E[Y - E[Y | X] | X] \\ &= E[Y | X] - E[Y | X] \\ &= 0. \end{aligned}$$

Consequências: $E[\varepsilon] = 0$ e $\text{Cov}(g(X), \varepsilon) = 0$ para qualquer função g de X .

Pausa 1: o que muda ao incluir tema?

Suponha que trocamos X pelo par (T, X) , tema e período.

- ① Em que condição $E[Y | T, X]$ reduzirá o EQM em relação a $E[Y | X]$?
- ② Uma diferença grande entre temas pode coexistir com uma diferença pequena entre períodos?
- ③ Como poucos votos em uma célula tema-período afetam a confiança que você teria na média observada?

Dica

Pense no quanto os centros das células variam e no número de observações que sustenta cada centro.

Prever exige definir uma função de perda

Um preditor $g(X)$ usa o valor observado de X para produzir uma previsão de Y .

Sob perda quadrática, avaliamos:

$$\text{EQM}(g) = E[(Y - g(X))^2] .$$

Onde:

- g é a regra de previsão;
- $Y - g(X)$ é o erro de previsão;
- o quadrado penaliza erros maiores mais intensamente.

Sem informação de X , a melhor constante é $E[Y]$

Considere previsões constantes $g(X) = c$.

$$\begin{aligned} E[(Y - c)^2] &= E[(Y - E[Y] + E[Y] - c)^2] \\ &= V(Y) + (E[Y] - c)^2. \end{aligned}$$

Como $V(Y)$ não depende de c , o menor EQM ocorre em:

$$c = E[Y].$$

No AGNA, a melhor previsão constante é 0,8014.

A CEF é o melhor preditor sob EQM

Resultado

Entre todas as funções possíveis de X , $m(X) = E[Y | X]$ minimiza $E[(Y - g(X))^2]$.

O resultado não exige:

- que a CEF seja linear;
- que X seja contínua;
- que X cause Y ;
- que os desvios tenham variância constante.

Ele exige que a esperança dos quadrados envolvidos seja finita.

Prova do preditor ótimo: passo 1

Para qualquer candidato $g(X)$, escreva:

$$Y - g(X) = \underbrace{Y - m(X)}_{\varepsilon} + \underbrace{m(X) - g(X)}_W.$$

Ao elevar ao quadrado:

$$(Y - g(X))^2 = \varepsilon^2 + 2\varepsilon W + W^2.$$

Como W depende somente de X , podemos tratá-lo como fixo ao condicionar em X .

Prova do preditor ótimo: passo 2

O termo cruzado desaparece:

$$E[\varepsilon W] = E[E[\varepsilon W \mid X]] = E[W E[\varepsilon \mid X]] = 0.$$

Logo:

$$\text{EQM}(g) = \underbrace{E[(Y - m(X))^2]}_{\text{erro irreduzível dado } X} + \underbrace{E[(m(X) - g(X))^2]}_{\text{custo de não usar a CEF}}.$$

O segundo termo é não negativo e vale zero quando $g(X) = m(X)$.

Quanto o período melhora a previsão no AGNA?

Tabela 2: EQM de quatro previsores na distribuição empírica Brasil-China.

Preditor	Previsão	EQM
Constante 0,5	0,5000	0,250000
Sempre 1	1,0000	0,198638
Média geral $E[Y]$	0,8014	0,159181
CEF por período $E[Y X]$	0,7861 ou 0,8255	0,158813

Na distribuição empírica observada, a CEF reduz o EQM em apenas 0,000368 ante a média geral. Esse ganho coincide com $V(E[Y | X])$ na decomposição da variância apresentada no anexo.

Ser ótimo não significa produzir grande ganho preditivo.

Predição ótima não revela um mecanismo

O teorema é preditivo

Se soubermos a distribuição conjunta de (X, Y) , a CEF minimiza o EQM ao prever Y com X .

O teorema não responde:

- por que a distribuição conjunta tem essa forma;
- o que ocorreria se intervíssemos em X ;
- se a associação sobreviveria em outra população ou período;
- como estimar a CEF populacional com amostra finita.

Essas são perguntas de mecanismo, identificação, transporte e inferência.

O BLP restringe a regra de previsão

A CEF pode assumir qualquer forma. Começamos restringindo a busca a regras com dois coeficientes ainda desconhecidos:

$$g(X) = \alpha + \beta X,$$

onde α é o intercepto e β é a inclinação. O BLP escolhe esses dois números para resolver:

$$\min_{(\alpha, \beta) \in \mathbb{R}^2} E[(Y - \alpha - \beta X)^2].$$

Troca envolvida

Ganhamos uma descrição por dois números; podemos perder padrões não lineares da CEF.

Derivação do BLP: passo 1, condições de primeira ordem

Defina $Q(\alpha, \beta) = E[(Y - \alpha - \beta X)^2]$ e $u = Y - \alpha - \beta X$.

$$\frac{\partial Q}{\partial \alpha} = -2E[u] = 0, \quad \frac{\partial Q}{\partial \beta} = -2E[Xu] = 0.$$

Portanto, os coeficientes escolhidos satisfazem:

$$E[Y - \alpha - \beta X] = 0, \quad E[X(Y - \alpha - \beta X)] = 0.$$

As duas condições dizem que o desvio do BLP tem esperança zero e é ortogonal a X .

Derivação do BLP: passo 2, resolver o intercepto

Use a primeira condição:

$$\begin{aligned} 0 &= E[Y - \alpha - \beta X] \\ &= E[Y] - \alpha - \beta E[X]. \end{aligned}$$

Logo:

$$\boxed{\alpha = E[Y] - \beta E[X].}$$

Implicação geométrica

A reta é $g(x) = \alpha + \beta x$. Ao avaliá-la em $x = E[X]$:

$$g(E[X]) = \alpha + \beta E[X] = E[Y].$$

Logo, o BLP passa pelo ponto $(E[X], E[Y])$.

Isso não exige avaliar a reta em $x = 0$. O intercepto é $g(0) = \alpha$; somente quando $E[X] = 0$ temos $\alpha = E[Y]$.

Derivação do BLP: passo 3, resolver a inclinação

Substitua $\alpha = E[Y] - \beta E[X]$ na segunda condição:

$$\begin{aligned} 0 &= E[X(Y - \alpha - \beta X)] \\ &= E[XY] - E[X]E[Y] - \beta\{E[X^2] - E[X]^2\} \\ &= \text{Cov}(X, Y) - \beta V(X). \end{aligned}$$

Se $V(X) > 0$:

$$\boxed{\beta = \frac{\text{Cov}(X, Y)}{V(X)}}.$$

Como interpretar os dois coeficientes do BLP

$$g(X) = \alpha + \beta X, \quad \beta = \frac{\text{Cov}(X, Y)}{V(X)}, \quad \alpha = E[Y] - \beta E[X].$$

Inclinação β

Mudança na previsão linear quando X aumenta uma unidade. Depende das unidades de X e Y .

Intercepto α

Previsão linear quando $X = 0$. Só tem interpretação substantiva direta se zero for um valor relevante.

Nenhum dos dois coeficientes recebe interpretação causal sem um argumento adicional de identificação.

Se a CEF é linear, ela coincide com o BLP

Suponha que a CEF já tenha a forma:

$$E[Y | X] = c + dX.$$

Essa função pertence ao conjunto de candidatos lineares e já minimiza o EQM entre **todas** as funções de X .

Logo, também minimiza o EQM no conjunto menor de funções lineares:

$$\alpha = c, \quad \beta = d, \quad \text{BLP}(X) = E[Y | X].$$

A recíproca exige cuidado

O BLP sempre é linear; sua existência não implica que a CEF seja linear.

Exemplo calculado: BLP com indicador de período

Com $X \in \{0, 1\}$:

$$\begin{aligned}\beta &= E[Y \mid X = 1] - E[Y \mid X = 0] \\ &= 0,8255 - 0,7861 = 0,0394,\end{aligned}$$

$$\alpha = E[Y \mid X = 0] = 0,7861.$$

Assim:

$$g(X) = 0,7861 + 0,0394X.$$

Para $X = 0$, a previsão é 0,7861; para $X = 1$, é 0,8255.

Com X binária, a reta já é saturada

Uma reta tem dois parâmetros e precisa reproduzir apenas dois pontos:

$$\begin{aligned}g(0) &= \alpha = E[Y \mid X = 0], \\g(1) &= \alpha + \beta = E[Y \mid X = 1].\end{aligned}$$

Portanto:

$$g(X) = E[Y \mid X] \quad \text{quando } X \in \{0, 1\}.$$

Generalização para X discreta

Se X assume K valores, um intercepto e $K - 1$ indicadores saturam o preditor linear:

$$g_{\text{sat}}(X) = \alpha + \sum_{k=2}^K \delta_k \mathbf{1}\{X = x_k\}.$$

Esse BLP coincide com a CEF. Com $K > 2$, apenas a reta $\alpha + \beta X$ geralmente não coincide.

Indicadoras de ano saturam o BLP




Figura 1: CEF anual, equivalente ao BLP saturado em indicadores de ano, e BLP linear simples da convergência Brasil-China, 1997-2016.

Uma indicadora para cada ano, omitindo uma categoria de referência, reproduz exatamente a CEF anual em azul. A reta vermelha usa apenas o termo numérico ano e pode perder padrões não lineares. A figura é descritiva e pondera anos pelo número de votos válidos.

Desvios da CEF e do BLP têm forças diferentes

Para a CEF, $\varepsilon_{\text{CEF}} = Y - E[Y | X]$ satisfaz:

$$E[\varepsilon_{\text{CEF}} | X] = 0.$$

Para o BLP linear simples, $\varepsilon_{\text{BLP}} = Y - (\alpha + \beta X)$ satisfaz:

$$E[\varepsilon_{\text{BLP}}] = 0, \quad \text{Cov}(X, \varepsilon_{\text{BLP}}) = 0.$$

Diferença central

Em um BLP não saturado, o desvio pode ter esperança condicional diferente de zero para alguns valores de X . Com indicadoras saturadas para X discreta, o BLP coincide com a CEF e essa diferença desaparece.

Independência produz CEF e BLP constantes

Se X e Y são independentes, então $\Pr(Y = y \mid X = x) = \Pr(Y = y)$.

Logo:

$$E[Y \mid X] = E[Y], \quad V(Y \mid X) = V(Y).$$

Além disso, $\text{Cov}(X, Y) = 0$, então:

$$\beta = 0, \quad \alpha = E[Y].$$

A volta não é automática

Covariância zero ou BLP horizontal não implica independência; relações não lineares podem permanecer.

De volta às quatro perguntas do projeto

Podemos fazer hoje

Descrever médias por tema e período; comparar CEFs; construir previsões simples; comparar EQMs; resumir linearmente com BLP.

Ainda não podemos fazer

Atribuir mudanças a 2009; interpretar associação como efeito do comércio; antecipar MQO; estimar regressões em corte transversal ou painel.

O laboratório produzirá uma análise de associação e previsão, não uma afirmação causal.

Desafio para a turma de pós-graduação

- 1 Se a CEF é não linear, por que mudar a distribuição de X pode mudar o BLP mesmo sem mudar a CEF?
- 2 Uma variável pode reduzir muito o EQM e ainda ser inútil para identificação causal? Construa um exemplo.
- 3 Ao cruzar tema e período, que tensão surge entre flexibilidade da CEF e número de observações por célula?
- 4 Se o BLP tem inclinação zero, que tipos de associação entre X e Y ainda podem existir?

Síntese: três ideias para levar adiante

- 1 A CEF $E[Y \mid X = x]$ descreve como o centro de Y varia com x .
- 2 Sob EQM, a CEF é o melhor preditor; o BLP é o melhor entre preditores lineares.
- 3 Descrição, associação e previsão não substituem identificação causal.

Condicionar organiza informação; não cria um contrafactual.

Leitura-base: Aronow, Peter M., e Benjamin T. Miller. *Foundations of Agnostic Statistics* (2019), seções 2.2.3-2.2.5. Dados: recorte AGNA de votações da Assembleia Geral da ONU, 1997-2016.

Anexo: de onde vem o termo cruzado?

Defina $m(X) = E[Y | X]$ e some e subtraia $m(X)$:

$$Y - E[Y] = \underbrace{Y - m(X)}_{\text{desvio dentro}} + \underbrace{m(X) - E[Y]}_{\text{desvio entre}}.$$

Ao calcular a variância, elevamos essa soma ao quadrado. Inicialmente aparecem três termos:

$$\begin{aligned} V(Y) &= E[\underbrace{(Y - m(X))^2}_{\text{termo dentro}}] \\ &\quad + \underbrace{2E[(Y - m(X))(m(X) - E[Y])]}_{\text{termo cruzado}} \\ &\quad + \underbrace{E[(m(X) - E[Y])^2]}_{\text{termo entre}}. \end{aligned}$$

O próximo passo mostra por que o termo do meio desaparece.

Anexo: por que o termo cruzado é zero?

O termo cruzado é duas vezes a esperança de um produto. Basta mostrar que essa esperança é zero:

$$\underbrace{E[(Y - m(X))(m(X) - E[Y])]}_{E[AB]} = \underbrace{E[E[(Y - m(X))(m(X) - E[Y]) \mid X]]}_{E[E[AB \mid X]]}.$$

Como $m(X) - E[Y]$ é função de X , podemos retirá-lo da esperança condicional:

$$E[E[AB \mid X]] = E \left[(m(X) - E[Y]) \underbrace{E[Y - m(X) \mid X]}_{m(X) - m(X) = 0} \right] = 0.$$

Anexo: decomposição da variância no AGNA

Como o termo cruzado é zero, restam apenas as parcelas dentro e entre:

$$V(Y) = \underbrace{E[V(Y | X)]}_{\text{dentro}} + \underbrace{V(E[Y | X])}_{\text{entre}}.$$

Como Y é binária, $V(Y | X = x) = m(x)[1 - m(x)]$.

$$\begin{aligned} E[V(Y | X)] &= \underbrace{0,6129}_{\Pr(X=0)}(0,7861)(0,2139) \\ &\quad + \underbrace{0,3871}_{\Pr(X=1)}(0,8255)(0,1745) \\ &= 0,158813. \end{aligned}$$

$$V(E[Y | X]) = 0,000368, \quad V(Y) = 0,159181.$$

$0,158813 + 0,000368 = 0,159181$. O período separa pouca da variabilidade total voto a voto.

Anexo: a parcela entre grupos é o ganho preditivo

Sob perda quadrática:

$$\begin{aligned}\text{EQM}(E[Y]) &= V(Y), \\ \text{EQM}(E[Y | X]) &= E[V(Y | X)].\end{aligned}$$

Logo:

$$\text{EQM}(E[Y]) - \text{EQM}(E[Y | X]) = V(E[Y | X]).$$

No AGNA

$0,159181 - 0,158813 = 0,000368$: conhecer o período reduz o EQM em apenas 0,23%. A decomposição quantifica quanto da variação de Y é previsível a partir de X .