

Aula 4: inferência causal

Resultados potenciais, mecanismos de seleção e experimentos aleatórios

FLS 6183 - Métodos Quantitativos de Pesquisa II

16 de setembro de 2026


Correlações que convidam uma interpretação causal

- 1 Pessoas que jogam **tênis** vivem mais.
- 2 Casais que mantêm **sobrenomes separados** se divorciam mais e antes.
- 3 Eleitores **contatados por campanhas** apoiam mais o candidato.

A tentação

Cada correlação permite contar uma história plausível sobre causa e efeito. A história, sozinha, não mostra o que aconteceria se mudássemos a escolha ou a intervenção.

Tênis e longevidade



Fonte do print: ABC News, 07/12/2018.

9,7 anos

Diferença estimada de expectativa de vida entre praticantes de tênis e pessoas sedentárias.

História causal: exercício, decisões rápidas e contato social prolongariam a vida.

Seleção: saúde anterior, renda, acesso, rotina e sociabilidade também influenciam quem joga.

Pergunta causal

O tênis prolonga a vida ou pessoas com trajetórias diferentes escolhem jogar tênis?

Estudo: Schnohr et al. (2018), Copenhagen City Heart Study. Associação observacional ajustada.

Sobrenome compartilhado e divórcio



Fonte do print: Polymarket no X, 15/09/2026.

+50%

O post afirma mais divórcios e separações cerca de **30% mais cedo** entre casais com sobrenomes diferentes.

Seleção: valores, religiosidade, expectativas e compromisso influenciam a escolha do sobrenome e o casamento.

Pergunta causal

Incentivar casais a compartilhar um sobrenome reduziria divórcios?

Análise original: Stone (2026), Institute for Family Studies. O autor descreve forte viés de seleção e não atribui sobrenomes aleatoriamente.

Contato de campanha e apoio eleitoral

Comparação observacional

Eleitores contatados por uma campanha podem demonstrar mais apoio ao candidato do que eleitores não contatados.

Campanhas escolhem onde concentrar tempo e recursos. Elas podem procurar:

- apoiadores potenciais;
- pessoas mais fáceis de localizar;
- eleitores com maior probabilidade de votar.

Problema

A diferença pode refletir persuasão e também o direcionamento estratégico da campanha.


Fonte: Arceneaux (2007), que usa um experimento aleatório para separar o efeito do contato do direcionamento da campanha.

A mesma estrutura nos três exemplos

Comparação	História causal	Como os grupos podem diferir
Tênis	O esporte prolonga a vida	Saúde, renda, rotina e sociabilidade
Sobrenome	O nome fortalece o casamento	Valores, compromisso e expectativas
Campanha	O contato persuade	Alvo escolhido pela própria campanha

As explicações alternativas começam antes da comparação dos resultados.

Correlação não implica causalidade



A associação pode ser real. Ela ainda não revela o mecanismo que a produziu.

Fonte: Randall Munroe, xkcd nº 552, "Correlation" (2009). Licença CC BY-NC 2.5.

Como os grupos foram formados?

Como cada pessoa, organização ou caso foi parar em um dos grupos?

Mecanismo de seleção

Conjunto de decisões, regras e circunstâncias que determina quem recebe uma intervenção e quem permanece na alternativa de comparação.

Essa pergunta vem antes da comparação das médias.

Uma variável, vários nomes

Lado de X ou D	Lado de Y
Variável independente	Variável dependente
Variável de tratamento	Variável resposta
Variável explicativa	Variável explicada
Variável preditora	Variável predita
Regressor	Regressando

Vocabulário desta aula

Usaremos **variável de tratamento** para D_i e **variável resposta** para Y_i .

Fonte: adaptado da tabela "Terminology" dos slides de regressão de Manoel Galdino.

Tratamento, controle e resposta

Para estudar uma intervenção binária, adotaremos a linguagem da medicina:

- **tratamento**: alternativa de interesse;
- **controle**: alternativa relevante ao tratamento;
- $D_i = 1$: a unidade i recebe o tratamento;
- $D_i = 0$: a unidade i permanece no controle;
- Y_i : valor da variável resposta para a unidade i .

Mecanismos de seleção

Autoseleção

A própria unidade escolhe entre tratamento e controle.

Exemplos: praticar um esporte, candidatar-se à reeleição, aderir a um programa.

Seleção por outros atores

Outra pessoa ou instituição decide a atribuição.

Exemplos: médico, campanha, partido, burocracia ou regra de elegibilidade.

Agência e consequências esperadas

Pessoas e organizações não precisam conhecer a linguagem da inferência causal.

Elas formam crenças sobre as consequências de cada escolha e agem com base nessas crenças, sob informação e restrições.

Implicação

Quando a escolha depende das consequências esperadas, os grupos podem ser diferentes justamente nas quantidades que gostaríamos de comparar.

O formalismo de resultados potenciais torna essa dificuldade explícita.

Dois resultados potenciais para cada unidade

Para uma unidade i :

$Y_i(1)$ = resultado de i se recebesse o tratamento

$Y_i(0)$ = resultado da mesma unidade se permanecesse no controle

Exemplo eleitoral

$Y_i(1)$ é o apoio da eleitora i se fosse contatada. $Y_i(0)$ é o apoio da mesma eleitora se não fosse contatada.

Resultado potencial não significa grupo observado

Grupo observado	$Y_i(1)$	$Y_i(0)$
$D_i = 1$	Resultado observado sob tratamento	Resultado que teria sob controle
$D_i = 0$	Resultado que teria sob tratamento	Resultado observado sob controle

Distinção essencial

$Y_i(1)$ existe como resultado potencial também para quem observamos em $D_i = 0$. $Y_i(0)$ existe como resultado potencial também para quem observamos em $D_i = 1$.

Quatro médias diferentes

Quantidade	Leitura	Status
$E[Y_i(1) \mid D_i = 1]$	Tratados sob tratamento	Observada por meio de Y_i
$E[Y_i(0) \mid D_i = 1]$	Tratados se estivessem no controle	Contrafactual
$E[Y_i(1) \mid D_i = 0]$	Controles se fossem tratados	Contrafactual
$E[Y_i(0) \mid D_i = 0]$	Controles sob controle	Observada por meio de Y_i

Os dois termos contrafactuais fazem perguntas sobre pessoas que estão no grupo oposto.

O resultado observado

Depois que o mecanismo atribui D_i , observamos apenas o resultado correspondente:

$$Y_i = \begin{cases} Y_i(1), & D_i = 1, \\ Y_i(0), & D_i = 0. \end{cases}$$

Equação de seleção do resultado observado:

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$$

A atribuição faz duas coisas

Ela define qual alternativa a unidade recebe e qual dos dois resultados potenciais se torna observável.

Problema fundamental da inferência causal

i	D_i	$Y_i(0)$	$Y_i(1)$	Y_i
1	1	?	8	8
2	0	6	?	6
3	1	?	5	5
4	0	3	?	3

O contrafactual ausente

Para a mesma unidade e o mesmo momento, observamos $Y_i(1)$ ou $Y_i(0)$. Nunca observamos ambos. Aumentar o número de unidades não revela o potencial ausente de cada uma.

Holland (1986) chamou essa impossibilidade de problema fundamental da inferência causal.

Efeitos causais de características imutáveis

Regra de Holland

“No causation without manipulation.” Para Imai, a regra exige reformular perguntas sobre gênero, raça, idade ou outros atributos que não podem ser atribuídos diretamente.

- 1 **Característica percebida:** variar o atributo que a pessoa responsável pela decisão percebe.
- 2 **Reinterpretação:** estudar uma situação manipulável associada ao atributo.
- 3 **Redefinição:** decompor o atributo em componentes que podem variar.
- 4 **Intervenção no grupo:** alterar uma condição e medir quanto da diferença entre grupos permanece.

Ligação com o tema da resolução

“Direitos humanos” não é uma característica imutável, mas também pode designar um pacote de rótulo, texto, problema, atores e contexto. A pergunta causal precisa escolher qual componente varia.

Tema não define automaticamente um tratamento

Suponha:

$$D_i = 1 \text{ para direitos humanos,} \quad D_i = 0 \text{ para desarmamento.}$$

Escrever $Y_i(1)$ e $Y_i(0)$ ainda não esclarece o que fazemos com a resolução i .

Leitura do “tema”	Comparação resultante
Rótulo percebido	A mesma resolução apresentada com etiquetas temáticas diferentes
Enquadramento textual	A mesma proposta escrita em versões de direitos humanos e de segurança
Categoria substantiva	Resoluções diferentes; problema, texto, atores, momento e unidade podem mudar juntos

Cada leitura define resultados potenciais e efeitos causais diferentes.

Uma intervenção define o estimando

Uma pergunta mais precisa poderia ser:

Intervenção hipotética

Qual é o efeito de apresentar a mesma proposta com um enquadramento de direitos humanos, em vez de um enquadramento de segurança, mantendo fixo seu conteúdo substantivo, sobre a probabilidade de o Brasil votar “sim”?

$$ATE_{\text{enquadramento}} = E[Y_i(\text{direitos humanos}) - Y_i(\text{segurança})].$$

Estimando causal

É a quantidade definida pela unidade, pelas duas versões da intervenção, pela variável resposta, pela população e pelo momento da comparação.

Uma pergunta bem definida ainda precisa de um desenho que identifique esse estimando. O banco AGNA atual não contém essa intervenção.

Efeito causal individual

O efeito causal para a unidade i é:

$$\tau_i = Y_i(1) - Y_i(0)$$

Exemplo hipotético:

$$Y_i(1) = 8, \quad Y_i(0) = 6 \quad \implies \quad \tau_i = 2.$$

O contraste correto

Mantemos a unidade fixa e mudamos apenas seu estado de tratamento. Comparar duas pessoas diferentes não produz diretamente τ_i .

Efeito médio do tratamento

O efeito médio do tratamento na população é:

$$ATE = E[\tau_i] = E[Y_i(1) - Y_i(0)] = E[Y_i(1)] - E[Y_i(0)]$$

Alvo causal

O ATE responde quanto o resultado mudaria, em média, se toda a população passasse do controle para o tratamento.

O ATE continua envolvendo dois resultados potenciais por unidade, embora seja uma média.

Efeito médio entre quem recebeu o tratamento

$$ATT = E[\tau_i \mid D_i = 1] = E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 1]$$

População diferente

O ATT calcula o efeito médio apenas entre as unidades que o mecanismo colocou no tratamento.

Se o mecanismo seleciona quem mais se beneficia, ATT e ATE podem diferir.

A tabela-oráculo da Médica Perfeita

i	1	2	3	4	5
$Y_i(1)$	7	5	5	7	4
$Y_i(0)$	1	6	1	8	2
τ_i	6	-1	4	-1	2

i	6	7	8	9	10
$Y_i(1)$	10	1	5	3	9
$Y_i(0)$	1	10	6	7	8
τ_i	9	-9	-1	-4	1

$$ATE = \frac{6 - 1 + 4 - 1 + 2 + 9 - 9 - 1 - 4 + 1}{10} = 0,6 \text{ ano.}$$

Fonte dos valores: Cunningham, *Causal Inference: The Remix*, capítulo 4. Valores inteiramente hipotéticos.

A Médica Perfeita escolhe para cada paciente

Ela conhece os dois resultados potenciais e atribui o ventilador quando ele prolonga a vida:

$$D_i = \mathbf{1}\{Y_i(1) > Y_i(0)\} = \mathbf{1}\{\tau_i > 0\}.$$

Grupo	Pacientes	Regra
Ventilador ($D = 1$)	1, 3, 5, 6, 10	$\tau_i > 0$
Sem ventilador ($D = 0$)	2, 4, 7, 8, 9	$\tau_i \leq 0$

Seleção orientada pelo benefício

A médica produz o melhor resultado para cada paciente e, ao mesmo tempo, cria grupos muito diferentes.

A associação muda o sinal do efeito

Na tabela completa, conhecemos o efeito causal médio:

$$ATE = +0,6 \text{ ano.}$$

Nos dados observados, comparar os grupos produz:

$$SDO = E[Y_i | D_i = 1] - E[Y_i | D_i = 0] = 7,0 - 7,4 = -0,4 \text{ ano.}$$

O aparente paradoxo

O ventilador prolonga a vida em média, mas pacientes no ventilador vivem menos que pacientes fora dele.

Diferença Simples de Médias (SDO)

Defina:

$$\text{SDO} = E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0].$$

Pela equação do resultado observado:

$$\text{SDO} = E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0].$$

O contraste observado

Comparamos pessoas diferentes sob estados diferentes. Esse contraste ainda não mantém a unidade fixa.

SDO preserva a sigla de Cunningham para *Simple Difference in Outcomes*; em português, usaremos *Diferença Simples de Médias*.

O contrafactual revela as duas parcelas

Some e subtraia o resultado que os tratados teriam sob controle:

$$\begin{aligned} \text{SDO} = & E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 1] \\ & + E[Y_i(0) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0]. \end{aligned}$$

Por que esse termo?

$E[Y_i(0) \mid D_i = 1]$ mantém fixo o grupo tratado e pergunta o que aconteceria com ele na alternativa de controle.

Efeito causal e viés de seleção

$$\begin{aligned} \text{SDO} = & \underbrace{E[Y_i(1) - Y_i(0) \mid D_i = 1]}_{ATT} \\ & + \underbrace{E[Y_i(0) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0]}_{\text{viés de seleção}} \end{aligned}$$

Interpretação

A SDO mistura o efeito entre tratados com uma diferença que já existiria entre os grupos sob controle.

Decomposição da Médica Perfeita

Entre os pacientes que receberam ventilador:

$$ATT = 4,4 \text{ anos.}$$

Se ninguém recebesse ventilador, os dois grupos ainda seriam diferentes:

$$E[Y_i(0) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0] = 2,6 - 7,4 = -4,8.$$

Portanto:

$$\boxed{-0,4 = 4,4 - 4,8.}$$

O mecanismo de seleção nos três exemplos

Exemplo	Quem seleciona	Informação relacionada aos resultados
Tênis	A própria pessoa e suas circunstâncias	Saúde, renda, preferências e expectativa de benefício
Sobrenome	O casal, sob normas e regras	Valores, compromisso e expectativa sobre o casamento
Campanha	Organização partidária	Apoio prévio, propensão a votar e chance de persuasão

Em cada caso, o processo que forma os grupos pode estar relacionado a $Y_i(0)$, a $Y_i(1)$ ou ao ganho τ_i .

O Médico Ruim ignora os resultados potenciais

Cunningham contrasta a Médica Perfeita com um Médico Ruim.

Médica Perfeita

Escolhe a melhor opção para cada paciente usando $Y_i(1)$ e $Y_i(0)$.
Produce seleção orientada pelos ganhos.

Médico Ruim

Atribui o ventilador sem usar $Y_i(1)$, $Y_i(0)$ ou τ_i .
Produce uma atribuição independente dos resultados potenciais.

A ironia

O melhor mecanismo para cada paciente pode produzir dados ruins para comparação. Um mecanismo indiferente aos resultados potenciais produz grupos comparáveis em média.

Experimento aleatório como mecanismo de seleção

Em um experimento, a pesquisadora controla como as unidades chegam ao tratamento e ao controle.

Atribuição aleatória

O sorteio determina D_i sem consultar características, expectativas ou resultados potenciais das unidades.

$$(Y_i(0), Y_i(1)) \perp\!\!\!\perp D_i.$$

O ponto relevante

O experimento não elimina o mecanismo de seleção. Ele substitui o mecanismo anterior por um mecanismo conhecido e independente dos resultados potenciais.

Independência dos resultados potenciais

Se $(Y_i(0), Y_i(1)) \perp\!\!\!\perp D_i$, então:

$$E[Y_i(0) \mid D_i = 1] = E[Y_i(0) \mid D_i = 0] = E[Y_i(0)],$$

$$E[Y_i(1) \mid D_i = 1] = E[Y_i(1) \mid D_i = 0] = E[Y_i(1)].$$

Leitura

Tratados e controles têm, em expectativa, os mesmos resultados potenciais. Trocar os rótulos dos grupos não altera essas médias esperadas.

O viés de seleção se cancela

Sob atribuição aleatória:

$$\begin{aligned}\text{viés de seleção} &= E[Y_i(0) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0] \\ &= E[Y_i(0)] - E[Y_i(0)] \\ &= 0.\end{aligned}$$

Além disso, a atribuição independente implica, em expectativa:

$$ATT = ATE.$$

Quando a SDO identifica o ATE


Com independência dos resultados potenciais:

$$\begin{aligned} \text{SDO} &= E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0] \\ &= \text{ATT} + 0 \\ &= \text{ATE}. \end{aligned}$$

Qualificação

A igualdade vale em expectativa sobre o mecanismo de atribuição. Um sorteio específico pode produzir grupos desequilibrados e uma estimativa distante do ATE.

Sorteios diferentes, estimativas diferentes



A média das 252 SDOs é 0,6 ano, exatamente o ATE da população fictícia.

Aplicação ao projeto AGNA

Período	Resoluções	Convergentes	Proporção
1997–2008	1.080	849	78,6%
2009–2016	682	563	82,6%

$$82,6\% - 78,6\% = 3,94 \text{ pontos percentuais.}$$

Diagnóstico

O período separa observações no tempo, mas não define uma intervenção. A agenda de resoluções e o contexto internacional também mudam. Sem D_i , resultados potenciais e mecanismo de seleção claros, a SDO permanece descritiva.

Três perguntas para qualquer afirmação causal

- 1 Qual intervenção define $D_i = 1$ e qual alternativa define $D_i = 0$?
- 2 Como as unidades chegaram a cada grupo?
- 3 Esse mecanismo depende de $Y_i(0)$, de $Y_i(1)$ ou do ganho τ_i ?

Regra de leitura

Antes de interpretar uma correlação, reconstrua o mecanismo de seleção.

- 1 Efeito causal compara dois resultados potenciais da mesma unidade.
- 2 A codificação de D_i só define um efeito quando suas versões correspondem a uma intervenção clara.
- 3 Observamos apenas o potencial correspondente ao estado recebido.
- 4 A SDO mistura efeito causal e seleção.
- 5 Agência e decisões institucionais costumam relacionar D_i aos resultados potenciais.
- 6 A atribuição aleatória rompe essa relação em expectativa.

Ideia central

Inferência causal começa pela pergunta sobre o mecanismo que formou os grupos.

Referências da aula

Arceneaux, Kevin. 2007. “I’m Asking for Your Support: The Effects of Personally Delivered Campaign Messages on Voting Decisions and Opinion Formation.’’ *Quarterly Journal of Political Science* 2: 43–65.

Aronow, Peter M.; Miller, Benjamin T. 2019. *Foundations of Agnostic Statistics*. Capítulo 7.

Cunningham, Scott. *Causal Inference: The Remix*. Capítulo 4, “Potential Outcomes and Randomization.’’
Versão online consultada em 16/09/2026.

Imai, Kosuke. 2021. *Potential Outcomes*. Slides de aula, Harvard University, slide 8.

Holland, Paul W. 1986. “Statistics and Causal Inference.’’ *Journal of the American Statistical Association* 81(396): 945–960.

Munroe, Randall. 2009. “Correlation.’’ *xkcd*, nº 552. Licença CC BY-NC 2.5.

Stone, Lyman. 2026. “Can Sharing a Last Name Save Your Marriage? It Depends.’’ *Institute for Family Studies*, 16 de abril.

Schnohr, Peter et al. 2018. “Various Leisure-Time Physical Activities Associated With Widely Divergent Life Expectancies: The Copenhagen City Heart Study.’’ *Mayo Clinic Proceedings* 93(12): 1775–1785.

Apêndice: decomposição centrada no ATE

Se $\pi = \Pr(D_i = 1)$ e $ATU = E[\tau_i \mid D_i = 0]$, então:

$$\begin{aligned} SDO &= ATE \\ &+ \underbrace{E[Y_i(0) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0]}_{\text{viés de seleção}} \\ &+ \underbrace{(1 - \pi)(ATT - ATU)}_{\text{viés de heterogeneidade}} \end{aligned}$$

Uso

A versão com ATT torna o viés de seleção mais transparente. Esta versão mostra também como seleção sobre ganhos afasta a SDO do ATE.

Apêndice: ATE, ATT e ATU

Pela lei da esperança iterada:

$$ATE = \pi ATT + (1 - \pi) ATU.$$

- ATE : efeito médio em toda a população.
- ATT : efeito médio entre quem recebeu o tratamento.
- ATU : efeito médio entre quem permaneceu no controle.

Heterogeneidade e seleção

Efeitos heterogêneos não geram o terceiro termo sozinhos. O termo aparece quando o mecanismo distribui unidades com ganhos médios diferentes entre tratamento e controle.

Apêndice: independência condicional

Em dados observacionais, uma estratégia pode defender independência após fixar covariáveis pré-tratamento X_i :

$$(Y_i(0), Y_i(1)) \perp\!\!\!\perp D_i \mid X_i.$$

Ela também precisa de comparação possível:

$$0 < \Pr(D_i = 1 \mid X_i = x) < 1.$$

Interpretação

Dentro de valores comuns de X_i , o mecanismo de seleção não pode conter informação adicional sobre os resultados potenciais.

Limite

Incluir muitas covariáveis em uma regressão não demonstra independência condicional.

Apêndice: consistência e interferência

O modelo binário também exige que cada estado do tratamento tenha conteúdo substantivo claro.

- **Consistência:** o tratamento observado corresponde ao resultado potencial definido para aquele tratamento.
- **Sem versões ocultas:** formas diferentes de $D = 1$ não podem produzir resultados distintos sem aparecer na definição.
- **Sem interferência:** o resultado potencial da unidade i não depende do tratamento recebido por outra unidade j .

Exemplo

“Praticar esporte” reúne atividades, intensidades e contextos sociais diferentes. Um tratamento vago produz resultados potenciais vagos.

Apêndice: variáveis posteriores ao tratamento

Uma variável medida depois de D_i pode ser consequência do próprio tratamento.

- Ajustar por um **mediador** pode bloquear parte do efeito total.
- Ajustar por um **colisor** pode criar uma associação que não existia.
- Capacidade preditiva não define se uma variável é um controle causal válido.

Regra prática

Reconstrua a ordem temporal e o mecanismo causal antes de escolher controles.