

Aula 5: mínimos quadrados ordinários

Regressão bivariada, estimação e interpretação

FLS 6183 - Métodos Quantitativos de Pesquisa II

23 de setembro de 2026

Problema

Qual reta resume melhor a associação linear entre X e Y em uma amostra?

Ponte com a Aula 3

O BLP minimiza o EQM na população. O MQO aplica o mesmo critério à amostra, e o princípio plug-in liga os dois.

- 1 Princípio plug-in
- 2 Derivação do MQO bivariado
- 3 Exemplo com quatro pares
- 4 Interpretação dos coeficientes
- 5 Aplicação ao projeto AGNA

Ao final

Você saberá derivar e calcular a reta de MQO e interpretar seus coeficientes nas unidades dos dados.

Princípio plug-in

Em palavras

Escreva a fórmula de uma quantidade da população. Aplique a mesma regra aos dados observados e use o resultado como estimador.

Para a média populacional de Y :

$$\mu = E[Y] \quad \longrightarrow \quad \hat{\mu} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Se observarmos os valores 1, 3, 2 e 6, a média amostral será $\bar{Y} = (1 + 3 + 2 + 6)/4 = 3$.

Pergunta

Aplicar a fórmula à amostra garante que o estimador não tenha viés?

Variância plug-in

Na população, denote a variância de Y por σ^2 :

$$\sigma^2 = V(Y) = E[Y^2] - E[Y]^2.$$

Ao aplicar a mesma regra à amostra:

$$\widehat{V}_{\text{PI}} = \overline{Y^2} - \bar{Y}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad \overline{Y^2} = \frac{1}{n} \sum_{i=1}^n Y_i^2.$$

Para os quatro valores do slide anterior, $\bar{Y} = 3$ e $\widehat{V}_{\text{PI}} = (4 + 0 + 1 + 9)/4 = 3,5$.

Em amostras repetidas

Se as observações forem independentes e identicamente distribuídas, com variância finita, $E[\widehat{V}_{\text{PI}}] = \frac{n-1}{n} \sigma^2$: o viés é negativo.

Viés e consistência

Duas propriedades

Viés em amostras finitas: $E[\widehat{V}_{\text{PI}}] \neq \sigma^2$ quando n é finito e $\sigma^2 > 0$. Com $n = 4$, a esperança é $3\sigma^2/4$.

Consistência: sob amostragem independente e identicamente distribuída e $\sigma^2 < \infty$, $\widehat{V}_{\text{PI}} \xrightarrow{p} \sigma^2$ quando n cresce. O símbolo $\xrightarrow{p}$ significa convergência em probabilidade.

Por quê? $\overline{Y^2} \xrightarrow{p} E[Y^2]$ e $\bar{Y} \xrightarrow{p} E[Y]$; portanto, $\overline{Y^2} - \bar{Y}^2 \xrightarrow{p} E[Y^2] - E[Y]^2$.

A correção $s^2 = \frac{n}{n-1} \widehat{V}_{\text{PI}} = \frac{1}{n-1} \sum_i (Y_i - \bar{Y})^2$ elimina o viés em amostras finitas.

Quando o plug-in funciona

- 1 Os dados precisam aproximar a distribuição de interesse; o livro parte de amostragem independente e identicamente distribuída.
- 2 A quantidade calculada precisa estar definida: para a variância, por exemplo, é necessário que $E[Y^2] < \infty$.
- 3 A regra deve ser **estável**: uma pequena mudança na distribuição não pode provocar uma mudança desproporcional na quantidade de interesse.

Condições de regularidade

Essas condições dependem da quantidade estimada. Para resultados mais fortes, como normalidade assintótica, Aronow e Miller exigem que a regra seja bem-comportada no entorno da distribuição populacional.

Sem amostragem adequada ou com uma regra instável, aplicar a fórmula à amostra não garante aproximação da quantidade populacional.

Definição formal do plug-in

Seja $\theta = T(F)$ uma característica da distribuição populacional F . Para observações $X_1, \dots, X_n$ independentes e identicamente distribuídas, $\widehat{F}$ é a função de distribuição empírica:

$$\widehat{F}(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}.$$

Estimador plug-in

$$\widehat{\theta}_{\text{PI}} = T(\widehat{F}).$$

Aplicamos à distribuição empírica a mesma regra T usada para definir θ na população.

Fonte: Aronow e Miller (2019, seções 3.2.3 e 3.3–3.3.1, pp. 105–107 e 116–120).

Convergência Brasil–China na AGNU




Figura 1: Convergência média dos votos de Brasil e China na Assembleia Geral das Nações Unidas (AGNU), 1997–2016. Cada ponto representa um ano; denominador de cada taxa: 61 a 112 resoluções válidas naquele ano. Fonte: base didática AGNA do curso.

Em 1997, a taxa observada foi 79,3%; em 2016, 69,6%. O que aconteceria se uma reta usasse **todos** os pontos, e não apenas os extremos?

Pergunta do projeto AGNA

Pergunta substantiva

Qual é a associação linear entre o ano da votação e a convergência média anual dos votos de Brasil e China na AGNU?

- Unidade de análise da regressão: **ano**, após agregar as resoluções.
- Variável resposta Y_i : taxa de convergência no ano i .
- Preditor X_i : anos decorridos desde 1997 no ano i .
- Amostra: $n = 20$ anos, de 1997 a 2016, construídos com 1.762 resoluções válidas.

Exemplo: quatro pares

São os mesmos quatro valores de Y usados no slide do princípio plug-in, agora acompanhados por um preditor X :

i	1	2	3	4
X_i	0	1	2	3
Y_i	1	3	2	6

Antes de calcular

Você esperaria uma reta crescente ou decrescente? Uma reta precisa passar por todos os quatro pontos para resumir bem a associação?

Valor ajustado e resíduo

A reta de regressão amostral associa a cada X_i observado um valor ajustado:

$$\widehat{Y}_i = \hat{\alpha} + \hat{\beta}X_i,$$

em que $\hat{\alpha}$ é o intercepto estimado e $\hat{\beta}$ é a inclinação estimada. Cada observação se decompõe em

$$\underbrace{Y_i}_{\text{observado}} = \underbrace{\widehat{Y}_i}_{\text{ajustado}} + \underbrace{\widehat{e}_i}_{\text{resíduo}}, \quad \widehat{e}_i = Y_i - \widehat{Y}_i.$$

Geometria

O resíduo é a distância vertical, com sinal, entre o ponto observado e a reta ajustada.

Resíduos no exemplo




Figura 2: Resíduos em torno da reta de MQO no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

Critério de mínimos quadrados

A soma dos quadrados dos resíduos de uma reta candidata $a + bX$ é:

$$\text{SQR}(a, b) = \sum_{i=1}^n (Y_i - a - bX_i)^2.$$

Estimador de MQO

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{(a,b) \in \mathbb{R}^2} \text{SQR}(a, b).$$

- $\arg \min$ devolve o par (a, b) que minimiza a SQR.
- Minimizar o EQM amostral, $\text{SQR}(a, b)/n$, produz os mesmos coeficientes.
- Elevar ao quadrado impede que resíduos positivos e negativos se cancelem e penaliza mais os resíduos grandes.
- Se todos os X_i forem iguais, o critério não produz uma inclinação única.

Condições de primeira ordem

Escreva $Q(a, b) = \sum_{i=1}^n (Y_i - a - bX_i)^2$. Pela regra da cadeia:

$$\frac{\partial Q(a, b)}{\partial a} = -2 \sum_{i=1}^n (Y_i - a - bX_i), \quad \frac{\partial Q(a, b)}{\partial b} = -2 \sum_{i=1}^n X_i (Y_i - a - bX_i).$$

No mínimo $(\hat{\alpha}, \hat{\beta})$, as duas derivadas se anulam. Obtemos as **equações normais**:

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}X_i) = 0,$$

$$\sum_{i=1}^n X_i (Y_i - \hat{\alpha} - \hat{\beta}X_i) = 0.$$

O termo entre parênteses é o resíduo $\hat{e}_i$. Logo, $\sum_i \hat{e}_i = 0$ e $\sum_i X_i \hat{e}_i = 0$.

Intuição

No ponto mínimo, um pequeno movimento isolado no intercepto ou na inclinação não reduz a SQR.

Equações normais

No ajuste com intercepto, as duas condições são:

$$\sum_i \hat{e}_i = 0, \quad \sum_i X_i \hat{e}_i = 0.$$

Discuta antes de continuar

- 1 Se os quatro resíduos fossem positivos, a primeira igualdade poderia valer?
- 2 No exemplo, X vai de 0 a 3. Qual ponto pesa mais na segunda soma: um resíduo em $X = 0$ ou o mesmo resíduo em $X = 3$?

Intercepto

Comece por $\sum_i \hat{e}_i = 0$:

$$\begin{aligned} 0 &= \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}X_i) \\ &= \sum_{i=1}^n Y_i - n\hat{\alpha} - \hat{\beta} \sum_{i=1}^n X_i. \end{aligned}$$

Divida por n e defina as médias amostrais $\bar{X} = n^{-1} \sum_i X_i$ e $\bar{Y} = n^{-1} \sum_i Y_i$:

$$\boxed{\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}.}$$

Substitua $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$ na segunda equação normal:

$$0 = \sum_i X_i \{Y_i - \bar{Y} - \hat{\beta}(X_i - \bar{X})\}.$$

Como $\sum_i (Y_i - \bar{Y}) = 0$ e $\sum_i (X_i - \bar{X}) = 0$, podemos escrever:

$$0 = \sum_i (X_i - \bar{X})(Y_i - \bar{Y}) - \hat{\beta} \sum_i (X_i - \bar{X})^2.$$

Fórmulas do MQO

Se $\sum_i (X_i - \bar{X})^2 > 0$:

$$\hat{\beta} = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}, \quad \hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}.$$

Intuição

O numerador mede como X e Y se movem juntos; o denominador mede quanto X varia. A razão converte covariação em mudança de Y por unidade de X .

MQO como estimador plug-in do BLP

Na população, o BLP da Aula 3 é:

$$\beta = \frac{\text{Cov}(X, Y)}{V(X)}, \quad \alpha = E[Y] - \beta E[X].$$

Na amostra, substituímos cada momento populacional pelo momento amostral correspondente:

$$E[X] \mapsto \bar{X}, \quad E[Y] \mapsto \bar{Y}, \quad \text{Cov}(X, Y) \mapsto \frac{1}{n} \sum_i (X_i - \bar{X})(Y_i - \bar{Y}), \quad V(X) \mapsto \frac{1}{n} \sum_i (X_i - \bar{X})^2.$$

Essa substituição produz exatamente os coeficientes do MQO.

Pergunta

A covariância e a variância plug-in têm ambas o fator $1/n$. Por que ele não aparece em $\hat{\beta}$?

População e amostra

BLP populacional

Objeto: distribuição conjunta de (X, Y) .

Critério: $E[(Y - a - bX)^2]$.

Coeficientes: α e β .

Desvio: $\varepsilon = Y - \alpha - \beta X$.

MQO amostral

Objeto: n pares observados.

Critério: $n^{-1} \sum_i (Y_i - a - bX_i)^2$.

Coeficientes: $\hat{\alpha}$ e $\hat{\beta}$.

Resíduo: $\hat{e}_i = Y_i - \hat{Y}_i$.

O chapéu marca uma quantidade calculada na amostra. Fonte: Aronow e Miller (2019, seção 4.1) e Hansen (2022, seções 3.3–3.4).

Exemplo: desvios e produtos

Tabela 1: Momentos para calcular a reta no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

Unidade	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	Produto	Quadrado de X
1	0	1	-1,5	-2	3,0	2,25
2	1	3	-0,5	0	0,0	0,25
3	2	2	0,5	-1	-0,5	0,25
4	3	6	1,5	3	4,5	2,25

$$\bar{X} = (0 + 1 + 2 + 3)/4 = 1,5 \text{ e } \bar{Y} = (1 + 3 + 2 + 6)/4 = 3,0.$$

Exemplo: coeficientes

Da Tabela 1:

$$\sum_i (X_i - \bar{X})(Y_i - \bar{Y}) = 3 + 0 - 0,5 + 4,5 = 7, \quad \sum_i (X_i - \bar{X})^2 = 2,25 + 0,25 + 0,25 + 2,25 = 5.$$

Portanto:

$$\hat{\beta} = \frac{7}{5} = 1,4, \quad \hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X} = 3,0 - (1,4)(1,5) = 0,9, \quad \boxed{\hat{Y}_i = 0,9 + 1,4X_i.}$$

Checagem

Quando $X = \bar{X} = 1,5$, a reta passa por $\hat{Y} = 0,9 + 1,4(1,5) = 3 = \bar{Y}$.

Exemplo: valores ajustados e resíduos

Tabela 2: Ajuste e resíduos da reta de MQO no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

Unidade	X_i	Y_i	$\widehat{Y}_i$	$\hat{e}_i$	$\hat{e}_i^2$
1	0	1	0,9	0,1	0,01
2	1	3	2,3	0,7	0,49
3	2	2	3,7	-1,7	2,89
4	3	6	5,1	0,9	0,81

$SQR = 0,01 + 0,49 + 2,89 + 0,81 = 4,20$ e $EQM = 4,20/4 = 1,05$.

Equações normais no exemplo:

$$\sum_i \hat{e}_i = 0,1 + 0,7 - 1,7 + 0,9 = 0, \quad \sum_i X_i \hat{e}_i = 0(0,1) + 1(0,7) + 2(-1,7) + 3(0,9) = 0.$$

Exemplo: MQO e uma reta alternativa




Figura 3: Comparação entre a reta de MQO e a reta alternativa $1 + X$. Unidade: observação; denominador: quatro observações em cada painel. Fonte: elaboração própria.

A reta alternativa parece plausível, mas sua SQR é 42,9% maior que a do MQO.

Interpretação da inclinação

Regra de interpretação

Quando X aumenta uma unidade, o valor ajustado $\hat{Y}$ muda $\hat{\beta}$ unidades de Y .

No exemplo:

$$\hat{\beta} = 1,4 \frac{\text{unidade de } Y}{\text{unidade de } X}.$$

Duas observações cujos valores de X diferem em uma unidade têm valores ajustados que diferem em 1,4 unidade de Y .

Interpretação do intercepto

$$\hat{\alpha} = \widehat{Y} \text{ quando } X = 0.$$

No exemplo, $X = 0$ está na amostra e $\hat{\alpha} = 0,9$ é uma leitura direta.

No AGNA, chame o ano bruto de $A_i = \text{ano}_i$. Usar A_i diretamente como preditor produziria:

$$\widehat{Y}_i = \hat{\alpha}_A + \hat{\beta}A_i,$$

e $\hat{\alpha}_A$ descreveria a reta no ano zero.

Problema

O ano zero está muito fora dos dados de 1997–2016; o intercepto seria matematicamente válido, mas substantivamente pouco útil.

Centralização

Escolha um ponto de referência c e defina:

$$X_i^c = X_i - c.$$

Como $X_i = X_i^c + c$:

$$\begin{aligned}\widehat{Y}_i &= \widehat{\alpha} + \widehat{\beta}(X_i^c + c) \\ &= (\widehat{\alpha} + \widehat{\beta}c) + \widehat{\beta}X_i^c.\end{aligned}$$

Consequência

A nova inclinação continua $\widehat{\beta}$; o novo intercepto é o valor ajustado no ponto original $X = c$.

Centralização no AGNA

Defina:

$$A_i = \text{ano}_i, \quad X_i = A_i - 1997.$$

Então:

- $X_i = 0$ representa 1997;
- $X_i = 1$ representa 1998;
- $X_i = 19$ representa 2016.

Vantagem

O intercepto passa a ser a convergência média anual ajustada para 1997, o início da janela observada.

Com A_i ou com X_i , a inclinação e os valores ajustados são os mesmos; muda apenas o intercepto.

Interpolação e extrapolação

Para qualquer X_i observado, $\widehat{Y}_i = \hat{\alpha} + \hat{\beta}X_i$ resume a associação linear naquele ponto.

Interpolação

Avaliar a reta entre valores de X cobertos pela amostra.

Extrapolação

Avaliar a reta fora do suporte observado de X . Uma reta estimada entre 1997 e 2016 pode ser calculada para 2050, mas os dados não mostram que a associação linear persiste até lá.

Mesmo dentro do suporte, o valor ajustado pode se afastar da CEF se a associação for não linear.

AGNA: taxa anual e reta de MQO




Figura 4: Convergência média anual e reta de MQO, 1997–2016. Unidade da regressão: ano (20 pontos); denominador de cada taxa: 61 a 112 resoluções válidas naquele ano, 1.762 no total. Eixo vertical: 0%–100%. Fonte: base didática AGNA do curso.

AGNA: coeficientes

Com $X = \text{ano} - 1997$, o ajuste nos 20 anos é:

$$\hat{Y} = 0,7672 + 0,0039X.$$

Intercepto

A convergência média anual ajustada para 1997 é 76,7%.

Inclinação

Cada ano adicional está associado a 0,39 ponto percentual adicional de convergência média anual, segundo a reta.

Cada ano recebe o mesmo peso porque a unidade da regressão é o ano.

De volta aos extremos

Dois anos isolados

Taxa observada em 1997: 79,3%.

Taxa observada em 2016: 69,6%.

Ligar apenas esses dois pontos produziria uma reta descendente.

Todos os anos

O MQO ajusta a reta aos 20 pontos anuais. Sua inclinação é positiva: +0,39 ponto percentual por ano.

O que explica a diferença?

Os 18 anos intermediários também entram nas somas de covariação e variação. Os dois extremos, sozinhos, não determinam a inclinação do MQO.

MQO no R

Em R, a chamada bivariada é:

```
modelo_mqo <- lm(  
  taxa_media_convergencia ~ anos_desde_1997,  
  data = dados_anuais  
)  
  
coef(modelo_mqo)  
fitted(modelo_mqo)  
residuals(modelo_mqo)
```

O que `lm()` devolve

Os coeficientes que minimizam a SQR, os valores ajustados e os resíduos.

Escopo desta aula

Não usaremos valores-p, testes, intervalos de confiança nem `summary(modelo_mqo)`.

- 1 **Antes da reta:** leia `dados_anuais` e `grafico_basico`. Confirme que há 20 anos e que cada taxa tem seu próprio denominador.
- 2 **A reta:** use `coeficientes_comparados` para confrontar os cálculos manuais e o resultado de `lm()`.
- 3 **Interpretação:** use `grafico_final` e `dados_com_ajuste` para relacionar pontos, valores ajustados e resíduos.

Pergunta comum aos três momentos

O que a saída descreve na amostra?

Exercício

No AGNA, A_i é o ano, $X_i = A_i - 1997$ mede anos desde 1997, e Y_i é a taxa de convergência em proporção. A reta arredondada é:

$$\widehat{Y} = 0,7672 + 0,0039X.$$

- 1 Qual é a taxa ajustada em 2000, quando $X = 3$?
- 2 Se, hipoteticamente, a taxa observada nesse ano fosse 0,80, qual seria o resíduo?
- 3 Quais são as unidades da inclinação e o que representa o intercepto?

- 1 O MQO aplica a regra populacional do BLP aos momentos amostrais e escolhe a reta que minimiza a SQR, ou o EQM.
- 2 A inclinação é covariação dividida pela variação de X ; a reta passa por $(\bar{X}, \bar{Y})$.
- 3 Centralizar X torna o intercepto interpretável sem mudar inclinação, ajustes ou resíduos.
- 4 Leia $\hat{\beta}$ nas unidades de X e Y e avalie a reta apenas dentro do suporte observado de X .

Referências

Leituras principais

Aronow, Peter M., e Benjamin T. Miller. *Foundations of Agnostic Statistics* (2019), seções 3.2.3, 3.3–3.3.1 e 4.1.

Hansen, Bruce E. *Econometrics* (2022), seções 3.3–3.8.

Fronteira

A Aula 5 termina na estimação e interpretação bivariada. Regressão múltipla começa na Aula 6; propriedades amostrais, diagnóstico e inferência entram apenas nas aulas posteriores previstas no syllabus.

Dados de aplicação: base didática AGNA do curso, votações da Assembleia Geral das Nações Unidas, 1997–2016.