

# Aula 5: mínimos quadrados ordinários

Regressão bivariada, estimação e interpretação

FLS 6183 - Métodos Quantitativos de Pesquisa II

23 de setembro de 2026

## Problema

Qual reta resume melhor a associação linear entre  $X$  e  $Y$  em uma amostra?

## Ponte com a Aula 3

O BLP minimiza o EQM na população. O MQO aplica o mesmo critério à amostra, e o princípio plug-in liga os dois.

- 1 Princípio plug-in
- 2 Derivação do MQO bivariado
- 3 Exemplo com quatro pares
- 4 Interpretação dos coeficientes
- 5 Aplicação: votos de Brasil e China na AGNU

## Objetivo

Derivar e calcular a reta de MQO e interpretar seus coeficientes nas unidades dos dados.

# Princípio plug-in

## Definição informal

Escreva a fórmula de uma quantidade da população. Aplique a mesma regra aos dados observados e use o resultado como estimador.

Para a média populacional de  $Y$ :

$$\mu = E[Y] \quad \longrightarrow \quad \hat{\mu} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Se observarmos os valores 1, 3, 2 e 6, a média amostral será  $\bar{Y} = (1 + 3 + 2 + 6)/4 = 3$ .

## Pergunta

Aplicar a fórmula à amostra garante que o estimador não tenha viés?

# Variância plug-in

Na população, denote a variância de  $Y$  por  $\sigma^2$ :

$$\sigma^2 = V(Y) = E[Y^2] - E[Y]^2.$$

Ao aplicar a mesma regra à amostra:

$$\widehat{V}_{\text{PI}} = \overline{Y^2} - \bar{Y}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad \overline{Y^2} = \frac{1}{n} \sum_{i=1}^n Y_i^2.$$

Para os quatro valores do slide anterior,  $\bar{Y} = 3$  e  $\widehat{V}_{\text{PI}} = (4 + 0 + 1 + 9)/4 = 3,5$ .

## Em amostras repetidas

Se as observações forem independentes e identicamente distribuídas, com variância finita,  $E[\widehat{V}_{\text{PI}}] = \frac{n-1}{n} \sigma^2$ : o viés é negativo.

# Viés e consistência

## Duas propriedades

**Viés em amostras finitas:**  $E[\widehat{V}_{\text{PI}}] \neq \sigma^2$  quando  $n$  é finito e  $\sigma^2 > 0$ . Com  $n = 4$ , a esperança é  $3\sigma^2/4$ .

**Consistência:** sob amostragem independente e identicamente distribuída e  $\sigma^2 < \infty$ ,  $\widehat{V}_{\text{PI}} \xrightarrow{p} \sigma^2$  quando  $n$  cresce. O símbolo  $\xrightarrow{p}$  significa convergência em probabilidade.

Por quê?  $\overline{Y^2} \xrightarrow{p} E[Y^2]$  e  $\bar{Y} \xrightarrow{p} E[Y]$ ; portanto,  $\overline{Y^2} - \bar{Y}^2 \xrightarrow{p} E[Y^2] - E[Y]^2$ .

A correção  $s^2 = \frac{n}{n-1} \widehat{V}_{\text{PI}} = \frac{1}{n-1} \sum_i (Y_i - \bar{Y})^2$  elimina o viés em amostras finitas.

# Quando o plug-in funciona

- 1 Os dados precisam aproximar a distribuição de interesse; o livro parte de amostragem independente e identicamente distribuída.
- 2 A quantidade calculada precisa estar definida: para a variância, por exemplo, é necessário que  $E[Y^2] < \infty$ .
- 3 A regra deve ser **estável**: uma pequena mudança na distribuição não pode provocar uma mudança desproporcional na quantidade de interesse.

## Condições de regularidade

Essas condições dependem da quantidade estimada. Para resultados mais fortes, como normalidade assintótica, Aronow e Miller exigem que a regra seja bem-comportada no entorno da distribuição populacional.

Sem amostragem adequada ou com uma regra instável, aplicar a fórmula à amostra não garante aproximação da quantidade populacional.

# Definição formal do plug-in

Seja  $\theta = T(F)$  uma característica da distribuição populacional  $F$ . Para observações  $X_1, \dots, X_n$  independentes e identicamente distribuídas,  $\widehat{F}$  é a função de distribuição empírica:

$$\widehat{F}(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}.$$

## Estimador plug-in

$$\widehat{\theta}_{\text{PI}} = T(\widehat{F}).$$

Aplicamos à distribuição empírica a mesma regra  $T$  usada para definir  $\theta$  na população.

Fonte: Aronow e Miller (2019, seções 3.2.3 e 3.3–3.3.1, pp. 105–107 e 116–120).

# EUA e China na AGNU, 2019




Figura 1: Índice de concordância de votos com EUA e China na sessão de 2019 da AGNU. Cada ponto é um país (191; exclui EUA e China). Fonte: Voeten, Strezhnev e Bailey, United Nations General Assembly Voting Data (jun. 2024).

# EUA e China na AGNU, 2019




Figura 2: Índice de concordância de votos com EUA e China na sessão de 2019 da AGNU. Cada ponto é um país (191; exclui EUA e China). Fonte: Voeten, Strezhnev e Bailey, United Nations General Assembly Voting Data (jun. 2024).

# EUA e Rússia na AGNU, 2018




Figura 3: Índice de concordância de votos com EUA e Rússia na sessão de 2018 da AGNU. Cada ponto é um país (191; exclui EUA e Rússia). Fonte: Voeten, Strezhnev e Bailey, United Nations General Assembly Voting Data (jun. 2024).

# EUA e Rússia na AGNU, 2018




Figura 4: Índice de concordância de votos com EUA e Rússia na sessão de 2018 da AGNU. Cada ponto é um país (191; exclui EUA e Rússia). Fonte: Voeten, Strezhnev e Bailey, United Nations General Assembly Voting Data (jun. 2024).

# Rússia e Brasil na AGNU, 2019




Figura 5: Índice de concordância de votos com Rússia e Brasil na sessão de 2019 da AGNU. Cada ponto é um país (191; exclui Rússia e Brasil). Fonte: Voeten, Strezhnev e Bailey, United Nations General Assembly Voting Data (jun. 2024).

# Rússia e Brasil na AGNU, 2019




Figura 6: Índice de concordância de votos com Rússia e Brasil na sessão de 2019 da AGNU. Cada ponto é um país (191; exclui Rússia e Brasil). Fonte: Voeten, Strezhnev e Bailey, United Nations General Assembly Voting Data (jun. 2024).

# Brasil e China na AGNU, 1997–2016




Figura 7: Convergência média anual dos votos de Brasil e China na AGNU, 1997–2016. Cada ponto é um ano; denominador: 61 a 112 resoluções válidas por ano. Fonte: votações nominais da AGNU (pacote unvotes), base didática do curso.

# Brasil e China na AGNU, 1997–2016




Figura 8: Convergência média anual dos votos de Brasil e China na AGNU, 1997–2016. Cada ponto é um ano; denominador: 61 a 112 resoluções válidas por ano. Fonte: votações nominais da AGNU (pacote unvotes), base didática do curso.

## Exemplo: quatro pares

São os mesmos quatro valores de  $Y$  usados no slide do princípio plug-in, agora acompanhados por um preditor  $X$ :

| $i$   | 1 | 2 | 3 | 4 |
|-------|---|---|---|---|
| $X_i$ | 0 | 1 | 2 | 3 |
| $Y_i$ | 1 | 3 | 2 | 6 |

### Perguntas

Você esperaria uma reta crescente ou decrescente? Uma reta precisa passar por todos os quatro pontos para resumir bem a associação?

# Valor ajustado e resíduo

A reta de regressão amostral associa a cada  $X_i$  observado um valor ajustado:

$$\widehat{Y}_i = \widehat{\alpha} + \widehat{\beta}X_i,$$

em que  $\widehat{\alpha}$  é o intercepto e  $\widehat{\beta}$  é a inclinação calculados na amostra. Sem chapéu,  $\alpha$  e  $\beta$  são os parâmetros populacionais do BLP. Cada observação se decompõe em

$$\underbrace{Y_i}_{\text{observado}} = \underbrace{\widehat{Y}_i}_{\text{ajustado}} + \underbrace{\widehat{e}_i}_{\text{resíduo}}, \quad \widehat{e}_i = Y_i - \widehat{Y}_i.$$

## Geometria

O resíduo é a distância vertical, com sinal, entre o ponto observado e a reta ajustada.

# Resíduos no exemplo




Figura 9: Resíduos em torno da reta de MQO no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

# Critério de mínimos quadrados

A soma dos quadrados dos resíduos de uma reta candidata, com intercepto  $\tilde{\alpha}$  e inclinação  $\tilde{\beta}$ , é:

$$\text{SQR}(\tilde{\alpha}, \tilde{\beta}) = \sum_{i=1}^n (Y_i - \tilde{\alpha} - \tilde{\beta}X_i)^2.$$

## Estimador de MQO

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{(\tilde{\alpha}, \tilde{\beta}) \in \mathbb{R}^2} \text{SQR}(\tilde{\alpha}, \tilde{\beta}).$$

O til marca valores candidatos; o chapéu, o par que minimiza a SQR.

- Minimizar o EQM amostral,  $\text{SQR}(\tilde{\alpha}, \tilde{\beta})/n$ , produz os mesmos coeficientes.
- Elevar ao quadrado impede que resíduos positivos e negativos se cancelem e penaliza mais os resíduos grandes.
- Se todos os  $X_i$  forem iguais, o critério não produz uma inclinação única.

# Condições de primeira ordem

Derive a SQR em relação a  $\tilde{\alpha}$  e a  $\tilde{\beta}$ . Pela regra da cadeia:

$$\frac{\partial \text{SQR}}{\partial \tilde{\alpha}} = -2 \sum_{i=1}^n (Y_i - \tilde{\alpha} - \tilde{\beta} X_i), \quad \frac{\partial \text{SQR}}{\partial \tilde{\beta}} = -2 \sum_{i=1}^n X_i (Y_i - \tilde{\alpha} - \tilde{\beta} X_i).$$

No mínimo  $(\hat{\alpha}, \hat{\beta})$ , as duas derivadas são iguais a zero. Obtemos as **equações normais**:

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} X_i) = 0,$$

$$\sum_{i=1}^n X_i (Y_i - \hat{\alpha} - \hat{\beta} X_i) = 0.$$

O termo entre parênteses é o resíduo  $\hat{e}_i$ . Logo,  $\sum_i \hat{e}_i = 0$  e  $\sum_i X_i \hat{e}_i = 0$ .

## Intuição

No ponto mínimo, um pequeno movimento isolado no intercepto ou na inclinação não reduz a SQR.

# Equações normais

São as duas condições de primeira ordem da minimização da SQR, uma para cada coeficiente:

$$\underbrace{\sum_i \hat{e}_i}_{\partial \text{SQR} / \partial \tilde{\alpha} = 0} = 0 \qquad \underbrace{\sum_i X_i \hat{e}_i}_{\partial \text{SQR} / \partial \tilde{\beta} = 0} = 0$$

## Por que “normais”

Em geometria, *normal* quer dizer perpendicular. Com os vetores  $\hat{\mathbf{e}} = (\hat{e}_1, \dots, \hat{e}_n)$ ,  $\mathbf{1}_n = (1, \dots, 1)$  e  $\mathbf{X} = (X_1, \dots, X_n)$ , as duas somas são produtos internos:  $\mathbf{1}_n \cdot \hat{\mathbf{e}} = 0$  e  $\mathbf{X} \cdot \hat{\mathbf{e}} = 0$ . O vetor de resíduos é perpendicular a  $\mathbf{1}_n$  e a  $\mathbf{X}$ .

# Equações normais: população e amostra

## População: BLP (Aula 3)

$(\alpha, \beta)$  é o par  $(\tilde{\alpha}, \tilde{\beta})$  que minimiza  $E[(Y - \tilde{\alpha} - \tilde{\beta}X)^2]$ . Com  $\varepsilon = Y - \alpha - \beta X$ , as condições de primeira ordem são:

$$E[\varepsilon] = 0, \quad E[X\varepsilon] = 0.$$

## Amostra: MQO

$(\hat{\alpha}, \hat{\beta})$  é o par  $(\tilde{\alpha}, \tilde{\beta})$  que minimiza  $n^{-1} \sum_i (Y_i - \tilde{\alpha} - \tilde{\beta}X_i)^2$ . Com  $\hat{e}_i = Y_i - \hat{\alpha} - \hat{\beta}X_i$ :

$$\frac{1}{n} \sum_{i=1}^n \hat{e}_i = 0, \quad \frac{1}{n} \sum_{i=1}^n X_i \hat{e}_i = 0.$$

As equações amostrais são as populacionais com a esperança trocada pela média amostral: o princípio plug-in aplicado às equações normais.

## Por construção

No BLP,  $E[\varepsilon] = 0$  e  $E[X\varepsilon] = 0$  valem pela própria definição de  $\alpha$  e  $\beta$ , desde que os segundos momentos sejam finitos e  $V(X) > 0$ .

# Intercepto

Comece por  $\sum_i \hat{e}_i = 0$ :

$$\begin{aligned} 0 &= \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}X_i) \\ &= \sum_{i=1}^n Y_i - n\hat{\alpha} - \hat{\beta} \sum_{i=1}^n X_i. \end{aligned}$$

Divida por  $n$  e defina as médias amostrais  $\bar{X} = n^{-1} \sum_i X_i$  e  $\bar{Y} = n^{-1} \sum_i Y_i$ :

$$\boxed{\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}.}$$

Substitua  $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$  na segunda equação normal:

$$0 = \sum_i X_i \{Y_i - \bar{Y} - \hat{\beta}(X_i - \bar{X})\}.$$

Como  $\sum_i (Y_i - \bar{Y}) = 0$  e  $\sum_i (X_i - \bar{X}) = 0$ , podemos escrever:

$$0 = \sum_i (X_i - \bar{X})(Y_i - \bar{Y}) - \hat{\beta} \sum_i (X_i - \bar{X})^2.$$

# Fórmulas do MQO

Se  $\sum_i (X_i - \bar{X})^2 > 0$ :

$$\hat{\beta} = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}, \quad \hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}.$$

## Intuição

O numerador mede como  $X$  e  $Y$  se movem juntos; o denominador mede quanto  $X$  varia. A razão converte covariação em mudança de  $Y$  por unidade de  $X$ .

# MQO como estimador plug-in do BLP

Na população, o BLP da Aula 3 é:

$$\beta = \frac{\text{Cov}(X, Y)}{V(X)}, \quad \alpha = E[Y] - \beta E[X].$$

Na amostra, substituímos cada momento populacional pelo momento amostral correspondente:

$$E[X] \mapsto \bar{X}, \quad E[Y] \mapsto \bar{Y}, \quad \text{Cov}(X, Y) \mapsto \frac{1}{n} \sum_i (X_i - \bar{X})(Y_i - \bar{Y}), \quad V(X) \mapsto \frac{1}{n} \sum_i (X_i - \bar{X})^2.$$

Essa substituição produz exatamente os coeficientes do MQO.

## Pergunta

A covariância e a variância plug-in têm ambas o fator  $1/n$ . Por que ele não aparece em  $\hat{\beta}$ ?

# População e amostra

## BLP populacional

Objeto: distribuição conjunta de  $(X, Y)$ .

Critério: minimizar  $E[(Y - \tilde{\alpha} - \tilde{\beta}X)^2]$ .

Coeficientes:  $\alpha$  e  $\beta$ .

Desvio:  $\varepsilon = Y - \alpha - \beta X$ .

## MQO amostral

Objeto:  $n$  pares observados.

Critério: minimizar  $n^{-1} \sum_i (Y_i - \tilde{\alpha} - \tilde{\beta}X_i)^2$ .

Coeficientes:  $\hat{\alpha}$  e  $\hat{\beta}$ .

Resíduo:  $\hat{e}_i = Y_i - \hat{Y}_i$ .

O chapéu marca uma quantidade calculada na amostra. Fonte: Aronow e Miller (2019, seção 4.1) e Hansen (2022, seções 3.3–3.4).

## Exemplo: desvios e produtos

Tabela 1: Momentos para calcular a reta no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

| Unidade | $X_i$ | $Y_i$ | $X_i - \bar{X}$ | $Y_i - \bar{Y}$ | Produto | Quadrado de $X$ |
|---------|-------|-------|-----------------|-----------------|---------|-----------------|
| 1       | 0     | 1     | -1,5            | -2              | 3,0     | 2,25            |
| 2       | 1     | 3     | -0,5            | 0               | 0,0     | 0,25            |
| 3       | 2     | 2     | 0,5             | -1              | -0,5    | 0,25            |
| 4       | 3     | 6     | 1,5             | 3               | 4,5     | 2,25            |

$$\bar{X} = (0 + 1 + 2 + 3)/4 = 1,5 \text{ e } \bar{Y} = (1 + 3 + 2 + 6)/4 = 3,0.$$

## Exemplo: coeficientes

Da Tabela 1:

$$\sum_i (X_i - \bar{X})(Y_i - \bar{Y}) = 3 + 0 - 0,5 + 4,5 = 7, \quad \sum_i (X_i - \bar{X})^2 = 2,25 + 0,25 + 0,25 + 2,25 = 5.$$

Portanto:

$$\hat{\beta} = \frac{7}{5} = 1,4, \quad \hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X} = 3,0 - (1,4)(1,5) = 0,9, \quad \boxed{\hat{Y}_i = 0,9 + 1,4X_i.}$$

### Checagem

Quando  $X = \bar{X} = 1,5$ , a reta passa por  $\hat{Y} = 0,9 + 1,4(1,5) = 3 = \bar{Y}$ .

## Exemplo: valores ajustados e resíduos

Tabela 2: Ajuste e resíduos da reta de MQO no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

| Unidade | $X_i$ | $Y_i$ | $\widehat{Y}_i$ | $\hat{e}_i$ | $\hat{e}_i^2$ |
|---------|-------|-------|-----------------|-------------|---------------|
| 1       | 0     | 1     | 0,9             | 0,1         | 0,01          |
| 2       | 1     | 3     | 2,3             | 0,7         | 0,49          |
| 3       | 2     | 2     | 3,7             | -1,7        | 2,89          |
| 4       | 3     | 6     | 5,1             | 0,9         | 0,81          |

$SQR = 0,01 + 0,49 + 2,89 + 0,81 = 4,20$  e  $EQM = 4,20/4 = 1,05$ .

Equações normais no exemplo:

$$\sum_i \hat{e}_i = 0,1 + 0,7 - 1,7 + 0,9 = 0, \quad \sum_i X_i \hat{e}_i = 0(0,1) + 1(0,7) + 2(-1,7) + 3(0,9) = 0.$$

## Exemplo: MQO e uma reta alternativa




Figura 10: Comparação entre a reta de MQO e a reta alternativa  $1 + X$ . Unidade: observação; denominador: quatro observações em cada painel. Fonte: elaboração própria.

A reta alternativa parece plausível, mas sua SQR é 42,9% maior que a do MQO.

# Interpretação da inclinação

## Regra de interpretação

Quando  $X$  aumenta uma unidade, o valor ajustado  $\hat{Y}$  muda  $\hat{\beta}$  unidades de  $Y$ .

No exemplo:

$$\hat{\beta} = 1,4 \frac{\text{unidade de } Y}{\text{unidade de } X}.$$

Duas observações cujos valores de  $X$  diferem em uma unidade têm valores ajustados que diferem em 1,4 unidade de  $Y$ .

# Interpretação do intercepto

$$\hat{\alpha} = \widehat{Y} \text{ quando } X = 0.$$

No exemplo,  $X = 0$  está na amostra e  $\hat{\alpha} = 0,9$  é uma leitura direta.

Na série Brasil-China, chame o ano bruto de  $A_i = \text{ano}_i$ . Usar  $A_i$  diretamente como preditor produziria:

$$\widehat{Y}_i = \hat{\alpha}_A + \hat{\beta}A_i,$$

e  $\hat{\alpha}_A$  descreveria a reta no ano zero.

## Problema

O ano zero está muito fora dos dados de 1997–2016; o intercepto seria matematicamente válido, mas substantivamente pouco útil.

# Centralização

Escolha um ponto de referência  $c$  e defina:

$$X_i^c = X_i - c.$$

Como  $X_i = X_i^c + c$ :

$$\begin{aligned}\widehat{Y}_i &= \widehat{\alpha} + \widehat{\beta}(X_i^c + c) \\ &= (\widehat{\alpha} + \widehat{\beta}c) + \widehat{\beta}X_i^c.\end{aligned}$$

## Consequência

A nova inclinação continua  $\widehat{\beta}$ ; o novo intercepto é o valor ajustado no ponto original  $X = c$ .

# Centralização em 1997

Defina:

$$A_i = \text{ano}_i, \quad X_i = A_i - 1997.$$

Então:

- $X_i = 0$  representa 1997;
- $X_i = 1$  representa 1998;
- $X_i = 19$  representa 2016.

## Vantagem

O intercepto passa a ser a convergência média anual ajustada para 1997, o início da janela observada.

Com  $A_i$  ou com  $X_i$ , a inclinação e os valores ajustados são os mesmos; muda apenas o intercepto.

# Interpolação e extrapolação

Para qualquer  $X_i$  observado,  $\widehat{Y}_i = \hat{\alpha} + \hat{\beta}X_i$  resume a associação linear naquele ponto.

## Interpolação

Avaliar a reta entre valores de  $X$  cobertos pela amostra.

## Extrapolação

Avaliar a reta fora do suporte observado de  $X$ . Uma reta estimada entre 1997 e 2016 pode ser calculada para 2050, mas os dados não mostram que a associação linear persiste até lá.

Mesmo dentro do suporte, o valor ajustado pode se afastar da CEF se a associação for não linear.

# Brasil e China: reta de MQO




Figura 11: Convergência média anual e reta de MQO, 1997–2016. Unidade da regressão: ano (20 pontos); denominador de cada taxa: 61 a 112 resoluções válidas naquele ano, 1.762 no total. Eixo vertical: 65%–90%. Fonte: votações nominais da AGNU (pacote unvotes), base didática do curso.

# Brasil e China: coeficientes

Com  $X = \text{ano} - 1997$ , o ajuste nos 20 anos é:

$$\hat{Y} = 0,7672 + 0,0039X.$$

## Intercepto

A convergência média anual ajustada para 1997 é 76,7%.

## Inclinação

Cada ano adicional está associado a 0,39 ponto percentual adicional de convergência média anual, segundo a reta.

Cada ano recebe o mesmo peso porque a unidade da regressão é o ano.

# Extremos e reta de MQO

## Dois anos isolados

Taxa observada em 1997: 79,3%.

Taxa observada em 2016: 69,6%.

Ligar apenas esses dois pontos produziria uma reta descendente.

## Todos os anos

O MQO ajusta a reta aos 20 pontos anuais. Sua inclinação é positiva: +0,39 ponto percentual por ano.

## Anos intermediários

Os 18 anos intermediários também entram nas somas de covariação e variação. Os dois extremos, sozinhos, não determinam a inclinação do MQO.

# MQO no R

Em R, a chamada bivariada é:

```
modelo_mqo <- lm(  
  taxa_media_convergencia ~ anos_desde_1997,  
  data = dados_anuais  
)  
  
coef(modelo_mqo)  
fitted(modelo_mqo)  
residuals(modelo_mqo)
```

## O que `lm()` devolve

Os coeficientes que minimizam a SQR, os valores ajustados e os resíduos.

## Escopo desta aula

Não usaremos valores-p, testes, intervalos de confiança nem `summary(modelo_mqo)`.

- 1 **Antes da reta:** leia `dados_anuais` e `grafico_basico`. Confirme que há 20 anos e que cada taxa tem seu próprio denominador.
- 2 **A reta:** use `coeficientes_comparados` para confrontar os cálculos manuais e o resultado de `lm()`.
- 3 **Interpretação:** use `grafico_final` e `dados_com_ajuste` para relacionar pontos, valores ajustados e resíduos.
- 4 **Correlação e padronização:** use `grafico_relacoes` e `comparacao_relacoes` para retomar os gráficos da lousa e verificar que, com  $X$  e  $Y$  padronizados, a inclinação é a correlação.

## Pergunta para os quatro momentos

O que a saída descreve na amostra?

# Exercício

Na série Brasil–China,  $A_i$  é o ano,  $X_i = A_i - 1997$  mede anos desde 1997, e  $Y_i$  é a taxa de convergência em proporção. A reta arredondada é:

$$\widehat{Y} = 0,7672 + 0,0039X.$$

- 1 Qual é a taxa ajustada em 2000, quando  $X = 3$ ?
- 2 Se, hipoteticamente, a taxa observada nesse ano fosse 0,80, qual seria o resíduo?
- 3 Quais são as unidades da inclinação e o que representa o intercepto?

- 1 O MQO aplica a regra populacional do BLP aos momentos amostrais e escolhe a reta que minimiza a SQR, ou o EQM.
- 2 A inclinação é covariação dividida pela variação de  $X$ ; a reta passa por  $(\bar{X}, \bar{Y})$ .
- 3 Centralizar  $X$  torna o intercepto interpretável sem mudar inclinação, ajustes ou resíduos.
- 4 Leia  $\hat{\beta}$  nas unidades de  $X$  e  $Y$  e avalie a reta apenas dentro do suporte observado de  $X$ .

# Referências

## Leituras principais

Aronow, Peter M., e Benjamin T. Miller. *Foundations of Agnostic Statistics* (2019), seções 3.2.3, 3.3–3.3.1 e 4.1.

Hansen, Bruce E. *Econometrics* (2022), seções 3.3–3.8.

## Fronteira

A Aula 5 termina na estimação e interpretação bivariada. Regressão múltipla começa na Aula 6; propriedades amostrais, diagnóstico e inferência entram apenas nas aulas posteriores previstas no syllabus.

Dados de aplicação: votações nominais da Assembleia Geral das Nações Unidas (pacote unvotes), 1997–2016; pontos ideais e índices de concordância de Voeten, Strezhnev e Bailey (jun. 2024).