

Aula 5: mínimos quadrados ordinários

Regressão bivariada, estimação e interpretação

FLS 6183 - Métodos Quantitativos de Pesquisa II

23 de setembro de 2026

Plug-in

Princípio plug-in, em palavras

Escreva a fórmula de uma quantidade da população. Aplique a mesma regra aos dados observados e use o resultado como estimador.

Para a média populacional de Y :

$$\mu = E[Y] \quad \longrightarrow \quad \hat{\mu} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Se observarmos os valores 1, 3, 2 e 6, a média amostral será $\bar{Y} = (1 + 3 + 2 + 6)/4 = 3$.

Pergunta

Aplicar a fórmula à amostra garante que o estimador não tenha viés?

A variância plug-in é viesada em amostras finitas

Na população, denote a variância de Y por σ^2 :

$$\sigma^2 = V(Y) = E[Y^2] - E[Y]^2.$$

Ao aplicar a mesma regra à amostra:

$$\widehat{V}_{\text{PI}} = \overline{Y^2} - \bar{Y}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad \overline{Y^2} = \frac{1}{n} \sum_{i=1}^n Y_i^2.$$

Para os quatro valores do slide anterior, $\bar{Y} = 3$ e $\widehat{V}_{\text{PI}} = (4 + 0 + 1 + 9)/4 = 3,5$.

Em amostras repetidas

Se as observações forem independentes e identicamente distribuídas, com variância finita, $E[\widehat{V}_{\text{PI}}] = \frac{n-1}{n}\sigma^2$: o viés é negativo.

Um estimador viesado ainda pode ser consistente

Duas perguntas diferentes

Viés em amostras finitas: $E[\widehat{V}_{\text{PI}}] \neq \sigma^2$ quando n é finito e $\sigma^2 > 0$. Com $n = 4$, a esperança é $3\sigma^2/4$.

Consistência: sob amostragem independente e identicamente distribuída e $\sigma^2 < \infty$, $\widehat{V}_{\text{PI}} \xrightarrow{p} \sigma^2$ quando n cresce. O símbolo $\xrightarrow{p}$ significa convergência em probabilidade.

Por quê? $\overline{Y^2} \xrightarrow{p} E[Y^2]$ e $\bar{Y} \xrightarrow{p} E[Y]$; portanto, $\overline{Y^2} - \bar{Y}^2 \xrightarrow{p} E[Y^2] - E[Y]^2$.

A correção $s^2 = \frac{n}{n-1} \widehat{V}_{\text{PI}} = \frac{1}{n-1} \sum_i (Y_i - \bar{Y})^2$ elimina o viés em amostras finitas.

Quando o princípio plug-in oferece boas estimativas?

- 1 Os dados precisam aproximar a distribuição de interesse; o livro parte de amostragem independente e identicamente distribuída.
- 2 A quantidade calculada precisa estar definida: para a variância, por exemplo, é necessário que $E[Y^2] < \infty$.
- 3 A regra deve ser **estável**: uma pequena mudança na distribuição não pode provocar uma mudança desproporcional na quantidade de interesse.

Condições de regularidade

Essas condições dependem da quantidade estimada. Para resultados mais fortes, como normalidade assintótica, Aronow e Miller exigem que a regra seja bem-comportada no entorno da distribuição populacional.

Sem amostragem adequada ou com uma regra instável, aplicar a fórmula à amostra não garante aproximação da quantidade populacional.

Definição formal do princípio plug-in

Seja $\theta = T(F)$ uma característica da distribuição populacional F . Para observações $X_1, \dots, X_n$ independentes e identicamente distribuídas, $\widehat{F}$ é a função de distribuição empírica:

$$\widehat{F}(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}.$$

Estimador plug-in

$$\widehat{\theta}_{\text{PI}} = T(\widehat{F}).$$

Aplicamos à distribuição empírica a mesma regra T usada para definir θ na população.

Fonte: Aronow e Miller (2019, seções 3.2.3 e 3.3–3.3.1, pp. 105–107 e 116–120).

Que reta resumiria estes 20 anos?




Figura 1: Convergência média dos votos de Brasil e China na Assembleia Geral das Nações Unidas (AGNU), 1997–2016. Cada ponto representa um ano; denominador de cada taxa: 61 a 112 resoluções válidas naquele ano. Fonte: base didática AGNA do curso.

Em 1997, a taxa observada foi 79,3%; em 2016, 69,6%. O que aconteceria se uma reta usasse **todos** os pontos, e não apenas os extremos?

Mapa conceitual: do BLP ao MQO amostral

Problema

Qual reta resume melhor a associação linear observada entre X e Y ?

Ponte com a Aula 3

O BLP minimiza o EQM na população; o MQO aplica o mesmo critério à amostra.

Dois problemas

Estimar uma reta não identifica, por si só, um efeito causal.

Ao final

Você saberá calcular a reta, interpretar seus coeficientes e delimitar o que ela não responde.

O projeto AGNA fornece uma pergunta bivariada

Pergunta substantiva

Qual é a associação linear entre o ano da votação e a convergência média anual dos votos de Brasil e China na AGNU?

- Unidade de análise da regressão: **ano**, após agregar as resoluções.
- Variável resposta Y_i : taxa de convergência no ano i .
- Preditor X_i : anos decorridos desde 1997 no ano i .
- Amostra: $n = 20$ anos, de 1997 a 2016, construídos com 1.762 resoluções válidas.

Leitura permitida

A inclinação descreverá associação temporal média, não efeito do tempo, de 2009, do comércio ou da China.

Estimação e identificação respondem a perguntas diferentes

Estimação por MQO

Qual reta minimiza os erros quadráticos nesta amostra?

Resultado: números $\hat{\alpha}$ e $\hat{\beta}$ calculados a partir dos dados.

Identificação causal

Que contraste observado corresponde a um contraste entre resultados potenciais?

Resultado: um argumento sobre desenho, atribuição e confundimento.

Uma solução algébrica para o primeiro problema não resolve o segundo.

Três elementos vêm antes da reta

Unidade de análise

O objeto ao qual cada linha da amostra se refere; o índice $i \in \{1, \dots, n\}$ identifica a unidade.

Variável resposta Y_i

O resultado que desejamos descrever ou ajustar para a unidade i .

Preditor X_i

A informação usada para construir a reta associacional para a unidade i .

No exemplo didático, a unidade é uma observação, X_i varia de 0 a 3 e Y_i varia de 1 a 6. No AGNA, cada unidade será um ano.

Quatro pares para acompanhar a construção da reta

São os mesmos quatro valores de Y usados na recapitulação do plug-in, agora acompanhados por um preditor X :

i	1	2	3	4
X_i	0	1	2	3
Y_i	1	3	2	6

Antes de calcular

Você esperaria uma reta crescente ou decrescente? Uma reta precisa passar por todos os quatro pontos para resumir bem a associação?

Uma reta atribui um valor ajustado a cada X_i

Definição em palavras

A reta de regressão amostral é uma regra linear que associa a cada valor observado de X um valor ajustado de Y .

Formalmente:

$$\widehat{Y}_i = \hat{\alpha} + \hat{\beta}X_i,$$

onde:

- $\widehat{Y}_i$ é o valor ajustado para a unidade i ;
- $\hat{\alpha}$ é o intercepto estimado;
- $\hat{\beta}$ é a inclinação estimada.

Limite

Uma reta resume apenas o componente linear da associação observada.

Valor observado, valor ajustado e resíduo não são sinônimos

Para cada unidade i :

$$\underbrace{Y_i}_{\text{observado}} = \underbrace{\widehat{Y}_i}_{\text{ajustado}} + \underbrace{\widehat{e}_i}_{\text{resíduo}}, \quad \widehat{e}_i = Y_i - \widehat{Y}_i.$$

Intuição geométrica

O resíduo é a distância vertical, com sinal, entre o ponto observado e a reta ajustada.

Erro comum

O resíduo $\widehat{e}_i$ é calculado depois de ajustar a reta à amostra; não é o mesmo objeto que um erro populacional não observado.

Os resíduos são distâncias verticais até a reta




Figura 2: Resíduos em torno da reta de MQO no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

O critério precisa resumir todos os resíduos

A soma dos quadrados dos resíduos é:

$$\text{SQR}(a, b) = \sum_{i=1}^n (Y_i - a - bX_i)^2.$$

O erro quadrático médio amostral é:

$$\text{EQM}(a, b) = \frac{1}{n} \sum_{i=1}^n (Y_i - a - bX_i)^2.$$

Mesma reta minimizadora

Como n é uma constante positiva, minimizar SQR ou EQM produz os mesmos coeficientes.

Por que elevar os resíduos ao quadrado?

- 1 Resíduos positivos e negativos não se cancelam.
- 2 Erros verticais maiores recebem penalidade maior.
- 3 A função objetivo é quadrática e, quando X varia, tem mínimo único.

Exemplo

Resíduos -2 e $+2$ somam zero, mas representam erro: seus quadrados somam $4 + 4 = 8$.

Limite

O quadrado é uma escolha de perda; ele torna observações com resíduos grandes especialmente influentes no critério.

O estimador escolhe a reta com menor erro quadrático

Definição formal

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{(a,b) \in \mathbb{R}^2} \sum_{i=1}^n (Y_i - a - bX_i)^2.$$

Onde:

- a e b são coeficientes candidatos;
- $\mathbb{R}^2$ é o conjunto de todos os pares reais (a, b) ;
- $\arg \min$ devolve o par que minimiza a SQR;
- $\hat{\alpha}$ e $\hat{\beta}$ são os valores escolhidos pelo MQO.

Se todos os X_i forem iguais, o critério não produzirá uma inclinação única.

A derivação começa pela função objetivo

Defina:

$$Q(a, b) = \sum_{i=1}^n (Y_i - a - bX_i)^2.$$

Para encontrar um mínimo interior, calculamos uma condição de primeira ordem para cada coeficiente:

$$\frac{\partial Q(a, b)}{\partial a} = 0, \quad \frac{\partial Q(a, b)}{\partial b} = 0.$$

Intuição

No ponto mínimo, um pequeno movimento isolado no intercepto ou na inclinação não reduz a SQR.

Intercepto: os resíduos somam zero

Pela regra da cadeia:

$$\begin{aligned}\frac{\partial Q(a, b)}{\partial a} &= \sum_{i=1}^n 2(Y_i - a - bX_i)(-1) \\ &= -2 \sum_{i=1}^n (Y_i - a - bX_i).\end{aligned}$$

Na solução $(\hat{\alpha}, \hat{\beta})$:

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}X_i) = 0.$$

O termo entre parênteses é o resíduo $\hat{e}_i$.

Inclinação: o produto com X soma zero

Também pela regra da cadeia:

$$\begin{aligned}\frac{\partial Q(a, b)}{\partial b} &= \sum_{i=1}^n 2(Y_i - a - bX_i)(-X_i) \\ &= -2 \sum_{i=1}^n X_i(Y_i - a - bX_i).\end{aligned}$$

Na solução:

$$\sum_{i=1}^n X_i(Y_i - \hat{\alpha} - \hat{\beta}X_i) = 0.$$

Logo, $\sum_i X_i \hat{e}_i = 0$.

Pausa: o que dizem as duas condições?

No ajuste com intercepto, as duas condições são:

$$\sum_i \hat{e}_i = 0, \quad \sum_i X_i \hat{e}_i = 0.$$

Discuta antes de continuar

- 1 Se os quatro resíduos fossem positivos, a primeira igualdade poderia valer?
- 2 No exemplo, X vai de 0 a 3. Qual ponto pesa mais na segunda soma: um resíduo em $X = 0$ ou o mesmo resíduo em $X = 3$?

A equação normal determina o intercepto

Comece por $\sum_i \hat{e}_i = 0$:

$$\begin{aligned} 0 &= \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}X_i) \\ &= \sum_{i=1}^n Y_i - n\hat{\alpha} - \hat{\beta} \sum_{i=1}^n X_i. \end{aligned}$$

Divida por n e defina as médias amostrais $\bar{X} = n^{-1} \sum_i X_i$ e $\bar{Y} = n^{-1} \sum_i Y_i$:

$$\boxed{\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}.}$$

Centralizar revela a fórmula da inclinação

Substitua $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$ na segunda equação normal:

$$0 = \sum_i X_i \{Y_i - \bar{Y} - \hat{\beta}(X_i - \bar{X})\}.$$

Como $\sum_i (Y_i - \bar{Y}) = 0$ e $\sum_i (X_i - \bar{X}) = 0$, podemos escrever:

$$0 = \sum_i (X_i - \bar{X})(Y_i - \bar{Y}) - \hat{\beta} \sum_i (X_i - \bar{X})^2.$$

Inclinação = covariação / variação de X

Se $\sum_i (X_i - \bar{X})^2 > 0$:

$$\hat{\beta} = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}, \quad \hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}.$$

Intuição

O numerador mede como X e Y se movem juntos; o denominador mede quanto X varia. A razão converte covariação em mudança de Y por unidade de X .

Limite

Sem variação em X , o denominador é zero e não há inclinação única.

Pausa: leia a fórmula antes das contas

Volte aos quatro pares (X_i, Y_i) do início da aula.

- 1 Você espera uma inclinação positiva ou negativa? Confira o sinal do numerador antes de dividir.
- 2 A covariância e a variância plug-in têm ambas um fator $1/n$. Por que esse fator não aparece na fórmula de $\hat{\beta}$?

Pista

O denominador é uma soma de quadrados, portanto é positivo quando X varia.

O MQO é o análogo amostral do BLP

Na população, o BLP da Aula 3 é:

$$\beta = \frac{\text{Cov}(X, Y)}{V(X)}, \quad \alpha = E[Y] - \beta E[X].$$

Na amostra, substituímos momentos populacionais por momentos amostrais:

$$E[X] \mapsto \bar{X}, \quad E[Y] \mapsto \bar{Y}, \quad \text{Cov}(X, Y) \mapsto \frac{1}{n} \sum_i (X_i - \bar{X})(Y_i - \bar{Y}).$$

Retomada do princípio plug-in

Aplicar o princípio à fórmula populacional do BLP produz os coeficientes do MQO amostral. No projeto AGNA, a reta resume a associação linear entre os 20 anos observados.

População e amostra não devem ser confundidas

BLP populacional

Objeto: distribuição conjunta de (X, Y) .

Critério: $E[(Y - a - bX)^2]$.

Coeficientes: α e β .

Desvio: $\varepsilon = Y - \alpha - \beta X$.

MQO amostral

Objeto: n pares observados.

Critério: $n^{-1} \sum_i (Y_i - a - bX_i)^2$.

Coeficientes: $\hat{\alpha}$ e $\hat{\beta}$.

Resíduo: $\hat{e}_i = Y_i - \hat{Y}_i$.

O chapéu marca uma quantidade calculada na amostra. Fonte: Aronow e Miller (2019, seção 4.1) e Hansen (2022, seções 3.3–3.4).

Exemplo completo: quatro pares observados

Tabela 1: Momentos para calcular a reta no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

Unidade	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	Produto	Quadrado de X
1	0	1	-1,5	-2	3,0	2,25
2	1	3	-0,5	0	0,0	0,25
3	2	2	0,5	-1	-0,5	0,25
4	3	6	1,5	3	4,5	2,25

$$\bar{X} = (0 + 1 + 2 + 3)/4 = 1,5 \text{ e } \bar{Y} = (1 + 3 + 2 + 6)/4 = 3,0.$$

Exemplo: calcular a inclinação

Da Tabela 1:

$$\sum_i (X_i - \bar{X})(Y_i - \bar{Y}) = 3 + 0 - 0,5 + 4,5 = 7.$$

$$\sum_i (X_i - \bar{X})^2 = 2,25 + 0,25 + 0,25 + 2,25 = 5.$$

Portanto:

$$\hat{\beta} = \frac{7}{5} = 1,4.$$

Uma unidade adicional de X está associada, na reta, a 1,4 unidade adicional de Y .

Exemplo: calcular o intercepto e escrever a reta

Use $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$:

$$\begin{aligned}\hat{\alpha} &= 3,0 - (1,4)(1,5) \\ &= 3,0 - 2,1 = 0,9.\end{aligned}$$

A reta estimada é:

$$\widehat{Y}_i = 0,9 + 1,4X_i.$$

Checagem

Quando $X = \bar{X} = 1,5$, a reta passa por $\widehat{Y} = 0,9 + 1,4(1,5) = 3 = \bar{Y}$.

Exemplo: ajustes, resíduos e SQR

Tabela 2: Ajuste e resíduos da reta de MQO no exemplo didático. Unidade: observação; denominador: quatro observações. Fonte: elaboração própria.

Unidade	X_i	Y_i	$\widehat{Y}_i$	$\hat{e}_i$	$\hat{e}_i^2$
1	0	1	0,9	0,1	0,01
2	1	3	2,3	0,7	0,49
3	2	2	3,7	-1,7	2,89
4	3	6	5,1	0,9	0,81

$$\text{SQR} = 0,01 + 0,49 + 2,89 + 0,81 = 4,20 \text{ e } \text{EQM} = 4,20/4 = 1,05.$$

As equações normais aparecem nas contas do exemplo

Com intercepto, o MQO garante mecanicamente:

$$\sum_i \hat{e}_i = 0, \quad \sum_i X_i \hat{e}_i = 0.$$

No exemplo:

$$0,1 + 0,7 - 1,7 + 0,9 = 0,$$

$$0(0,1) + 1(0,7) + 2(-1,7) + 3(0,9) = 0.$$

Cuidado

Essas igualdades são propriedades algébricas do ajuste na própria amostra; não demonstram causalidade nem qualidade fora da amostra.

Outra reta produz erro quadrático maior

Considere a reta candidata $\widetilde{Y}_i = 1 + X_i$.

Seus valores ajustados são $(1, 2, 3, 4)$ e os resíduos são $(0, 1, -1, 2)$.

$$\text{SQR}_{\text{alternativa}} = 0^2 + 1^2 + (-1)^2 + 2^2 = 6.$$

Para o MQO:

$$\text{SQR}_{\text{MQO}} = 4,20 < 6.$$

Leitura

A reta alternativa parece plausível, mas a soma de suas distâncias verticais ao quadrado é 42,9% maior.

O gráfico permite comparar as duas somas de quadrados




Figura 3: Comparação entre a reta de MQO e uma reta alternativa. Unidade: observação; denominador: quatro observações em cada painel. Fonte: elaboração própria.

A inclinação deve ser lida nas unidades originais

Regra de interpretação

Quando X aumenta uma unidade, o valor ajustado de Y muda $\hat{\beta}$ unidades, em média segundo a reta amostral.

No exemplo:

$$\hat{\beta} = 1,4 \frac{\text{unidade de } Y}{\text{unidade de } X}.$$

Erro comum

Uma inclinação positiva descreve associação linear positiva. Ela não diz que aumentar X causaria aumento de Y .

O intercepto só é substantivo quando $X = 0$ faz sentido

$$\hat{\alpha} = \hat{Y} \text{ quando } X = 0.$$

No exemplo, $X = 0$ está na amostra e $\hat{\alpha} = 0,9$ é uma leitura direta.

No AGNA, chame o ano bruto de $A_i = \text{ano}_i$. Usar A_i diretamente como preditor produziria:

$$\hat{Y}_i = \hat{\alpha}_A + \hat{\beta}A_i,$$

e $\hat{\alpha}_A$ descreveria a reta no ano zero.

Problema

O ano zero está muito fora dos dados de 1997–2016; o intercepto seria matematicamente válido, mas substantivamente pouco útil.

Centralizar muda o intercepto, não a inclinação

Escolha um ponto de referência c e defina:

$$X_i^c = X_i - c.$$

Como $X_i = X_i^c + c$:

$$\begin{aligned}\widehat{Y}_i &= \widehat{\alpha} + \widehat{\beta}(X_i^c + c) \\ &= (\widehat{\alpha} + \widehat{\beta}c) + \widehat{\beta}X_i^c.\end{aligned}$$

Consequência

A nova inclinação continua $\widehat{\beta}$; o novo intercepto é o valor ajustado no ponto original $X = c$.

Exemplo de centralização: tornar $X = 2$ a referência

A reta original é:

$$\widehat{Y} = 0,9 + 1,4X.$$

Defina $X^c = X - 2$, portanto $X = X^c + 2$:

$$\begin{aligned}\widehat{Y} &= 0,9 + 1,4(X^c + 2) \\ &= 3,7 + 1,4X^c.\end{aligned}$$

Leitura

O novo intercepto, 3,7, é o valor ajustado quando o X original vale 2. A reta e todos os valores ajustados permanecem idênticos.

No AGNA, 1997 é uma referência substantiva

Defina:

$$A_i = \text{ano}_i, \quad X_i = A_i - 1997.$$

Então:

- $X_i = 0$ representa 1997;
- $X_i = 1$ representa 1998;
- $X_i = 19$ representa 2016.

Vantagem

O intercepto passa a ser a convergência média anual ajustada para 1997, o início da janela observada.

O número de anos transcorridos muda a origem da escala, não a informação nem a inclinação.

Pausa: por que recentralizar não muda a reta?

No AGNA, substitua $X_i = A_i - 1997$ por:

$$X_i^{2009} = A_i - 2009.$$

Discuta:

- 1 Por que a inclinação permanece igual?
- 2 Por que o intercepto muda?
- 3 O que o novo intercepto representa?
- 4 Por que nenhuma parametrização identifica um efeito causal de 2009?

Dica

A centralização apenas muda o ponto em que o preditor vale zero; ela não muda pontos, resíduos, SQR ou valores ajustados.

Valores ajustados descrevem a reta dentro da amostra

Para qualquer X_i observado:

$$\widehat{Y}_i = \hat{\alpha} + \hat{\beta}X_i.$$

Uso descritivo

Comparar $\widehat{Y}_i$ entre valores de X resume a direção e a magnitude da associação linear observada.

Dois limites

O valor ajustado pode não coincidir com a CEF se a associação for não linear; e não é automaticamente uma previsão válida para uma nova amostra.

Extrapolar exige informação que os dados não fornecem

Interpolação

Avaliar a reta entre valores de X cobertos pela amostra.

Extrapolação

Avaliar a reta fora do suporte observado de X .

Uma reta estimada entre 1997 e 2016 pode ser calculada para 2050, mas os dados não mostram que a associação linear persiste até lá.

Pergunta de verificação

O valor de X que estou interpretando aparece nos dados ou depende de uma extensão não testada da reta?

A associação anual no AGNA é pequena e positiva




Figura 4: Convergência média anual e reta de MQO, 1997–2016. Unidade da regressão: ano (20 pontos); denominador de cada taxa: 61 a 112 resoluções válidas naquele ano, 1.762 no total. Eixo vertical: 0%–100%. Fonte: base didática AGNA do curso.

Os coeficientes do AGNA têm leitura associacional

Com $X = \text{ano} - 1997$, o ajuste nos 20 anos é:

$$\hat{Y} = 0,7672 + 0,0039X.$$

Intercepto

A convergência média anual ajustada para 1997 é 76,7%.

Inclinação

Cada ano adicional está associado a 0,39 ponto percentual adicional de convergência média anual, segundo a reta.

Cada ano recebe o mesmo peso porque a unidade da regressão é o ano.

Volte aos extremos: a reta usa os vinte pontos

Dois anos isolados

Taxa observada em 1997: 79,3%.

Taxa observada em 2016: 69,6%.

Ligar apenas esses dois pontos produziria uma reta descendente.

Todos os anos

O MQO ajusta a reta aos 20 pontos anuais. Sua inclinação é positiva: +0,39 ponto percentual por ano.

O que explica a diferença?

Os 18 anos intermediários também entram nas somas de covariação e variação. Os dois extremos, sozinhos, não determinam a inclinação do MQO.

A inclinação positiva não identifica efeito causal

O ajuste mostra:

$$\hat{\beta} > 0.$$

Isso permite dizer que a reta amostral tem direção positiva.

Não permite dizer que:

- a passagem do tempo causou convergência;
- 2009 causou uma mudança;
- comércio ou poder explicam a inclinação;
- a China causou os votos do Brasil.

Lição da Aula 4

Sem exposição bem definida, resultados potenciais e hipótese de identificação, a regressão permanece descritiva e associacional.

lm() executa o cálculo, não escolhe a interpretação

Em R, a chamada bivariada é:

```
modelo_mqo <- lm(  
  taxa_media_convergencia ~ anos_desde_1997,  
  data = dados_anuais  
)  
  
coef(modelo_mqo)  
fitted(modelo_mqo)  
residuals(modelo_mqo)
```

O que o programa faz

Encontra os coeficientes que minimizam a SQR e devolve valores ajustados e resíduos.

O que o programa não faz

lm() não cria identificação causal e, nesta aula, não usaremos valores-p, testes, intervalos de confiança ou `summary(modelo_mqo)`.

No laboratório, acompanhe três momentos

- 1 **Antes da reta:** leia `dados_anuais` e `grafico_basico`. Confirme que há 20 anos e que cada taxa tem seu próprio denominador.
- 2 **A reta:** use `coeficientes_comparados` para confrontar os cálculos manuais e o resultado de `lm()`.
- 3 **Interpretação:** use `grafico_final` e `dados_com_ajuste` para relacionar pontos, valores ajustados e resíduos.

Pergunta comum aos três momentos

O que a saída descreve na amostra? Que conclusão causal ela não permite?

Propriedades dos resíduos são mecânicas, não diagnósticas

Quando o modelo inclui intercepto:

$$\sum_i \hat{e}_i = 0, \quad \sum_i X_i \hat{e}_i = 0, \quad \sum_i \hat{Y}_i = \sum_i Y_i.$$

Também:

$(\bar{X}, \bar{Y})$ pertence à reta ajustada.

Escopo

Hoje usamos essas igualdades somente para verificar a construção da reta. Diagnóstico de resíduos e observações influentes pertence à Aula 8.

Pausa: recuperar a lógica sem usar software

No AGNA, A_i é o ano, $X_i = A_i - 1997$ mede anos desde 1997, e Y_i é a taxa de convergência em proporção. A reta arredondada é:

$$\widehat{Y} = 0,7672 + 0,0039X.$$

- 1 Qual é a taxa ajustada em 2000, quando $X = 3$?
- 2 Se, hipoteticamente, a taxa observada nesse ano fosse 0,80, qual seria o resíduo?
- 3 Quais são as unidades da inclinação e o que representa o intercepto?
- 4 Que argumento adicional seria necessário para chamar a inclinação de efeito causal?

Objetivo

Separar cálculo, interpretação em unidades, suporte de X e identificação.

Cinco erros que o MQO não corrige

- 1 Confundir a unidade resolução com a unidade ano.
- 2 Interpretar $\hat{\beta}$ sem mencionar unidades de X e Y .
- 3 Dar sentido substantivo a $\hat{\alpha}$ quando $X = 0$ é irrelevante.
- 4 Extrapolar a reta para valores de X não observados.
- 5 Chamar associação linear de efeito causal sem desenho de identificação.

E mais um limite de escopo

Hoje não ensinamos regressão múltipla, inferência, erros-padrão robustos, propriedades amostrais do estimador nem diagnóstico.

Síntese: quatro ideias para levar adiante

- 1 O MQO aplica a regra populacional do BLP aos momentos amostrais e escolhe a reta que minimiza a SQR, ou o EQM.
- 2 A inclinação é covariação dividida pela variação de X ; a reta passa por $(\bar{X}, \bar{Y})$.
- 3 Centralizar X torna o intercepto interpretável sem mudar inclinação, ajustes ou resíduos.
- 4 Uma reta bem estimada continua sendo associacional sem um argumento separado de identificação.

MQO resolve uma minimização; não inventa um contrafactual.

Referências e fronteira da aula

Leituras principais

Aronow, Peter M., e Benjamin T. Miller. *Foundations of Agnostic Statistics* (2019), seções 3.2.3, 3.3–3.3.1 e 4.1.

Hansen, Bruce E. *Econometrics* (2022), seções 3.3–3.8.

Fronteira

A Aula 5 termina na estimação e interpretação bivariada. Regressão múltipla começa na Aula 6; propriedades amostrais, diagnóstico e inferência entram apenas nas aulas posteriores previstas no syllabus.

Dados de aplicação: base didática AGNA do curso, votações da Assembleia Geral das Nações Unidas, 1997–2016.