

Aula 6: regressão múltipla

Interpretação condicional, variável omitida e preditores categóricos

FLS 6183 - Métodos Quantitativos de Pesquisa II

30 de setembro de 2026

Da Aula 5 à Aula 6

Na Aula 5, um preditor:

$$\widehat{Y}_i = \hat{\alpha} + \hat{\beta}X_i.$$

Agora, dois preditores:

$$\widehat{Y}_i = \hat{\alpha} + \hat{\beta}_1X_{1i} + \hat{\beta}_2X_{2i}.$$

Com k preditores: $\widehat{Y}_i = \hat{\alpha} + \hat{\beta}_1X_{1i} + \cdots + \hat{\beta}_kX_{ki}$. Os resultados desta aula valem para qualquer k ; as contas usam $k = 2$.

Notação

Sem chapéu, α , β_1 e β_2 são os coeficientes do BLP na população; com chapéu, as estimativas de MQO. O til marca valores candidatos na minimização. ε é o desvio em torno do BLP e $\hat{e}_i$, o resíduo.

BLP com dois preditores

$$(\alpha, \beta_1, \beta_2) = \arg \min_{(\tilde{\alpha}, \tilde{\beta}_1, \tilde{\beta}_2) \in \mathbb{R}^3} E[(Y - \tilde{\alpha} - \tilde{\beta}_1 X_1 - \tilde{\beta}_2 X_2)^2], \quad \varepsilon = Y - \alpha - \beta_1 X_1 - \beta_2 X_2.$$

Derivada em relação a $\tilde{\beta}_1$; as derivadas em $\tilde{\alpha}$ e $\tilde{\beta}_2$ são análogas:

$$\frac{\partial}{\partial \tilde{\beta}_1} E[(Y - \tilde{\alpha} - \tilde{\beta}_1 X_1 - \tilde{\beta}_2 X_2)^2] = -2E[X_1(Y - \tilde{\alpha} - \tilde{\beta}_1 X_1 - \tilde{\beta}_2 X_2)].$$

No mínimo, as três derivadas são iguais a zero:

$$E[\varepsilon] = 0,$$

$$E[X_1 \varepsilon] = 0,$$

$$E[X_2 \varepsilon] = 0.$$

Por construção

As três condições valem para o BLP de qualquer distribuição com segundos momentos finitos. São consequência da minimização, e não uma hipótese sobre a relação entre X e ε .

Solução única sem relação linear exata entre 1, X_1 e X_2 . Com um preditor, as duas condições davam $\beta = \text{Cov}(X, Y)/V(X)$ (Aula 3).

Equações normais

População: BLP

$$E[\varepsilon] = 0, \quad E[X_1\varepsilon] = 0, \quad E[X_2\varepsilon] = 0.$$

Amostra: MQO

$$\frac{1}{n} \sum_{i=1}^n \hat{e}_i = 0, \quad \frac{1}{n} \sum_{i=1}^n X_{1i} \hat{e}_i = 0, \quad \frac{1}{n} \sum_{i=1}^n X_{2i} \hat{e}_i = 0.$$

O MQO troca a esperança pela média amostral: o princípio plug-in da Aula 5. Com $\hat{e}_i = Y_i - \hat{\alpha} - \hat{\beta}_1 X_{1i} - \hat{\beta}_2 X_{2i}$, são três equações lineares em $\hat{\alpha}$, $\hat{\beta}_1$ e $\hat{\beta}_2$. Resolvidas com somatórios:

$$\hat{\beta}_1 = \frac{S_{22}S_{1Y} - S_{12}S_{2Y}}{S_{11}S_{22} - S_{12}^2}, \quad S_{jl} = \sum_i (X_{ji} - \bar{X}_j)(X_{li} - \bar{X}_l).$$

Com k preditores

São $k + 1$ equações, e a solução com somatórios cresce rápido a cada preditor. A notação matricial escreve o sistema e a solução da mesma forma para qualquer k .

Vetores e matrizes

Um **vetor** é uma lista ordenada de números, escrita em coluna:

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} \quad (n \times 1).$$

Uma **matriz** é uma tabela de números com linhas e colunas. A matriz dos preditores tem uma linha por unidade e uma coluna por coeficiente:

$$\mathbf{X} = \begin{bmatrix} 1 & X_{11} & X_{21} \\ 1 & X_{12} & X_{22} \\ \vdots & \vdots & \vdots \\ 1 & X_{1n} & X_{2n} \end{bmatrix} \quad (n \times 3).$$

Negrito: vetores e matrizes. X_{ji} é o valor do preditor j na unidade i ; a linha i de $\mathbf{X}$ é $(1, X_{1i}, X_{2i})$. A coluna de uns, $\mathbf{1}_n$, corresponde ao intercepto.

Exemplo: quatro observações

$$\mathbf{Y} = \begin{bmatrix} 2 \\ 3 \\ 5 \\ 10 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix}.$$

i	u_i	Y_i
A	1	2
B	-1	3
C	-1	5
D	1	10

Construção: $Y_i = 1 + 2X_{1i} + 3X_{2i} + u_i$. O erro u_i entra antes do ajuste; o resíduo $\hat{e}_i$ é calculado pelo MQO.

Transposta

A transposta $\mathbf{A}'$ troca linhas por colunas: o elemento (i, j) de $\mathbf{A}'$ é o elemento (j, i) de $\mathbf{A}$. Uma matriz $m \times n$ vira $n \times m$.

$$\mathbf{X} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix} \Rightarrow \mathbf{X}' = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix}.$$

- O vetor coluna $\mathbf{Y}$ (4×1) vira o vetor linha $\mathbf{Y}' = (2 \ 3 \ 5 \ 10)$ (1×4).
- Transposta do produto: $(\mathbf{AB})' = \mathbf{B}'\mathbf{A}'$.
- $\mathbf{A}$ é simétrica quando $\mathbf{A}' = \mathbf{A}$.

No R, a transposta é $\mathbf{t}(\mathbf{X})$. Alguns livros escrevem $\mathbf{A}^\top$.

Produto de matrizes

$\mathbf{A}$ ($m \times p$) vezes $\mathbf{B}$ ($p \times q$) dá $\mathbf{C} = \mathbf{AB}$ ($m \times q$). O elemento (i, j) combina a linha i de $\mathbf{A}$ com a coluna j de $\mathbf{B}$:

$$c_{ij} = \sum_{l=1}^p a_{il}b_{lj}.$$

O número de colunas de $\mathbf{A}$ precisa ser igual ao número de linhas de $\mathbf{B}$.

Dois produtos da aula

Produto interno de dois vetores $n \times 1$: $\mathbf{a}'\mathbf{b} = \sum_{i=1}^n a_i b_i$, um número.

Com $\tilde{\beta} = (\tilde{\alpha}, \tilde{\beta}_1, \tilde{\beta}_2)'$, a linha i de $\mathbf{X}\tilde{\beta}$ ($n \times 1$) é $\tilde{\alpha} + \tilde{\beta}_1 X_{1i} + \tilde{\beta}_2 X_{2i}$: o valor ajustado da unidade i pela reta candidata.

Somas em forma matricial

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} n & \sum_i X_{1i} & \sum_i X_{2i} \\ \sum_i X_{1i} & \sum_i X_{1i}^2 & \sum_i X_{1i}X_{2i} \\ \sum_i X_{2i} & \sum_i X_{1i}X_{2i} & \sum_i X_{2i}^2 \end{bmatrix}, \quad \mathbf{X}'\mathbf{Y} = \begin{bmatrix} \sum_i Y_i \\ \sum_i X_{1i}Y_i \\ \sum_i X_{2i}Y_i \end{bmatrix}.$$

Cada elemento é o produto interno de duas colunas de $\mathbf{X}$, ou de uma coluna de $\mathbf{X}$ com $\mathbf{Y}$. A matriz $\mathbf{X}'\mathbf{X}$ é 3×3 e simétrica.

Exemplo: quatro unidades

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} 4 & 2 & 4 \\ 2 & 2 & 3 \\ 4 & 3 & 6 \end{bmatrix}, \quad \mathbf{X}'\mathbf{Y} = \begin{bmatrix} 20 \\ 15 \\ 28 \end{bmatrix}.$$

Soma dos quadrados dos resíduos

O vetor de desvios da reta candidata é $\mathbf{Y} - \mathbf{X}\tilde{\boldsymbol{\beta}}$ ($n \times 1$). O produto interno de um vetor com ele mesmo é a soma dos quadrados dos seus elementos:

$$\text{SQR}(\tilde{\boldsymbol{\beta}}) = \sum_{i=1}^n (Y_i - \tilde{\alpha} - \tilde{\beta}_1 X_{1i} - \tilde{\beta}_2 X_{2i})^2 = (\mathbf{Y} - \mathbf{X}\tilde{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\tilde{\boldsymbol{\beta}}).$$

Estimador de MQO

$$\hat{\boldsymbol{\beta}} = \arg \min_{\tilde{\boldsymbol{\beta}}} (\mathbf{Y} - \mathbf{X}\tilde{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\tilde{\boldsymbol{\beta}}).$$

A expressão é a mesma com 1, 2 ou 20 preditores; muda só o número de colunas de $\mathbf{X}$.

Equações normais em forma matricial

Resíduos: $\hat{\mathbf{e}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$. As três equações normais formam um único produto:

$$\mathbf{X}'\hat{\mathbf{e}} = \begin{bmatrix} \sum_i \hat{e}_i \\ \sum_i X_{1i}\hat{e}_i \\ \sum_i X_{2i}\hat{e}_i \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

A derivada da SQR empilha as três derivadas parciais:

$$\frac{\partial \text{SQR}}{\partial \tilde{\boldsymbol{\beta}}} = -2\mathbf{X}'(\mathbf{Y} - \mathbf{X}\tilde{\boldsymbol{\beta}}).$$

No mínimo, ela é igual a zero:

$$\mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0} \implies \boxed{\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}.}$$

Matriz inversa

- Identidade $\mathbf{I}_m$: 1 na diagonal e 0 fora dela; $\mathbf{A}\mathbf{I} = \mathbf{I}\mathbf{A} = \mathbf{A}$.
- Inversa de uma matriz quadrada $\mathbf{A}$: $\mathbf{A}^{-1}\mathbf{A} = \mathbf{A}\mathbf{A}^{-1} = \mathbf{I}$.

Multiplique os dois lados de $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}$ por $(\mathbf{X}'\mathbf{X})^{-1}$:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

Posto completo

$(\mathbf{X}'\mathbf{X})^{-1}$ existe quando nenhuma coluna de $\mathbf{X}$ é combinação linear exata das outras. Com um preditor, é a condição $\sum_i (X_i - \bar{X})^2 > 0$ da Aula 5.

Exemplo em matrizes

Nas quatro unidades:

$$(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{4} \begin{bmatrix} 3 & 0 & -2 \\ 0 & 8 & -4 \\ -2 & -4 & 4 \end{bmatrix}, \quad \hat{\beta} = \frac{1}{4} \begin{bmatrix} 3 & 0 & -2 \\ 0 & 8 & -4 \\ -2 & -4 & 4 \end{bmatrix} \begin{bmatrix} 20 \\ 15 \\ 28 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

O erro escolhido satisfaz $\mathbf{X}'\mathbf{u} = \mathbf{0}$. Por isso, o MQO recupera $\hat{\beta} = (1, 2, 3)'$ e $\hat{\mathbf{e}} = \mathbf{u}$ neste exemplo. Em geral, erro e resíduo não coincidem.

Exercício

Multiplique $\mathbf{X}'\mathbf{X}$ por $(\mathbf{X}'\mathbf{X})^{-1}$ e confira que o resultado é $\mathbf{I}_3$.

No R: `solve(t(X) %*% X) %*% t(X) %*% Y`

BLP e MQO: duas rotas

Na população, $\mathbf{x} = (1, X_1, X_2)'$ e o BLP escolhe os coeficientes β para minimizar o erro quadrático esperado:

$$\beta = \arg \min_{\mathbf{b}} E[(Y - \mathbf{x}'\mathbf{b})^2], \quad E[\mathbf{x}(Y - \mathbf{x}'\beta)] = \mathbf{0}.$$

Na amostra, o plug-in troca a esperança pela média, com $\mathbf{x}_i = (1, X_{1i}, X_{2i})'$:

$$\hat{\beta}_{\text{plug-in}} = \arg \min_{\mathbf{b}} \underbrace{\frac{1}{n} \sum_{i=1}^n (Y_i - \mathbf{x}_i' \mathbf{b})^2}_{\text{SQR}(\mathbf{b})/n}.$$

Por que reaparece a fórmula de MQO?

Dividir a SQR por $n > 0$ não muda o minimizador. Logo, o plug-in resolve o mesmo problema de MQO dos slides 9–11. Sua condição amostral é

$$\frac{1}{n} \mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\beta}) = \mathbf{0} \iff \mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y} \implies \hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

Interpretação condicional

Compare dois perfis com o mesmo X_2 e valores de X_1 que diferem em uma unidade:

$$\widehat{Y}(x_1 + 1, x_2) - \widehat{Y}(x_1, x_2) = \hat{\beta}_1.$$

- A diferença é a mesma para quaisquer x_1 e x_2 : o modelo é linear em X_1 e não tem interação entre X_1 e X_2 .
- A unidade de $\hat{\beta}_1$ é unidade de Y por unidade de X_1 , como na Aula 5.

A decomposição do coeficiente mostra quais comparações nos dados determinam $\hat{\beta}_1$.

Decomposição do coeficiente

Regressão de X_1 nos demais preditores, com intercepto. Com dois preditores:

$$X_{1i} = \hat{\pi}_0 + \hat{\pi}_2 X_{2i} + \hat{r}_i.$$

O resíduo $\hat{r}_i$ é a parte de X_{1i} que os demais preditores não preveem linearmente.

Resultado

$$\hat{\beta}_1 = \frac{\sum_i \hat{r}_i Y_i}{\sum_i \hat{r}_i^2} = (\hat{\mathbf{r}}' \hat{\mathbf{r}})^{-1} \hat{\mathbf{r}}' \mathbf{Y}.$$

O coeficiente de X_1 na regressão múltipla é a inclinação da regressão simples de Y em $\hat{r}$.

Teorema de Frisch–Waugh–Lovell. Na população, o mesmo resultado vale com esperanças no lugar das somas (Hansen, seção 2.23); a versão amostral está na seção 3.18.

Decomposição com somatórios

Multiplique $Y_i = \hat{\alpha} + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \hat{e}_i$ por $\hat{r}_i$ e some em i :

$$\sum_i \hat{r}_i Y_i = \hat{\alpha} \sum_i \hat{r}_i + \hat{\beta}_1 \sum_i \hat{r}_i X_{1i} + \hat{\beta}_2 \sum_i \hat{r}_i X_{2i} + \sum_i \hat{r}_i \hat{e}_i.$$

- ❶ $\sum_i \hat{r}_i = 0$ e $\sum_i \hat{r}_i X_{2i} = 0$: equações normais da regressão de X_1 em X_2 .
- ❷ $\sum_i \hat{r}_i \hat{e}_i = 0$: $\hat{r}_i = X_{1i} - \hat{\pi}_0 - \hat{\pi}_2 X_{2i}$ combina 1, X_1 e X_2 , e $\hat{e}$ é ortogonal aos três.
- ❸ $\sum_i \hat{r}_i X_{1i} = \sum_i \hat{r}_i (\hat{\pi}_0 + \hat{\pi}_2 X_{2i} + \hat{r}_i) = \sum_i \hat{r}_i^2$, pelo item 1.

Logo,

$$\sum_i \hat{r}_i Y_i = \hat{\beta}_1 \sum_i \hat{r}_i^2.$$

Com três ou quatro preditores, a regressão de X_1 tem mais coeficientes, e cada passo ganha mais somas.

Matriz de resíduos

Separe as colunas de $\mathbf{X}$ em $\mathbf{X} = [\mathbf{X}_1 \ \mathbf{Z}]$: $\mathbf{X}_1$ é a coluna de X_1 , e $\mathbf{Z}$ reúne as demais (o intercepto e os outros preditores; com dois preditores, $\mathbf{Z} = [\mathbf{1}_n \ \mathbf{X}_2]$).

Regressão de um vetor $\mathbf{v}$ ($n \times 1$) em $\mathbf{Z}$:

$$\text{ajustados: } \mathbf{P}_Z \mathbf{v}, \quad \mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'; \quad \text{resíduos: } \mathbf{M}_Z \mathbf{v}, \quad \mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z.$$

Três propriedades

- 1 $\mathbf{M}_Z \mathbf{Z} = \mathbf{Z} - \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{Z} = \mathbf{0}$.
- 2 $\mathbf{M}_Z' = \mathbf{M}_Z$ e $\mathbf{M}_Z \mathbf{M}_Z = \mathbf{M}_Z$, porque $\mathbf{P}_Z' = \mathbf{P}_Z$ e $\mathbf{P}_Z \mathbf{P}_Z = \mathbf{P}_Z$.
- 3 Se $\mathbf{Z}'\mathbf{v} = \mathbf{0}$, então $\mathbf{M}_Z \mathbf{v} = \mathbf{v}$.

O resíduo da regressão de X_1 nos demais preditores é $\hat{\mathbf{r}} = \mathbf{M}_Z \mathbf{X}_1$.

Decomposição com matrizes

As equações normais da regressão múltipla, $\mathbf{X}'\hat{\mathbf{e}} = \mathbf{0}$, dão $\mathbf{X}'_1\hat{\mathbf{e}} = 0$ e $\mathbf{Z}'\hat{\mathbf{e}} = 0$. Com $\hat{\boldsymbol{\theta}}$ os coeficientes das colunas de $\mathbf{Z}$, multiplique $\mathbf{Y} = \mathbf{X}_1\hat{\boldsymbol{\beta}}_1 + \mathbf{Z}\hat{\boldsymbol{\theta}} + \hat{\mathbf{e}}$ por $\hat{\mathbf{r}}' = \mathbf{X}'_1\mathbf{M}_Z$:

$$\hat{\mathbf{r}}'\mathbf{Y} = \hat{\mathbf{r}}'\mathbf{X}_1\hat{\boldsymbol{\beta}}_1 + \hat{\mathbf{r}}'\mathbf{Z}\hat{\boldsymbol{\theta}} + \hat{\mathbf{r}}'\hat{\mathbf{e}}.$$

- ❶ $\hat{\mathbf{r}}'\mathbf{Z} = \mathbf{X}'_1\mathbf{M}_Z\mathbf{Z} = \mathbf{0}'$ (propriedade 1).
- ❷ $\hat{\mathbf{r}}'\hat{\mathbf{e}} = \mathbf{X}'_1\mathbf{M}_Z\hat{\mathbf{e}} = \mathbf{X}'_1\hat{\mathbf{e}} = 0$ (propriedade 3, com $\mathbf{v} = \hat{\mathbf{e}}$).
- ❸ $\hat{\mathbf{r}}'\mathbf{X}_1 = \mathbf{X}'_1\mathbf{M}'_Z\mathbf{M}_Z\mathbf{X}_1 = \hat{\mathbf{r}}'\hat{\mathbf{r}}$ (propriedade 2).

$$\hat{\boldsymbol{\beta}}_1 = (\hat{\mathbf{r}}'\hat{\mathbf{r}})^{-1}\hat{\mathbf{r}}'\mathbf{Y}.$$

Os mesmos três passos dos somatórios, com qualquer número de colunas em $\mathbf{Z}$.

Exemplo: quatro unidades

Unidade	X_1	X_2	Y	$\hat{r}$
A	0	0	2	0
B	0	1	3	-0,5
C	1	1	5	0,5
D	1	2	10	0

Regressão de X_1 em X_2 : $\hat{X}_1 = 0,5X_2$, e $\hat{r} = \mathbf{M}_Z \mathbf{X}_1$ é a última coluna. Então

$$\hat{\beta}_1 = \frac{(-0,5)(3) + (0,5)(5)}{(-0,5)^2 + (0,5)^2} = \frac{1}{0,5} = 2.$$

Aqui $\hat{r}_i$ é o resíduo da regressão auxiliar de X_1 em X_2 , não o erro u_i adicionado a Y . Só B e C têm $\hat{r}_i \neq 0$; por isso $\hat{\beta}_1$ compara essas unidades.

Perguntas

Sem X_2 na regressão, qual é a inclinação de Y em X_1 ? Por que ela difere de 2?

Resíduo de Y

Seja $M_Z Y$ o resíduo de Y nos demais preditores.

- **Mesmo $\hat{\beta}_1$:** $\hat{r}' M_Z Y = X_1' M_Z M_Z Y = \hat{r}' Y$. A parte de Y prevista pelos demais preditores é combinação das colunas de Z , e $\hat{r}' Z = 0'$: ela não altera a inclinação.
- **Mesmos resíduos:** a regressão de $M_Z Y$ em $\hat{r}$ tem os resíduos $\hat{e}$ da regressão múltipla. A de Y em $\hat{r}$ tem resíduos maiores, porque inclui a parte de Y que Z prevê.
- **Correlação parcial:** a correlação entre $M_Z Y$ e $\hat{r}$ é a correlação parcial entre Y e X_1 , dados os demais preditores.

Só Y residualizado

Com X_1 original, a inclinação de $M_Z Y$ em X_1 é $\hat{\beta}_1 \sum_i \hat{r}_i^2 / \sum_i (X_{1i} - \bar{X}_1)^2$, mais perto de zero: no exemplo, 1 em vez de 2. Com vários preditores, os coeficientes se misturam e podem trocar de sinal (Hull, 2018).

Regressão curta e regressão longa

Longa: $Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$. Curta: $\gamma_1 = \text{Cov}(X_1, Y)/V(X_1)$.

Substitua Y na covariância:

$$\text{Cov}(X_1, Y) = \beta_1 V(X_1) + \beta_2 \text{Cov}(X_1, X_2) + \text{Cov}(X_1, \varepsilon),$$

e $\text{Cov}(X_1, \varepsilon) = E[X_1 \varepsilon] - E[X_1]E[\varepsilon] = 0$. Logo:

$$\boxed{\gamma_1 = \beta_1 + \beta_2 \delta}, \quad \delta = \frac{\text{Cov}(X_1, X_2)}{V(X_1)}.$$

δ é a inclinação da regressão de X_2 em X_1 . Na amostra, com intercepto nas três regressões e as mesmas observações, a identidade é exata: $\hat{\gamma}_1 = \hat{\beta}_1 + \hat{\beta}_2 \hat{\delta}$. No exemplo, $\widehat{X}_2 = 0,5 + X_1$, logo $\hat{\delta} = 1$ e $5 = 2 + 3 \times 1$.

Os rótulos “curta” e “longa” são de Goldberger (1991); ver Hansen, seção 2.24.

Sinal da diferença

$\gamma_1 - \beta_1 = \beta_2 \delta$		
$\delta > 0$		$\delta < 0$
$\beta_2 > 0$	$\gamma_1 > \beta_1$	$\gamma_1 < \beta_1$
$\beta_2 < 0$	$\gamma_1 < \beta_1$	$\gamma_1 > \beta_1$

As duas inclinações coincidem quando $\beta_2 = 0$ ou $\delta = 0$.

Perguntas

Em um artigo que você leu, qual variável ficou fora da regressão? Quais seriam os sinais de β_2 e δ ?

Ano e agenda da AGNU

- Unidade: resolução votada por Brasil e China, 1997–2016 (1.762 resoluções).
- Y_i : 100 quando os votos coincidem e 0 quando divergem.
- X_{1i} : anos desde 1997. X_{2i} : 1 quando a resolução está classificada no tema conflito palestino (pacote unvotes).

Regressão	Preditores	Coeficientes
Curta	X_1	$\hat{\gamma}_1 = 0,31$ p.p. por ano
Longa	X_1, X_2	$\hat{\beta}_1 = 0,45$ p.p. por ano; $\hat{\beta}_2 = 23,2$ p.p.
Auxiliar	X_2 em X_1	$\hat{\delta} = -0,0060$ por ano

$$0,31 = 0,45 + 23,2 \times (-0,0060).$$

Na Aula 5, a unidade era o ano (20 pontos), e a inclinação, 0,39 p.p. por ano. Fonte: votações nominais da AGNU (pacote unvotes).

Resoluções sobre o conflito palestino




Figura 1: Participação das resoluções sobre o conflito palestino nas votações de cada ano, 1997–2016, e reta de MQO ponderada pelo número de votações do ano (inclinação: $-0,60$ p.p. por ano). Fonte: votações nominais da AGNU (pacote unvotes).

Convergência: 98,1% nessas resoluções e 75,4% nas demais. Participação na agenda: 22,5% em 1997–2008 e 18,0% em 2009–2016. Com $\hat{\beta}_2 > 0$ e $\hat{\delta} < 0$, a inclinação curta fica abaixo da longa.

Preditor categórico

Y_i : convergência dos votos do país i com os da China na AGNU em 2016, em % dos pares de votos válidos. O continente tem quatro categorias. Com intercepto, entram três indicadoras; a categoria sem indicadora é a referência (África):

$$\widehat{Y}_i = \hat{\alpha} + \hat{\beta}_{\text{Am}} D_{\text{Am},i} + \hat{\beta}_{\text{As}} D_{\text{As},i} + \hat{\beta}_{\text{Eu}} D_{\text{Eu},i}.$$

- África: $\widehat{Y} = \hat{\alpha}$.
- Américas: $\widehat{Y} = \hat{\alpha} + \hat{\beta}_{\text{Am}}$.
- Ásia e Oceania: $\widehat{Y} = \hat{\alpha} + \hat{\beta}_{\text{As}}$.
- Europa: $\widehat{Y} = \hat{\alpha} + \hat{\beta}_{\text{Eu}}$.

Países: Brasil e 95 países em que a China não foi o principal destino das exportações de bens em nenhum ano de 1997–2016 e com série completa. Fonte: votações nominais da AGNU (pacote unvotes).

Médias por grupo

Continente	Países	Média de Y (%)	Coeficiente
África	24	70,02	$\hat{\alpha} = 70,02$
Américas	22	65,86	$\hat{\beta}_{Am} = -4,16$
Ásia e Oceania	20	65,33	$\hat{\beta}_{As} = -4,70$
Europa	30	50,03	$\hat{\beta}_{Eu} = -19,99$

Só com as indicadoras, os valores ajustados são as médias de cada grupo: a regressão é saturada, como as indicadoras de ano na Aula 3.

Coeficientes calculados antes do arredondamento das médias.

Indicadoras e colinearidade

Com as quatro indicadoras e o intercepto:

$$D_{Af,i} + D_{Am,i} + D_{As,i} + D_{Eu,i} = 1 \quad \text{para todo } i.$$

A coluna do intercepto é a soma exata das indicadoras. $\mathbf{X}'\mathbf{X}$ não tem inversa, e `lm()` devolve NA para uma delas.

Troca da referência

Com as Américas como referência: $\hat{\alpha} = 65,86$; África +4,16; Ásia e Oceania -0,53; Europa -15,83. Os coeficientes mudam, e os valores ajustados continuam iguais às médias por grupo.

Categoria e preditor contínuo




Figura 2: Convergência dos votos com a China e exportações para a China em 2016, 96 países, com as retas de MQO do modelo com continente. Fontes: votações nominais da AGNU (pacote unvotes); ITPD-E, release 3 (USITC).

Mesma inclinação nos quatro continentes: $\hat{\beta}_1 = -0,11$ p.p. de convergência por p.p. de exportações. Na regressão curta, sem continente, $\hat{\gamma}_1 = 0,19 = -0,11 + \sum_g \hat{\beta}_g \hat{\delta}_g$, uma parcela por indicadora omitida. Inclinações diferentes por continente exigem interação (Aula 11).

- ❶ O MQO resolve $\mathbf{X}'\hat{\mathbf{e}} = \mathbf{0}$: $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$, a mesma expressão para qualquer número de preditores e o plug-in de $\beta = E[\mathbf{xx}']^{-1}E[\mathbf{x}Y]$.
- ❷ $\hat{\beta}_1 = (\hat{\mathbf{r}}'\hat{\mathbf{r}})^{-1}\hat{\mathbf{r}}'\mathbf{Y}$: a inclinação da regressão de Y na parte de X_1 que os demais preditores não preveem linearmente.
- ❸ Regressões curta e longa: $\gamma_1 = \beta_1 + \beta_2\delta$.
- ❹ Um preditor categórico com G categorias entra com $G - 1$ indicadoras; cada coeficiente é a diferença de valor ajustado em relação à referência, com os demais preditores fixos.

Referências

Leituras

Hansen, Bruce E. *Econometrics* (2022), seções 2.21–2.25; notação matricial: seções 3.10–3.12; decomposição na amostra: seções 3.16 e 3.18.

Shalizi, Cosma R. *The Truth About Linear Regression*, capítulo 12 e seção 14.3.

Goldberger, Arthur S. 1991. *A Course in Econometrics*. Harvard University Press.

Hull, Peter. 2018. “On Residualized Outcome Regressions.” Nota, 30 de março.

Aplicações

Flores-Macías, Gustavo A., e Sarah E. Kreps. 2013. “The Foreign Policy Consequences of Trade: China’s Commercial Relations with Africa and Latin America, 1992–2006.” *The Journal of Politics* 75(2): 357–371.

Dados: votações nominais da Assembleia Geral das Nações Unidas (pacote unvotes), 1997–2016; exportações por destino: International Trade and Production Database for Estimation (ITPD-E), release 3, USITC.