

Aula 6: regressão múltipla

Interpretação condicional, categorias e variável omitida

FLS 6183 - Métodos Quantitativos de Pesquisa II

30 de setembro de 2026

Pergunta

Como ler a associação entre comércio e convergência de votos quando também observamos cobertura da votação, região e outras características dos países?

- 1 Da reta bivariada ao ajuste múltiplo
- 2 Categoria de referência
- 3 Variável omitida
- 4 Aplicação com 96 países da AGNU
- 5 Laboratório em duplas ou trios

Exposição e discussão: cerca de 65 minutos. Laboratório: cerca de 45 minutos.

Da Aula 5 à Aula 6

Na Aula 5, uma única reta resumia a associação entre duas variáveis:

$$\widehat{Y}_i = \hat{\alpha} + \hat{\beta}X_i.$$

Agora permitimos mais de um preditor:

$$\widehat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1X_i + \hat{\beta}_2Z_i.$$

Mudança na pergunta

Qual é a diferença ajustada em Y entre unidades que diferem em X , mantendo Z no mesmo valor?

O sentido de manter constante

Imagine dois países com o mesmo valor de Z , mas valores de X que diferem em uma unidade:

$$\widehat{Y}(X + 1, Z) - \widehat{Y}(X, Z) = \widehat{\beta}_1.$$

O modelo produz essa comparação. Países reais podem diferir também em características que não incluímos.

Leitura correta

$\widehat{\beta}_1$ descreve uma diferença ajustada pela equação escolhida. Para chamá-la de efeito causal, precisaríamos de um desenho de identificação.

Símbolos da regressão múltipla

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i.$$

- i : unidade observada; Y_i : desfecho.
- X_{ji} : valor do preditor j na unidade i .
- β_j : coeficiente da projeção linear de referência; o chapéu marca a estimativa na amostra.
- u_i : diferença entre Y_i e a parte linear de referência.

No laboratório, cada i será um país em 2016, e Y_i será uma taxa entre 0 e 1.

Preditor categórico: a referência

Defina $D_i = 1$ para país da América Latina e $D_i = 0$ para país de outra região:

$$\widehat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{\gamma} D_i.$$

- Outra região ($D = 0$): $\widehat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$.
- América Latina ($D = 1$): $\widehat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X + \hat{\gamma}$.

Interpretação

$\hat{\gamma}$ é a diferença ajustada entre as categorias para o mesmo X . A categoria $D = 0$ é a referência.

Variável omitida: quatro unidades

Unidade	X	Z	$Y = 1 + 2X + 3Z$
A	0	0	1
B	0	1	4
C	1	1	6
D	1	2	9

X e Z crescem juntos; ambos entram na regra que gerou Y .

Pergunta para a turma

Quanto parece variar Y com X se Z for ignorado? E se compararmos B e C, que têm o mesmo $Z = 1$?

A regressão curta e a comparação condicional

Ignorando Z , a média de Y é 2,5 quando $X = 0$ e 7,5 quando $X = 1$:

$$\hat{\beta}_X^{\text{curta}} = 7,5 - 2,5 = 5.$$

Entre B e C, $Z = 1$ nos dois casos. Quando X passa de 0 a 1, Y passa de 4 a 6: diferença de 2.

Com os dois preditores, a regressão recupera $\hat{Y} = 1 + 2X + 3Z$.

A decomposição da omissão

No exemplo, o coeficiente da regressão de Z em X é 1:

$$\underbrace{5}_{\text{coeficiente curto}} = \underbrace{2}_{\text{coeficiente com } Z} + \underbrace{3}_{\text{coeficiente de } Z} \times \underbrace{1}_{\text{associação } X-Z}.$$

Esta é uma decomposição algébrica entre duas regressões lineares estimadas nas mesmas quatro unidades.

Cuidado

Mudar o coeficiente ao acrescentar Z informa como a especificação altera a associação estimada. Isso não comprova que Z seja um confundidor causal.

Como o MQO escolhe os coeficientes

Para k preditores, o MQO escolhe os coeficientes que minimizam:

$$\text{SQR}(\tilde{\beta}_0, \dots, \tilde{\beta}_k) = \sum_{i=1}^n \left(Y_i - \tilde{\beta}_0 - \sum_{j=1}^k \tilde{\beta}_j X_{ji} \right)^2.$$

É a mesma regra da Aula 5, agora aplicada a um plano com mais dimensões.

$\tilde{\beta}_j$ é um candidato. $\hat{\beta}_j$ é o valor que minimiza a soma de quadrados na amostra.

Em notação matricial, com colunas linearmente independentes: $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$. A função `lm()` faz o cálculo.

A aplicação: países e votos na AGNU

- Recorte: 2016, uma linha por país, 96 países.
- Desfecho: proporção de pares de votos válidos em que o país votou como a China nas votações nominais da Assembleia Geral das Nações Unidas (AGNU).
- Fonte: painel didático preservado, formado a partir de votações da AGNU e de `synth_data.rds`.

$$\text{taxa de convergência}_i = \frac{\text{votos convergentes com a China}_i}{\text{pares de votos válidos}_i}.$$

A taxa não é uma medida de alinhamento causal nem um resultado de intervenção.

Conferência dos denominadores

Verificação em 2016	Resultado
Países distintos	96
Países da América Latina	20
Votações no ano	114
Pares válidos por país: mínimo / mediana / máximo	5 / 112 / 113
Ausências nas variáveis usadas	0

Cada país contribui com uma taxa calculada sobre seu próprio denominador. Um país com cinco pares válidos requer cautela especial.

Fonte: painel didático país–ano da AGNU, 2016; validações executadas no script do laboratório.

A escala dos preditores

O campo de comércio com a China foi transformado na fonte original. O dicionário local não documenta a transformação.


$$Z_{Xi} = \frac{X_i - \bar{X}}{s_X}, \quad s_X = \text{desvio-padrão de } X \text{ entre os 96 países.}$$

Unidade do coeficiente

Ao multiplicar o coeficiente da taxa por 100, lemos a diferença ajustada em pontos percentuais de convergência por um desvio-padrão do preditor.

Não lemos o coeficiente como pontos percentuais de comércio.

Associação bivariada no recorte de 2016



Unidade: país (96); denominador da taxa: 5 a 113 pares de votos válidos por país. A reta laranja é bivariada. Fonte: painel didático da AGNU e `synth_data.rds`. Associação, sem leitura causal.

Quatro modelos na mesma amostra

Modelo	Preditores acrescentados
M1	Campo de comércio com a China
M2	Cobertura de pares válidos e categoria América Latina
M3	Campo de comércio com os EUA e hiato de poder em relação aos EUA
M4	Dois controles econômicos da fonte: <code>pci_cur</code> e <code>CA_GDP</code>

Todos usam os mesmos 96 países. Os preditores contínuos foram padronizados nesse recorte; a categoria tem referência “outras regiões”.

Coeficiente do comércio com a China


	M1	M2	M3	M4
Coeficiente	+0,80	+0,52	+1,29	+1,69

Unidade: pontos percentuais da taxa de convergência por um desvio-padrão do campo comercial transformado.

Leitura de M4

Entre países com os mesmos valores dos demais preditores no modelo, uma diferença de um desvio-padrão no campo comercial está associada a 1,69 ponto percentual a mais na taxa ajustada.

O coeficiente muda entre especificações



Unidade: pontos percentuais da taxa por um desvio-padrão do campo comercial. M1: comércio com a China; M2: cobertura e região; M3: comércio com os EUA e hiato de poder; M4: controles econômicos. Fonte: painel didático da AGNU e `synth_data.rds`. A linha não representa tempo nem incerteza.

A categoria geográfica em M4

A referência da categoria é “outras regiões”. O coeficiente de América Latina em M4 é +6,70 pontos percentuais.

$$\widehat{Y}_{\text{América Latina}}(X) - \widehat{Y}_{\text{outras regiões}}(X) = 0,0670.$$

Todos os outros preditores X têm o mesmo valor nos dois lados. O modelo é aditivo: essa diferença prevista é constante em X .

Relações distintas por nível de comércio exigiriam uma interação, assunto da Aula 11.

Dois perfis condicionais de M4

Fixe todos os preditores contínuos em zero depois da padronização (a média dos 96 países). Mude apenas a região:

Perfil hipotético	Taxa ajustada
Outras regiões	60,45%
América Latina	67,15%

A diferença de 6,70 pontos percentuais reproduz o coeficiente da categoria. São previsões da reta, não dois países observados.

Ajuste descritivo dos modelos

	M1	M2	M3	M4
R^2 amostral	0,004	0,104	0,250	0,398
Países	96	96	96	96

R^2 resume a fração da variação amostral do desfecho explicada pelos valores ajustados. Ao acrescentar preditores na mesma amostra, o R^2 do MQO não diminui.

Limite

Mais ajuste dentro da amostra não comprova melhor previsão fora dela, nem efeito causal dos preditores.

Limites desta comparação

- É um corte transversal de 2016: coeficientes são associações entre países.
- Os denominadores das taxas variam de 5 a 113 pares válidos. O MQO aqui dá o mesmo peso a cada país.
- Não conhecemos a transformação original dos campos comerciais; por isso a leitura é por desvio-padrão no recorte.
- Características não incluídas podem alterar os coeficientes.

Não interpretamos valores-p ou intervalos nesta aula. A inferência está prevista para as Aulas 9 e 10.

Laboratório: leitura e validação

Abra o projeto no RStudio e execute, bloco a bloco, `scripts/09_laboratorio_aula6_regressao_multipla.R`.

- 1 Leia o painel país-ano e filtre 2016.
- 2 Confirme 96 países, 20 latino-americanos e 114 votações.
- 3 Confira tipos, ausências, chaves únicas, numerador, denominador e taxa.
- 4 Observe o menor denominador: cinco pares válidos.

O script mostra os objetos `validacao_2016` e `ausentes_2016` antes de qualquer modelo.

Laboratório: estimar e comparar

- 1 Padronize os preditores contínuos nos mesmos 96 países.
- 2 Execute M1 a M4 com `lm()`.
- 3 Leia `tabela_modelos`: coeficiente comercial, coeficiente da categoria e R^2 .
- 4 Confira que perfis difere apenas em região.

Unidade a escrever na resposta

Pontos percentuais de convergência por um desvio-padrão do campo comercial, com os demais preditores do modelo mantidos constantes.

Laboratório: conversa em duplas ou trios

- 1 Por que o coeficiente do campo comercial muda de $+0,80$ em M1 para $+1,69$ em M4?
- 2 O que significa a referência "outras regiões" no coeficiente de América Latina?
- 3 Uma taxa baseada em cinco pares válidos merece a mesma confiança descritiva que outra baseada em 113? Explique.
- 4 Que informação adicional seria necessária para defender uma leitura causal da associação comercial?

Entregue uma tabela curta, uma figura, o script e um parágrafo de interpretação associacional.

- 1 Um coeficiente múltiplo compara valores ajustados quando os demais preditores do modelo ficam iguais.
- 2 Categorias entram por contraste com uma referência explícita.
- 3 Omitir um preditor associado a X e a Y pode mudar o coeficiente de X ; a mudança sozinha não estabelece causalidade.

No projeto da AGNU, a unidade, a escala e o denominador determinam como devemos ler cada número.

Hansen, Bruce E. *Econometrics* (2022), seções 2.21–2.25.

Shalizi, Cosma R. *The Truth About Linear Regression*, capítulo 12 e seção 14.3:
<https://www.stat.cmu.edu/~cshalizi/TALR/>.

Painel didático país–ano da AGNU (1997–2016), dicionário e manifesto local de dados no projeto do curso.
Fontes preservadas: votações nominais do pacote `unvotes` e `synth_data.rds`.

Os resultados numéricos destes slides são reproduzidos e verificados em
`scripts/09_laboratorio_aula6_regressao_multipla.R`.