Aula 7: propriedades do estimador de MQO

Distribuição amostral, viés, consistência, Gauss–Markov e bootstrap

FLS 6183 - Métodos Quantitativos de Pesquisa II

14 de outubro de 2026

BLP e MQO

Na população, $\mathbf{x} = (1, X_1, \ldots, X_k)'$ e $\beta = (\alpha, \beta_1, \ldots, \beta_k)'$:

$$Y = \mathbf{x}'\beta + \varepsilon, \qquad E[\mathbf{x}\varepsilon] = \mathbf{0}, \qquad \beta = E[\mathbf{x}\mathbf{x}']^{-1}E[\mathbf{x}Y].$$

Na amostra, $\mathbf{X}$ tem as linhas $\mathbf{x}_i'$ e $\mathbf{Y} = (Y_1, \ldots, Y_n)'$:

$$\widehat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}, \qquad \widehat{\mathbf{e}} = \mathbf{Y} - \mathbf{X}\widehat{\beta}.$$

Estimador e estimativa

$\widehat{\beta}$ é uma função da amostra aleatória. Cada amostra observada produz uma estimativa dos mesmos coeficientes populacionais.

Nova amostra, nova reta

População conhecida: $X \sim N(10, 3^2)$, $\varepsilon \sim N(0, 2^2)$ independente de X, $Y = 5 + 1{,}5X + \varepsilon$.

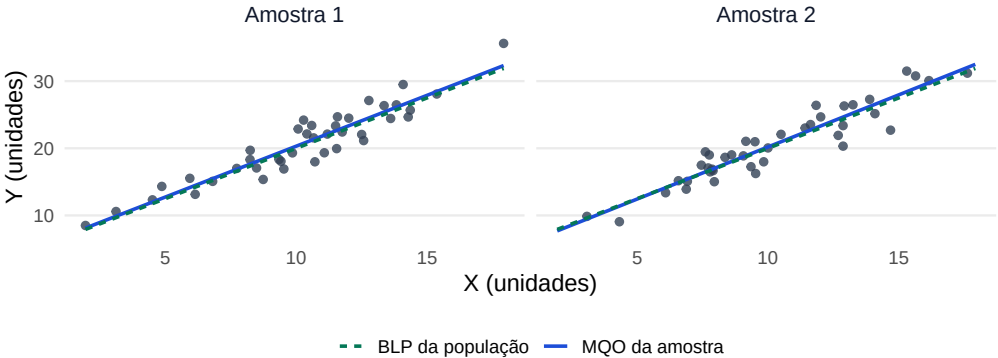


Figura 1: Duas amostras independentes de 40 pares (X,Y) da mesma população. A linha contínua é o MQO da amostra e a tracejada é o BLP populacional. Fonte: dados sintéticos do processo descrito.

Inclinações estimadas: $1{,}514$ e $1{,}552$. O coeficiente populacional é $\beta = 1{,}5$.

Distribuição amostral

Repetimos a amostragem e o ajuste de MQO 5.000 vezes, sempre com $n = 40$.

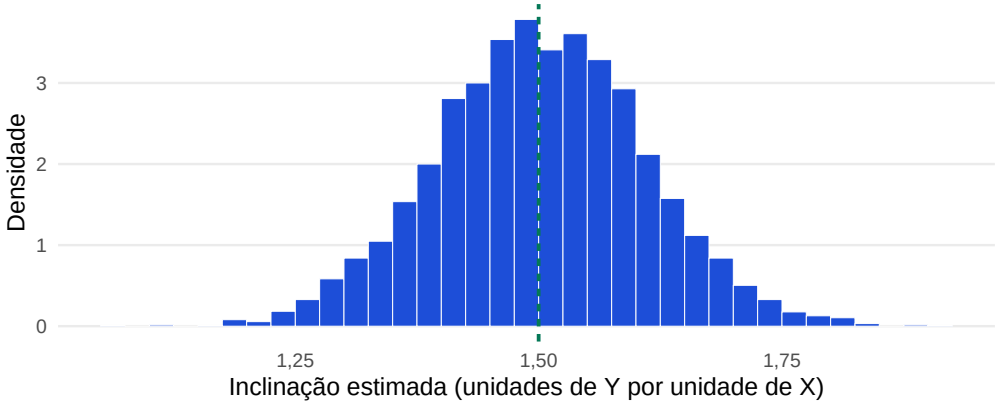


Figura 2: Histograma em escala de densidade de 5.000 inclinações de MQO. Cada valor vem de uma amostra independente de tamanho 40. A linha tracejada marca beta = 1,5. Fonte: simulação da população conhecida.

A média das estimativas, $1{,}502$, aproxima $E[\hat{\beta}]$. O desvio-padrão, $0{,}107$, aproxima a dispersão amostral.

Amostras pequenas e não viés

Mesmo processo gerador, com $\beta = 1{,}5$. Repetimos o MQO 5.000 vezes para cada n.

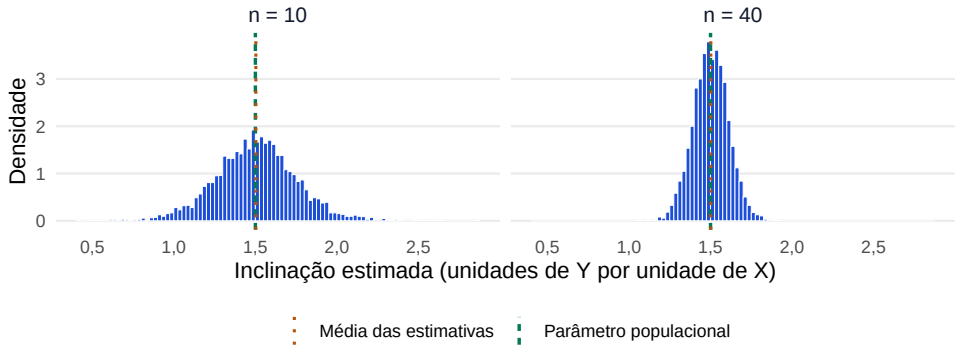


Figura 3: Distribuições de 5.000 inclinações por tamanho de amostra, com eixos e largura de classe comuns. A linha tracejada marca o parâmetro 1,5 e a pontilhada, a média das estimativas. Fonte: simulação da mesma população conhecida.

Médias: $1{,}503$ ($n = 10$) e $1{,}502$ ($n = 40$). Desvios-padrão: $0{,}254$ e $0{,}107$.

Com $n = 10$, há maior dispersão individual e a média das repetições fica próxima de $1{,}5$.

Viés do estimador

Para explicitar o tamanho da amostra, escrevemos $\hat{\beta}_n$:

$$\boxed{\text{Viés}_n(\hat{\beta}_n) = E[\hat{\beta}_n] - \beta.}$$

A esperança considera todas as amostras possíveis de tamanho n da mesma população.

Não viés para um tamanho de amostra fixo

$E[\hat{\beta}_n] = \beta$. A definição usa a distribuição amostral do estimador e não exige tomar o limite quando n cresce.

Erro de uma estimativa observada

Na primeira amostra, $\hat{\beta} - \beta = 1{,}514 - 1{,}5$. Essa diferença é o erro de estimação daquela amostra. O viés descreve sua média na distribuição amostral.

Variância e erro quadrático médio

A variância amostral descreve a dispersão do estimador:

$$\mathrm{V}(\hat{\beta}_n) = E\left[(\hat{\beta}_n - E[\hat{\beta}_n])^2\right].$$

O erro quadrático médio (EQM) considera a distância ao parâmetro:

$$\boxed{\mathrm{EQM}(\hat{\beta}_n) = E[(\hat{\beta}_n - \beta)^2] = \mathrm{V}(\hat{\beta}_n) + \mathrm{Viés}_n(\hat{\beta}_n)^2.}$$

Não viés e precisão

Quando o viés é zero, o EQM é igual à variância amostral. Um estimador não viesado ainda pode produzir estimativas muito dispersas.

O desvio-padrão da distribuição amostral, $\sqrt{\mathrm{V}(\hat{\beta}_n)}$, é o erro-padrão do estimador.

Consistência

$\hat{\beta}_n$ é consistente para β se, para todo $\delta > 0$,

$$\boxed{\Pr(|\hat{\beta}_n - \beta| > \delta) \longrightarrow 0 \quad \text{quando } n \longrightarrow \infty.}$$

Escrevemos $\hat{\beta}_n \xrightarrow{p} \beta$: convergência em probabilidade.

O papel de n

Consistência descreve uma sequência de estimadores conforme a amostra cresce. Não viés descreve a esperança do estimador para um n fixo.

Exemplo com Y_i i.i.d., $E[Y_i] = \mu \neq 0$ e $0 < \mathrm{V}(Y_i) < \infty$:

Estimador de μ	Não viesado	Consistente
Y_1, qualquer que seja n	Sim	Não
$\frac{n}{n+1}\bar{Y}$	Não	Sim

Calcular MQO na amostra

Com dados observados finitos, o MQO minimiza

$$S(\mathbf{b}) = (\mathbf{Y} - \mathbf{X}\mathbf{b})'(\mathbf{Y} - \mathbf{X}\mathbf{b}).$$

Condição para coeficientes únicos

$\mathbf{X}$ tem posto completo: suas $k+1$ colunas são linearmente independentes. Assim, $\mathbf{X}'\mathbf{X}$ tem inversa e

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

Independência não é exigida para calcular

Podemos calcular o MQO com observações dependentes ou de distribuições distintas. Segundos momentos populacionais finitos também não são uma exigência desse cálculo.

Sem posto completo, o problema de minimização tem soluções, mas os coeficientes não são únicos.

MQO: reescrever a fórmula conhecida

Começamos com a fórmula que já estudamos:

$$\widehat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

A lei dos grandes números trata da convergência de médias. Vamos escrever o MQO em termos dessas médias.

Dividir uma matriz por n multiplica sua inversa por n:

$$\left(\frac{\mathbf{X}'\mathbf{X}}{n}\right)^{-1} = n(\mathbf{X}'\mathbf{X})^{-1}.$$

Por isso, dividir os dois produtos por n preserva o resultado:

$$\begin{aligned}\left(\frac{\mathbf{X}'\mathbf{X}}{n}\right)^{-1}\left(\frac{\mathbf{X}'\mathbf{Y}}{n}\right) &= n(\mathbf{X}'\mathbf{X})^{-1}\frac{\mathbf{X}'\mathbf{Y}}{n} \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \widehat{\beta}.\end{aligned}$$

A reescrita conserva exatamente a estimativa calculada na mesma amostra.

Os produtos matriciais contêm somas

Com um único preditor, cada linha de $\mathbf{X}$ é $(1, X_i)$. A multiplicação de matrizes produz

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum_i X_i \\ \sum_i X_i & \sum_i X_i^2 \end{pmatrix}, \qquad \mathbf{X}'\mathbf{Y} = \begin{pmatrix} \sum_i Y_i \\ \sum_i X_i Y_i \end{pmatrix}.$$

Dividindo por n, cada soma se torna uma média. $\overline{X^2}$ é a média dos quadrados e $\overline{XY}$ a média dos produtos:

$$\frac{\mathbf{X}'\mathbf{X}}{n} = \begin{pmatrix} 1 & \bar{X} \\ \bar{X} & \overline{X^2} \end{pmatrix}, \qquad \frac{\mathbf{X}'\mathbf{Y}}{n} = \begin{pmatrix} \bar{Y} \\ \overline{XY} \end{pmatrix}.$$

Ligação com a fórmula da inclinação

São as mesmas médias que aparecem na fórmula escalar:

$$\hat{\beta}_1 = \frac{\overline{XY} - \bar{X}\bar{Y}}{\overline{X^2} - \bar{X}^2} = \frac{\widehat{\mathrm{Cov}}(X, Y)}{\widehat{\mathrm{V}}(X)}.$$

Consistência: médias e alvo populacional

Cada entrada dos produtos divididos por n é uma média amostral. Com vários preditores, a mesma lógica vale.

Suposições da demonstração

- Amostragem i.i.d.: os pares $(Y_i, \mathbf{x}_i)$ são independentes e identicamente distribuídos.
- Segundos momentos finitos de Y e de cada preditor.

Pela lei dos grandes números,

$$\frac{\mathbf{X}'\mathbf{X}}{n} \xrightarrow{p} E[\mathbf{x}\mathbf{x}'], \qquad \frac{\mathbf{X}'\mathbf{Y}}{n} \xrightarrow{p} E[\mathbf{x}Y].$$

Se $E[\mathbf{x}\mathbf{x}']$ tem inversa, a continuidade da inversão e da multiplicação implica

$$\widehat{\beta} = \left(\frac{\mathbf{X}'\mathbf{X}}{n}\right)^{-1} \left(\frac{\mathbf{X}'\mathbf{Y}}{n}\right) \xrightarrow{p} \underbrace{E[\mathbf{x}\mathbf{x}']^{-1} E[\mathbf{x}Y]}_{\beta\text{: coeficientes do BLP}}.$$

Média condicional do erro

Propriedade do erro do BLP

$$E[\mathbf{x}\varepsilon] = \mathbf{0}.$$

Suposição chave para o não viés

$$E[\varepsilon \mid \mathbf{x}] = 0.$$

Linear nos parâmetros

Na equação $Y = \mathbf{x}'\beta + \varepsilon$, a suposição implica $E[Y \mid \mathbf{x}] = \mathbf{x}'\beta$.
Por exemplo, com $\mathbf{x} = (1, X, X^2)'$,

$$E[Y \mid X] = \alpha + \beta_1 X + \beta_2 X^2.$$

A linearidade é em α, β_1, β_2. A relação com X pode ter curvatura.

Média condicional zero implica ortogonalidade, pela lei da esperança iterada. A implicação inversa não vale em geral.

Exemplo político: gasto de campanha e votos

Considere candidatos a prefeito. Queremos interpretar τ como efeito do gasto:

$$Y_i = \alpha + \tau G_i + \varepsilon_i.$$

Y_i é a porcentagem de votos; G_i é o gasto de campanha em R$ por eleitor; ε_i reúne fatores não medidos, como a força eleitoral prévia.

O que exige independência na média?

Entre candidatos que gastam R$ 2, R$ 5 ou R$ 10 por eleitor, a média de ε precisaria ser a mesma:

$$E[\varepsilon \mid G = 2] = E[\varepsilon \mid G = 5] = E[\varepsilon \mid G = 10] = E[\varepsilon].$$

Candidatos previamente mais fortes podem atrair mais doações e gastar mais. Isso pode fazer a média de ε variar com G.

Centrar o erro para que $E[\varepsilon] = 0$ é uma normalização. Só com independência na média obtemos $E[\varepsilon \mid G] = 0$.

Exemplo hipotético adaptado da lógica de Cunningham, *Causal Inference: The Mixtape*, seção 2.12. Aqui ε representa fatores não medidos na equação causal proposta; a condição de média zero não decorre da ortogonalidade do BLP.

Não viés do MQO

Reunimos os erros do modelo em $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)'$.

Suposição chave para o não viés

Sob amostragem i.i.d., $E[\varepsilon_i \mid \mathbf{x}_i] = 0$ implica $\boxed{E[\varepsilon \mid \mathbf{X}] = \mathbf{0}.}$

Na fórmula de MQO, substituímos $\mathbf{Y}$ por $\mathbf{X}\beta + \varepsilon$ e aplicamos a distributiva:

$$\begin{aligned}\widehat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \varepsilon) \\ &= (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{X})\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon \\ &= \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon.\end{aligned}$$

Ao condicionar em $\mathbf{X}$, a matriz dos preditores fica fixa:

$$E[\widehat{\beta} \mid \mathbf{X}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \underbrace{E[\varepsilon \mid \mathbf{X}]}_{\mathbf{0}} = \beta.$$

Com posto completo e esperança do estimador existente, a lei da esperança iterada dá $E[\widehat{\beta}] = \beta$. O resultado vale para n fixo.

Variância do MQO

Suponha $\mathrm{V}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n$. Então:

$$\boxed{\mathrm{V}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}.}$$

Com um preditor e intercepto, $\mathrm{V}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 / \sum_i (X_i - \bar{X})^2$. Maior ruído aumenta a variância. Maior variação do preditor reduz a variância.

Teorema de Gauss–Markov

Considere $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$, com posto completo,

$$E[\varepsilon \mid \mathbf{X}] = \mathbf{0}, \qquad \mathrm{V}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n.$$

Versão clássica

O MQO tem a menor variância entre os estimadores lineares em $\mathbf{Y}$ e não viesados condicionalmente em $\mathbf{X}$.

- Linear em $\mathbf{Y}$: $\hat{\beta}^{\,a} = \mathbf{A}\mathbf{Y}$, com $\mathbf{A}$ dependendo apenas de $\mathbf{X}$.
- Não viés para todo β: $E[\hat{\beta}^{\,a} \mid \mathbf{X}] = \beta$.
- A comparação vale para cada coeficiente e para qualquer combinação linear dos coeficientes.

BLUE: *best linear unbiased estimator*, ou melhor estimador linear não viesado. O teorema dispensa a normalidade dos erros.

Outra prova do não viés do MQO

Defina $\mathbf{A}_0 = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$. Como $\mathbf{A}_0$ depende apenas de $\mathbf{X}$, $\widehat{\beta} = \mathbf{A}_0\mathbf{Y}$. Com $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ e $E[\varepsilon \mid \mathbf{X}] = \mathbf{0}$:

$$\begin{aligned} E[\widehat{\beta} \mid \mathbf{X}] &= E[\mathbf{A}_0\mathbf{Y} \mid \mathbf{X}] \\ &= \mathbf{A}_0 E[\mathbf{Y} \mid \mathbf{X}] \\ &= \mathbf{A}_0(\mathbf{X}\beta + E[\varepsilon \mid \mathbf{X}]) \\ &= \mathbf{A}_0\mathbf{X}\beta. \end{aligned}$$

Condição de não viés

Para que essa média seja β para todo vetor de coeficientes, precisamos de $\mathbf{A}_0\mathbf{X} = \mathbf{I}_{k+1}$: a identidade deixa β inalterado.

Como $\mathbf{X}'\mathbf{X}$ é invertível:

$$\mathbf{A}_0\mathbf{X} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{X}) = \mathbf{I}_{k+1}.$$

$\mathbf{I}_{k+1}$ tem uma linha e uma coluna por coeficiente, incluindo o intercepto. A conclusão usa média condicional zero; não exige variância constante.

Comparação entre estimadores

Agora considere outro estimador linear $\widehat{\beta}^{\,a} = \mathbf{AY}$, com $\mathbf{A}$ dependendo apenas de $\mathbf{X}$. A mesma conta dá $E[\widehat{\beta}^{\,a} \mid \mathbf{X}] = \mathbf{AX}\beta$. Para não viés para todo β, $\mathbf{AX} = \mathbf{I}_{k+1}$.

Escreva $\mathbf{A} = \mathbf{A}_0 + \mathbf{C}$. Como $\mathbf{AX} = \mathbf{A}_0\mathbf{X} = \mathbf{I}_{k+1}$, segue $\mathbf{CX} = \mathbf{0}$. Transpondo e usando $\mathbf{A}_0 = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$:

$$\mathbf{X}'\mathbf{C}' = (\mathbf{CX})' = \mathbf{0}, \qquad \mathbf{A}_0\mathbf{C}' = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{C}' = \mathbf{0}.$$

$$\begin{aligned} \mathrm{V}(\mathbf{AY} \mid \mathbf{X}) &= \sigma^2(\mathbf{A}_0 + \mathbf{C})(\mathbf{A}_0 + \mathbf{C})' \\ &= \sigma^2\mathbf{A}_0\mathbf{A}_0' + \sigma^2\mathbf{CC}'. \end{aligned}$$

A parcela adicional tem variância não negativa

Para qualquer vetor $\mathbf{a}$ de pesos dos coeficientes,

$$\mathrm{V}(\mathbf{a}'\mathbf{AY} \mid \mathbf{X}) - \mathrm{V}(\mathbf{a}'\widehat{\beta} \mid \mathbf{X}) = \sigma^2(\mathbf{C}'\mathbf{a})'(\mathbf{C}'\mathbf{a}) \geq 0.$$

Exemplo: variância da inclinação

Com intercepto e um preditor, $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$. Considere outro estimador linear e não viesado $\widehat{\beta}^{\,a} = \mathbf{AY}$, com $\mathbf{AX} = \mathbf{I}_2$.

Para comparar apenas a inclinação, escolha os pesos dos coeficientes:

$$\mathbf{a} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \qquad \mathbf{a}'\widehat{\beta}^{\,a} = \widehat{\beta}_1^{a}, \qquad \mathbf{a}'\widehat{\beta} = \widehat{\beta}_1.$$

A desigualdade do slide anterior se torna

$$\mathrm{V}(\widehat{\beta}_1^{a} \mid \mathbf{X}) - \mathrm{V}(\widehat{\beta}_1 \mid \mathbf{X}) = \sigma^2(\mathbf{C}'\mathbf{a})'(\mathbf{C}'\mathbf{a}) \geq 0.$$

Logo, a inclinação de MQO tem variância condicional menor ou igual. $\mathbf{A}$ define o estimador; $\mathbf{a} = (0, 1)'$ seleciona a inclinação.

Monte Carlo: tamanho da amostra

Mesmo processo gerador: $Y = 5 + 1{,}5X + \varepsilon$, com $\sigma = 2$.

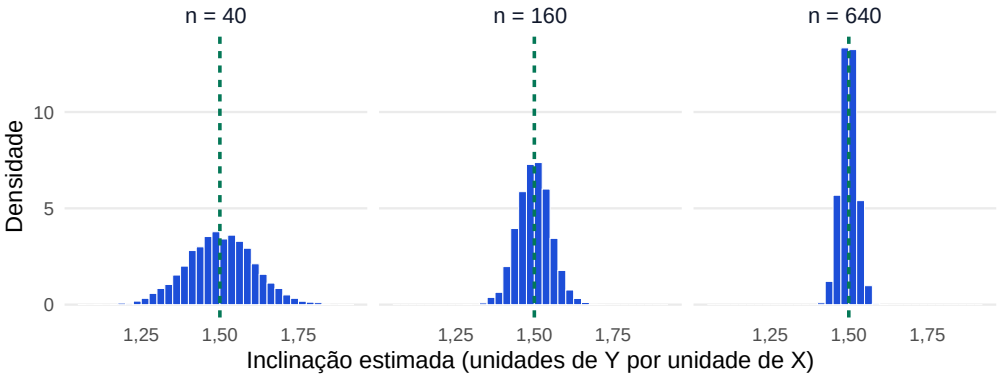


Figura 4: Distribuições de inclinações em 5.000 amostras independentes por tamanho n. Mesmos eixos e mesma largura de classe nos três painéis. A linha tracejada marca beta = 1,5. Fonte: simulação com X normal e erro independente.

Desvios-padrão: $0{,}107$ ($n = 40$), $0{,}053$ ($n = 160$) e $0{,}026$ ($n = 640$). A redução da dispersão ilustra a consistência demonstrada anteriormente.

Parâmetro da regra e coeficiente do BLP

Agora, $Y = 5 + 1{,}5X + u$, com $u = 0{,}8(X - 10) + v$ e $E[v \mid X] = 0$.

$$E[u \mid X] = 0{,}8(X - 10), \qquad Y = -3 + 2{,}3X + v.$$



Figura 5: Inclinações em 5.000 amostras por n da nova regra geradora. A linha pontilhada marca 1,5 e a tracejada marca o coeficiente do BLP, 2,3. Fonte: dados sintéticos, com X normal e v independente.

O MQO é consistente para o BLP, cujo coeficiente é $2{,}3$. u é o erro da regra original. O erro da projeção linear é $\varepsilon = v$. Recuperar o parâmetro $1{,}5$ da regra original exige condições adicionais.

Monte Carlo e bootstrap

Monte Carlo

Conhecemos a população e a regra geradora.

Geramos novas amostras independentes e calculamos o estimador em cada uma.

Podemos comparar as estimativas com o parâmetro conhecido.

Bootstrap

Temos uma amostra observada da população.

Reamostramos suas unidades e calculamos o estimador em cada reamostra.

Usamos a distribuição empírica como aproximação da população.

O bootstrap aplica a lógica do plug-in à distribuição amostral do estimador.

Bootstrap de pares

Cada unidade é um par (X_i, Y_i). Para uma amostra de n unidades:

1. Sorteamos n pares da amostra, com reposição.
2. Ajustamos o MQO e guardamos a inclinação $\hat{\beta}^{*(b)}$.
3. Repetimos o procedimento B vezes.
4. Calculamos o desvio-padrão das B inclinações.

Estimativa bootstrap do erro-padrão

$$\widehat{\mathrm{EP}}_{\mathrm{boot}}(\hat{\beta}) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}\left(\hat{\beta}^{*(b)} - \overline{\hat{\beta}^{*}}\right)^2}, \qquad \overline{\hat{\beta}^{*}} = \frac{1}{B}\sum_{b=1}^{B}\hat{\beta}^{*(b)}.$$

O asterisco identifica uma estimativa em reamostra. O bootstrap de pares usual pressupõe unidades i.i.d. e condições de regularidade. O sorteio mantém X_i e Y_i da mesma unidade juntos.

Distribuição bootstrap

Usamos a primeira amostra de 40 pares, com $\hat{\beta} = 1{,}514$, e fazemos $B = 5.000$ reamostras.

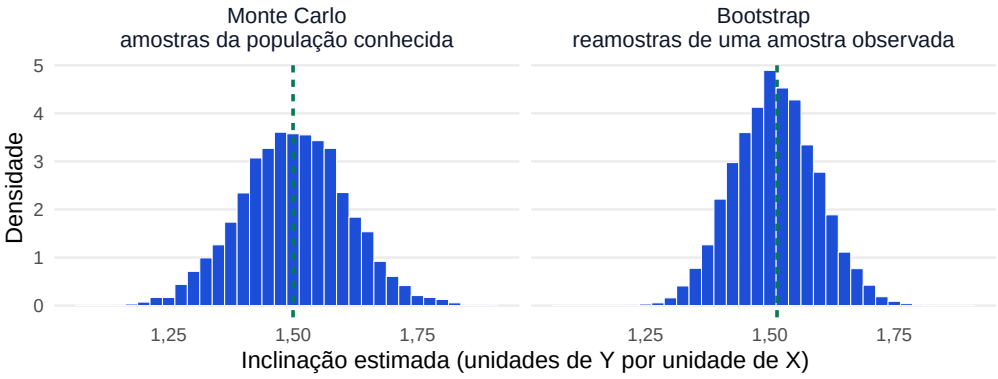


Figura 6: Monte Carlo com 5.000 novas amostras (esquerda) e bootstrap com 5.000 reamostras de uma única amostra (direita). A linha tracejada marca beta = 1,5 à esquerda e a estimativa original à direita. Fonte: dados sintéticos.

Dispersão Monte Carlo: $0{,}107$. Erro-padrão bootstrap: $0{,}084$. O bootstrap aproxima a incerteza usando a amostra disponível. O erro-padrão bootstrap também é uma estimativa e varia entre amostras.

Síntese

- O viés compara a esperança do estimador com o parâmetro. O EQM combina viés ao quadrado e variância amostral.
- A consistência descreve a aproximação ao parâmetro conforme n cresce. Para o BLP, amostragem i.i.d., segundos momentos finitos e matriz populacional invertível formam um conjunto de hipóteses suficientes para a consistência.
- A média condicional zero permite demonstrar o não viés do MQO. Sob as hipóteses da versão clássica de Gauss–Markov, o MQO tem a menor variância entre estimadores lineares não viesados.
- O bootstrap usa a distribuição empírica para aproximar a distribuição amostral e estimar o erro-padrão.

Na próxima aula: análise de resíduos e diagnóstico do modelo.

Leituras

Leituras previstas no programa

Aronow, Peter M., e Benjamin T. Miller. 2019. *Foundations of Agnostic Statistics*. Cambridge University Press. Capítulo 3, seção 3.2.2: teoria da estimação, pp. 102–105.

Hansen, Bruce E. 2022. *Econometrics*. Princeton University Press. Capítulo 4, seções 4.4–4.8: modelo linear, esperança e variância do MQO, momentos incondicionais e Gauss–Markov. Capítulo 7, seção 7.2: consistência do MQO.

Complemento para a introdução ao bootstrap

Aronow e Miller, capítulo 3, seção 3.4.3, pp. 130–132.

As figuras usam dados sintéticos. As aproximações de Monte Carlo e bootstrap usam 5.000 repetições por cenário. Os resultados teóricos dependem das condições indicadas nos slides.