Aula 7: propriedades do estimador de MQO

Distribuição amostral, viés, consistência, Gauss–Markov e bootstrap

FLS 6183 - Métodos Quantitativos de Pesquisa II

14 de outubro de 2026

BLP e MQO

Na população, $\mathbf{x} = (1, X_1, \ldots, X_k)'$ e $\beta = (\alpha, \beta_1, \ldots, \beta_k)'$:

$$Y = \mathbf{x}'\beta + \varepsilon, \qquad E[\mathbf{x}\varepsilon] = \mathbf{0}, \qquad \beta = E[\mathbf{x}\mathbf{x}']^{-1}E[\mathbf{x}Y].$$

Na amostra, $\mathbf{X}$ tem as linhas $\mathbf{x}_i'$ e $\mathbf{Y} = (Y_1, \ldots, Y_n)'$:

$$\widehat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}, \qquad \widehat{\mathbf{e}} = \mathbf{Y} - \mathbf{X}\widehat{\beta}.$$

Estimador e estimativa

$\widehat{\beta}$ é uma função da amostra aleatória. Cada amostra observada produz uma estimativa dos mesmos coeficientes populacionais.

Nova amostra, nova reta

População conhecida: $X \sim N(10, 3^2)$, $\varepsilon \sim N(0, 2^2)$ independente de X, $Y = 5 + 1{,}5X + \varepsilon$.

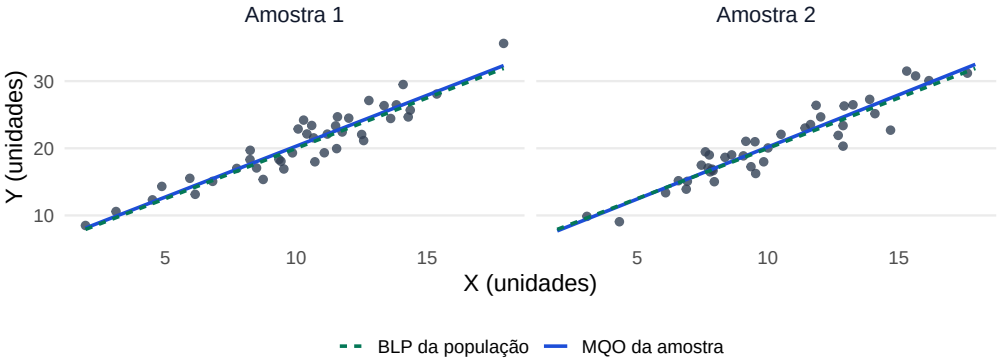


Figura 1: Duas amostras independentes de 40 pares (X,Y) da mesma população. A linha contínua é o MQO da amostra e a tracejada é o BLP populacional. Fonte: dados sintéticos do processo descrito.

Inclinações estimadas: $1{,}514$ e $1{,}552$. O coeficiente populacional é $\beta = 1{,}5$.

Distribuição amostral

Repetimos a amostragem e o ajuste de MQO 5.000 vezes, sempre com $n = 40$.

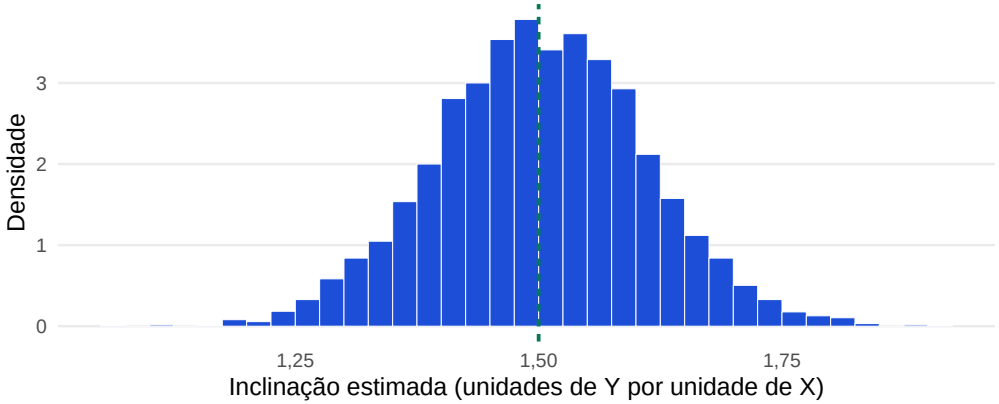


Figura 2: Histograma em escala de densidade de 5.000 inclinações de MQO. Cada valor vem de uma amostra independente de tamanho 40. A linha tracejada marca beta = 1,5. Fonte: simulação da população conhecida.

A média das estimativas, $1{,}502$, aproxima $E[\hat{\beta}]$. O desvio-padrão, $0{,}107$, aproxima a dispersão amostral.

Amostras pequenas e não viés

Mesmo processo gerador, com $\beta = 1{,}5$. Repetimos o MQO 5.000 vezes para cada n.

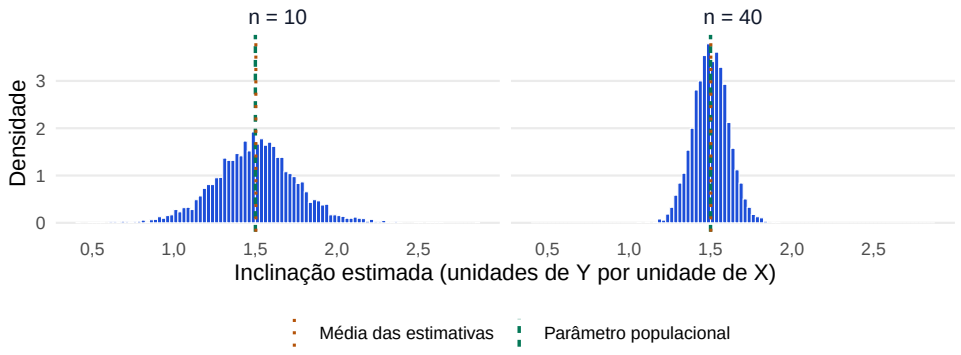


Figura 3: Distribuições de 5.000 inclinações por tamanho de amostra, com eixos e largura de classe comuns. A linha tracejada marca o parâmetro 1,5 e a pontilhada, a média das estimativas. Fonte: simulação da mesma população conhecida.

Médias: $1{,}503$ ($n = 10$) e $1{,}502$ ($n = 40$). Desvios-padrão: $0{,}254$ e $0{,}107$.

Com $n = 10$, há maior dispersão individual e a média das repetições fica próxima de $1{,}5$.

Viés do estimador

Para explicitar o tamanho da amostra, escrevemos $\hat{\beta}_n$:

$$\boxed{\text{Viés}_n(\hat{\beta}_n) = E[\hat{\beta}_n] - \beta.}$$

A esperança considera todas as amostras possíveis de tamanho n da mesma população.

Não viés para um tamanho de amostra fixo

$E[\hat{\beta}_n] = \beta$. A definição usa a distribuição amostral do estimador e não exige tomar o limite quando n cresce.

Erro de uma estimativa observada

Na primeira amostra, $\hat{\beta} - \beta = 1{,}514 - 1{,}5$. Essa diferença é o erro de estimação daquela amostra. O viés descreve sua média na distribuição amostral.

Variância e erro quadrático médio

A variância amostral descreve a dispersão do estimador:

$$\mathrm{V}(\hat{\beta}_n) = E\Big[(\hat{\beta}_n - E[\hat{\beta}_n])^2\Big] .$$

O erro quadrático médio (EQM) considera a distância ao parâmetro:

$$\boxed{\mathrm{EQM}(\hat{\beta}_n) = E[(\hat{\beta}_n - \beta)^2] = \mathrm{V}(\hat{\beta}_n) + \mathrm{Viés}_n(\hat{\beta}_n)^2.}$$

Não viés e precisão

Quando o viés é zero, o EQM é igual à variância amostral. Um estimador não viesado ainda pode produzir estimativas muito dispersas.

O desvio-padrão da distribuição amostral, $\sqrt{\mathrm{V}(\hat{\beta}_n)}$, é o erro-padrão do estimador.

Consistência

$\hat{\beta}_n$ é consistente para β se, para todo $\delta > 0$,

$$\boxed{\Pr(|\hat{\beta}_n - \beta| > \delta) \longrightarrow 0 \quad \text{quando } n \longrightarrow \infty.}$$

Escrevemos $\hat{\beta}_n \xrightarrow{p} \beta$: convergência em probabilidade.

O papel de n

Consistência descreve uma sequência de estimadores conforme a amostra cresce. Não viés descreve a esperança do estimador para um n fixo.

Exemplo com Y_i i.i.d., $E[Y_i] = \mu \neq 0$ e $0 < \mathrm{V}(Y_i) < \infty$:

Estimador de μ	Não viesado	Consistente
Y_1, qualquer que seja n	Sim	Não
$\frac{n}{n+1}\bar{Y}$	Não	Sim

Calcular MQO na amostra

Com dados observados finitos, o MQO minimiza

$$S(\mathbf{b}) = (\mathbf{Y} - \mathbf{X}\mathbf{b})'(\mathbf{Y} - \mathbf{X}\mathbf{b}).$$

Condição para coeficientes únicos

$\mathbf{X}$ tem posto completo: suas $k+1$ colunas são linearmente independentes. Assim, $\mathbf{X}'\mathbf{X}$ tem inversa e

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

Independência não é exigida para calcular

Podemos calcular o MQO com observações dependentes ou de distribuições distintas. Segundos momentos populacionais finitos também não são uma exigência desse cálculo.

Sem posto completo, o problema de minimização tem soluções, mas os coeficientes não são únicos.

Consistência do MQO

Para o alvo populacional $\mathbf{Q} = E[\mathbf{x}\mathbf{x}']$ invertível e $\mathbf{q} = E[\mathbf{x}Y]$, escreva

$$\hat{\beta} = \widehat{\mathbf{Q}}_n^{-1}\hat{\mathbf{q}}_n, \qquad \widehat{\mathbf{Q}}_n = \frac{1}{n}\sum_i \mathbf{x}_i\mathbf{x}_i', \quad \hat{\mathbf{q}}_n = \frac{1}{n}\sum_i \mathbf{x}_i Y_i.$$

Se os momentos amostrais convergem para esses momentos populacionais,

$$\widehat{\mathbf{Q}}_n \xrightarrow{p} \mathbf{Q}, \qquad \hat{\mathbf{q}}_n \xrightarrow{p} \mathbf{q}, \quad \text{então} \quad \boxed{\hat{\beta} \xrightarrow{p} \mathbf{Q}^{-1}\mathbf{q} = \beta.}$$

Um conjunto de hipóteses suficientes

Amostragem i.i.d. e segundos momentos finitos de Y e dos preditores permitem essas convergências pela lei dos grandes números. A convergência também pode ocorrer sob dependência ou distribuições distintas, com condições próprias.

A inversão e a multiplicação são contínuas quando a matriz limite tem inversa.

Média condicional do erro

Erro do BLP

$$E[\mathbf{x}\varepsilon] = \mathbf{0}.$$

Ortogonalidade por construção: as condições de primeira ordem da projeção linear.

Condição adicional

$$E[\varepsilon \mid \mathbf{x}] = 0.$$

A esperança condicional de Y é linear: $E[Y \mid \mathbf{x}] = \mathbf{x}'\beta$.

Média condicional zero implica ortogonalidade, pela lei da esperança iterada. A implicação inversa não vale em geral.

Exemplo

Se $X \sim N(0,1)$ e $\varepsilon = X^2 - 1$, $E[\varepsilon] = E[X\varepsilon] = 0$, mas $E[\varepsilon \mid X] = X^2 - 1$.

Não viés do MQO

Sob amostragem i.i.d. e média condicional zero, $E[\varepsilon \mid \mathbf{X}] = \mathbf{0}$, com $\varepsilon = (\varepsilon_1, \ldots, \varepsilon_n)'$.

Substituindo $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$:

$$\widehat{\beta} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon.$$

Ao condicionar em $\mathbf{X}$, a matriz dos preditores fica fixa:

$$E[\widehat{\beta} \mid \mathbf{X}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \underbrace{E[\varepsilon \mid \mathbf{X}]}_{\mathbf{0}} = \beta.$$

Esperança na distribuição amostral

Com posto completo e momentos do estimador existentes, $E[\widehat{\beta}] = \beta$ pela lei da esperança iterada. O resultado vale para n fixo. A homocedasticidade não é necessária para esse não viés.

Variância do MQO

Com média condicional zero e observações independentes, defina $\mathbf{D} = \mathrm{V}(\varepsilon \mid \mathbf{X}) = \mathrm{diag}(\sigma_1^2, \ldots, \sigma_n^2)$, onde $\sigma_i^2 = \mathrm{V}(\varepsilon_i \mid \mathbf{x}_i)$.

$$\mathrm{V}(\widehat{\beta} \mid \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{D}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}.$$

Homocedasticidade

Se $\sigma_i^2 = \sigma^2$ para todas as observações, $\mathbf{D} = \sigma^2\mathbf{I}_n$ e

$$\boxed{\mathrm{V}(\widehat{\beta} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}.}$$

Com um preditor e intercepto, $\mathrm{V}(\widehat{\beta} \mid \mathbf{X}) = \sigma^2 / \sum_i (X_i - \bar{X})^2$. Maior ruído aumenta a variância. Maior variação do preditor reduz a variância.

Teorema de Gauss–Markov

Considere $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$, com posto completo,

$$E[\varepsilon \mid \mathbf{X}] = \mathbf{0}, \qquad \mathrm{V}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n.$$

Versão clássica

O MQO tem a menor variância entre os estimadores lineares em $\mathbf{Y}$ e não viesados condicionalmente em $\mathbf{X}$.

- Linear em $\mathbf{Y}$: $\hat{\beta}^{\,a} = \mathbf{A}\mathbf{Y}$, com $\mathbf{A}$ dependendo apenas de $\mathbf{X}$.
- Não viés para todo β: $E[\hat{\beta}^{\,a} \mid \mathbf{X}] = \beta$.
- A comparação vale para cada coeficiente e para qualquer combinação linear dos coeficientes.

BLUE: *best linear unbiased estimator*, ou melhor estimador linear não viesado. O teorema dispensa a normalidade dos erros.

Comparação entre estimadores

O MQO usa $\mathbf{A}_0 = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$. Um estimador alternativo $\mathbf{AY}$ é não viesado para todo β quando $\mathbf{AX} = \mathbf{I}_{k+1}$.

Escreva $\mathbf{A} = \mathbf{A}_0 + \mathbf{C}$. Então $\mathbf{CX} = \mathbf{0}$ e $\mathbf{A}_0\mathbf{C}' = \mathbf{0}$.

$$\begin{aligned} \mathrm{V}(\mathbf{AY} \mid \mathbf{X}) &= \sigma^2(\mathbf{A}_0 + \mathbf{C})(\mathbf{A}_0 + \mathbf{C})' \\ &= \sigma^2\mathbf{A}_0\mathbf{A}_0' + \sigma^2\mathbf{C}\mathbf{C}'. \end{aligned}$$

A parcela adicional tem variância não negativa

Para qualquer vetor $\mathbf{a}$ de pesos dos coeficientes,

$$\mathrm{V}(\mathbf{a}'\mathbf{AY} \mid \mathbf{X}) - \mathrm{V}(\mathbf{a}'\widehat{\beta} \mid \mathbf{X}) = \sigma^2(\mathbf{C}'\mathbf{a})'(\mathbf{C}'\mathbf{a}) \geq 0.$$

Monte Carlo: tamanho da amostra

Mesmo processo gerador: $Y = 5 + 1{,}5X + \varepsilon$, com $\sigma = 2$.

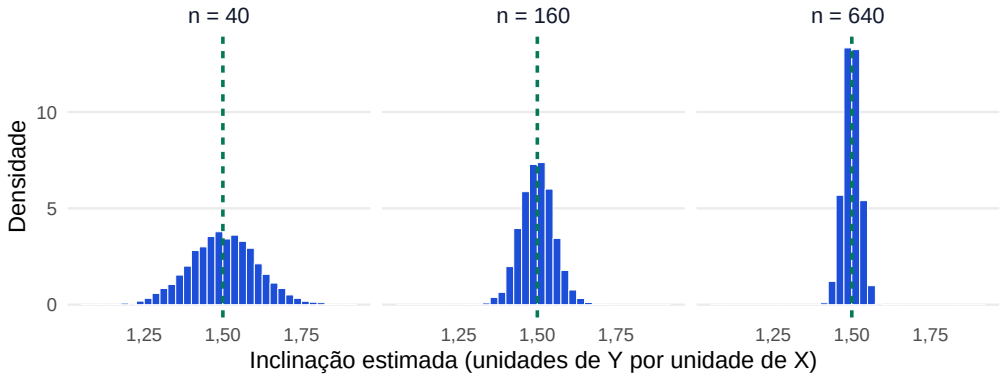


Figura 4: Distribuições de inclinações em 5.000 amostras independentes por tamanho n. Mesmos eixos e mesma largura de classe nos três painéis. A linha tracejada marca beta = 1,5. Fonte: simulação com X normal e erro independente.

Desvios-padrão: $0{,}107$ ($n = 40$), $0{,}053$ ($n = 160$) e $0{,}026$ ($n = 640$). A redução da dispersão ilustra a consistência demonstrada anteriormente.

Monte Carlo: ruído e heterocedasticidade

Nos três cenários, $n = 40$ e $E[\varepsilon \mid X] = 0$. No terceiro, $\mathrm{V}(\varepsilon \mid X) = 2[1 + ((X - 10)/3)^2]$.

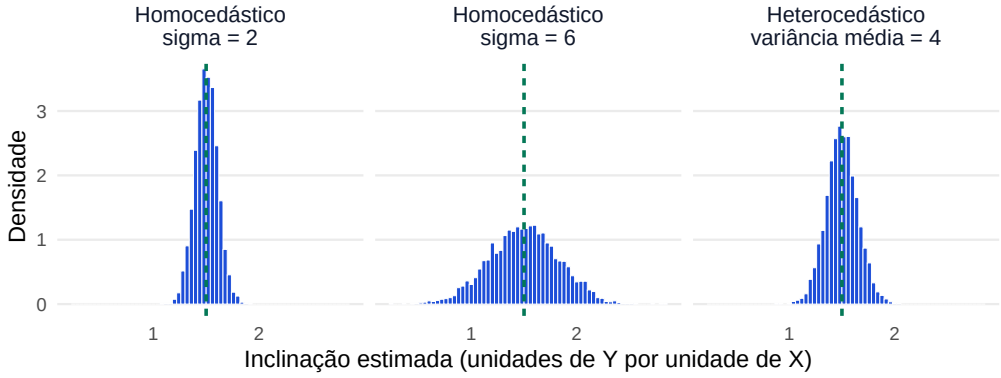


Figura 5: Distribuições de 5.000 inclinações por cenário, com eixos comuns. Nos painéis 1 e 3, a variância incondicional do erro é 4. No painel 2, é 36. A linha tracejada marca beta = 1,5. Fonte: simulação do mesmo BLP.

Desvios-padrão: $0{,}107$, $0{,}330$ e $0{,}149$. O MQO continua não viesado nos três cenários. Com heterocedasticidade, a garantia clássica de Gauss–Markov deixa de se aplicar.

Parâmetro da regra e coeficiente do BLP

Agora, $Y = 5 + 1{,}5X + u$, com $u = 0{,}8(X - 10) + v$ e $E[v \mid X] = 0$.

$$E[u \mid X] = 0{,}8(X - 10), \qquad Y = -3 + 2{,}3X + v.$$



Figura 6: Inclinações em 5.000 amostras por n da nova regra geradora. A linha pontilhada marca 1,5 e a tracejada marca o coeficiente do BLP, 2,3. Fonte: dados sintéticos, com X normal e v independente.

O MQO é consistente para o BLP, cujo coeficiente é $2{,}3$. u é o erro da regra original. O erro da projeção linear é $\varepsilon = v$. Recuperar o parâmetro $1{,}5$ da regra original exige condições adicionais.

Monte Carlo e bootstrap

Monte Carlo

Conhecemos a população e a regra geradora.

Geramos novas amostras independentes e calculamos o estimador em cada uma.

Podemos comparar as estimativas com o parâmetro conhecido.

Bootstrap

Temos uma amostra observada da população.

Reamostramos suas unidades e calculamos o estimador em cada reamostra.

Usamos a distribuição empírica como aproximação da população.

O bootstrap aplica a lógica do plug-in à distribuição amostral do estimador.

Bootstrap de pares

Cada unidade é um par (X_i, Y_i). Para uma amostra de n unidades:

1. Sorteamos n pares da amostra, com reposição.
2. Ajustamos o MQO e guardamos a inclinação $\hat{\beta}^{*(b)}$.
3. Repetimos o procedimento B vezes.
4. Calculamos o desvio-padrão das B inclinações.

Estimativa bootstrap do erro-padrão

$$\widehat{\mathrm{EP}}_{\mathrm{boot}}(\hat{\beta}) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}\left(\hat{\beta}^{*(b)} - \overline{\hat{\beta}^{*}}\right)^2}, \qquad \overline{\hat{\beta}^{*}} = \frac{1}{B}\sum_{b=1}^{B}\hat{\beta}^{*(b)}.$$

O asterisco identifica uma estimativa em reamostra. O bootstrap de pares usual pressupõe unidades i.i.d. e condições de regularidade. O sorteio mantém X_i e Y_i da mesma unidade juntos.

Distribuição bootstrap

Usamos a primeira amostra de 40 pares, com $\hat{\beta} = 1{,}514$, e fazemos $B = 5.000$ reamostras.

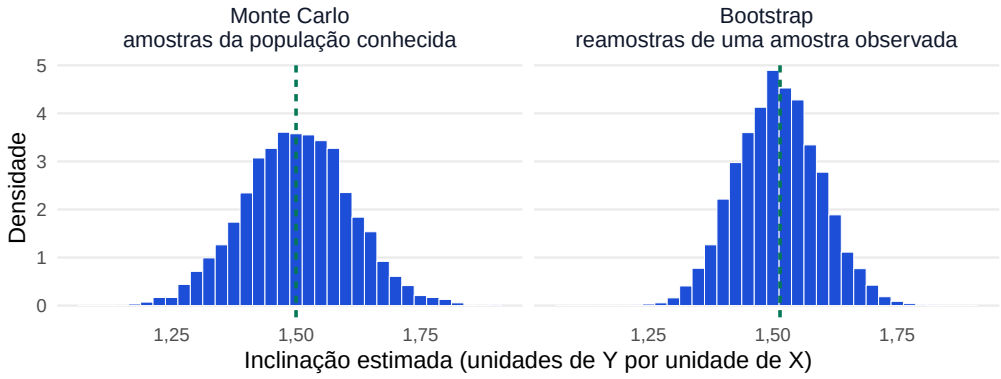


Figura 7: Monte Carlo com 5.000 novas amostras (esquerda) e bootstrap com 5.000 reamostras de uma única amostra (direita). A linha tracejada marca beta = 1,5 à esquerda e a estimativa original à direita. Fonte: dados sintéticos.

Dispersão Monte Carlo: $0{,}107$. Erro-padrão bootstrap: $0{,}084$. O bootstrap aproxima a incerteza usando a amostra disponível. O erro-padrão bootstrap também é uma estimativa e varia entre amostras.

Síntese

- O viés compara a esperança do estimador com o parâmetro. O EQM combina viés ao quadrado e variância amostral.
- A consistência descreve a aproximação ao parâmetro conforme n cresce. Para o BLP, amostragem i.i.d., segundos momentos finitos e matriz populacional invertível formam um conjunto de hipóteses suficientes para a consistência.
- A média condicional zero permite demonstrar o não viés do MQO. A homocedasticidade acrescenta a garantia clássica de eficiência entre estimadores lineares não viesados.
- O bootstrap usa a distribuição empírica para aproximar a distribuição amostral e estimar o erro-padrão.

Na próxima aula: análise de resíduos e diagnóstico do modelo.

Leituras

Leituras previstas no programa

Aronow, Peter M., e Benjamin T. Miller. 2019. *Foundations of Agnostic Statistics*. Cambridge University Press. Capítulo 3, seção 3.2.2: teoria da estimação, pp. 102–105.

Hansen, Bruce E. 2022. *Econometrics*. Princeton University Press. Capítulo 4, seções 4.4–4.8: modelo linear, esperança e variância do MQO, momentos incondicionais e Gauss–Markov. Capítulo 7, seção 7.2: consistência do MQO.

Complemento para a introdução ao bootstrap

Aronow e Miller, capítulo 3, seção 3.4.3, pp. 130–132.

As figuras usam dados sintéticos. As aproximações de Monte Carlo e bootstrap usam 5.000 repetições por cenário. Os resultados teóricos dependem das condições indicadas nos slides.