Aula 8: resíduos e diagnóstico do modelo

CEF, projeção linear, diagnóstico e previsão

FLS 6183 - Métodos Quantitativos de Pesquisa II

21 de outubro de 2026

Finalidade do diagnóstico

Um diagnóstico informa se a análise sustenta o resultado que queremos produzir.

Tabela 1: Objetivo da análise e pergunta de diagnóstico

Objetivo	Pergunta relevante
Prever Y	As previsões funcionam para novas observações?
Resumir uma relação	A projeção linear é um resumo útil? De quais observações depende?
Quantificar incerteza	Os erros-padrão acomodam a dispersão e a dependência dos dados?

O mesmo padrão nos resíduos pode ter consequências diferentes para cada objetivo.

Erro populacional e resíduo amostral

Na representação $Y_i = \mathbf{x}_i'\beta + \varepsilon_i$:

$$\underbrace{\varepsilon_i = Y_i - \mathbf{x}_i'\beta}_{\text{erro populacional}}, \qquad \underbrace{\widehat{e}_i = Y_i - \mathbf{x}_i'\widehat{\beta}}_{\text{resíduo amostral}}.$$

β é o vetor de parâmetros populacionais; $\mathbf{x}_i'\beta$ é o valor previsto com esses parâmetros.

O que observamos e o que calculamos

Observamos Y_i e $\mathbf{x}_i$. Em geral, o parâmetro populacional β é desconhecido, por isso não podemos calcular o erro ε_i.

Depois de estimar $\widehat{\beta}$, calculamos o resíduo $\widehat{e}_i$ com os dados observados e os coeficientes estimados.

Se β é conhecido, o erro é calculável. Isso ocorre em simulações com parâmetros conhecidos e na projeção linear de uma população finita inteiramente observada em um censo.

Por que o resíduo difere do erro?

Substituímos $Y_i = \mathbf{x}_i'\beta + \varepsilon_i$ na definição do resíduo:

$$\begin{aligned}\widehat{e}_i &= Y_i - \mathbf{x}_i'\widehat{\beta} \\ &= \mathbf{x}_i'\beta + \varepsilon_i - \mathbf{x}_i'\widehat{\beta} \\ &= \varepsilon_i - \mathbf{x}_i'(\widehat{\beta} - \beta).\end{aligned}$$

A diferença vem da estimação dos coeficientes

O resíduo incorpora o termo $-\mathbf{x}_i'(\widehat{\beta} - \beta)$. Se conhecêssemos β, poderíamos calcular o erro. Se $\widehat{\beta} = \beta$, resíduos e erros coincidiriam.

A identidade vale também quando β é o coeficiente do BLP. Ela não exige uma CEF linear.

Erro no BLP

A minimização do EQM populacional define o coeficiente e o erro de projeção:

$$\beta = \arg\min_{\mathbf{b}} E[(Y - \mathbf{x}'\mathbf{b})^2], \qquad \varepsilon_i = Y_i - \mathbf{x}_i'\beta.$$

Esse erro soma o erro da CEF u_i à diferença entre a CEF e o BLP:

$$\varepsilon_i = \underbrace{Y_i - m(\mathbf{x}_i)}_{u_i} + \underbrace{m(\mathbf{x}_i) - \mathbf{x}_i'\beta}_{\text{erro de aproximação}}.$$

Propriedade do erro de projeção

$E[\mathbf{x}_i\varepsilon_i] = \mathbf{0}$, mas $E[\varepsilon_i \mid \mathbf{x}_i]$ pode ser diferente de zero. Se a CEF é linear na especificação escolhida, o erro do BLP coincide com o erro da CEF.

MQO minimiza o critério na amostra, estima β e produz os resíduos $\widehat{e}_i = Y_i - \mathbf{x}_i'\widehat{\beta}$.

Hansen, seção 2.18: definição populacional do BLP e do erro de projeção.

Propriedades por construção

Com intercepto e MQO, as equações normais garantem, para cada regressor incluído:

$$\sum_{i=1}^{n} \hat{e}_i = 0, \qquad \sum_{i=1}^{n} X_{ij}\hat{e}_i = 0.$$

Essas igualdades valem mesmo quando a CEF tem outra forma.

O que é zero por construção

Regredir os resíduos nos mesmos regressores produz valores ajustados zero. Isso não garante média condicional zero dos resíduos: uma suavização pode revelar curvatura.

Essas identidades amostrais não testam $E[\varepsilon_i \mid \mathbf{x}_i] = 0$.

Curvatura na esperança condicional

Exemplo sintético: $X \sim U[-2, 2]$, $u \sim N(0, 0{,}6^2)$ independente de X e

$$Y = 2 + 1{,}5X - 0{,}8(X^2 - 4/3) + u.$$

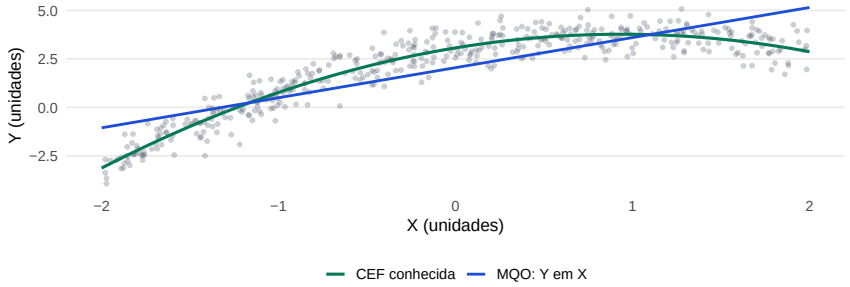


Figura 1: CEF quadrática (verde) e MQO simples estimado na amostra (azul). Fonte: 450 observações sintéticas.

Aqui, $E[X^2] = 4/3$ e $\mathrm{Cov}(X, X^2) = 0$ dão BLP $2 + 1{,}5X$. Esses coeficientes foram preservados por construção. Em geral, não basta retirar o termo quadrático da CEF para obter o BLP.

Curvatura nos resíduos

Usamos os resíduos da regressão simples do exemplo anterior.

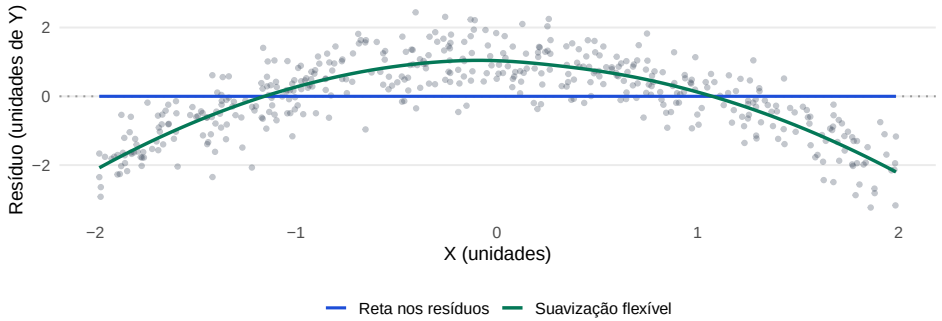


Figura 2: Resíduos contra X, com reta de MQO e suavização local (loess). A reta horizontal decorre das equações normais. A curva mostra a estrutura que o modelo simples deixou nos resíduos. Fonte: mesmos 450 dados sintéticos.

Interpretação

A curvatura indica uma aproximação incompleta da CEF. O coeficiente do BLP continua definido.

Consequências da curvatura

- **Previsão:** o modelo pode errar sistematicamente em regiões de X. Uma especificação mais flexível precisa ser avaliada em novos dados.
- **Resumo linear:** o coeficiente continua resumindo a relação na população e no suporte considerados.

Linearidade nos coeficientes

$Y = \alpha + \beta_1 X + \beta_2 X^2 + \varepsilon$ continua sendo uma regressão linear nos coeficientes. Termos quadráticos, splines e interações permitem maior flexibilidade.

Heterocedasticidade

Agora a CEF é linear: $Y = 1 + 1{,}5X + u$, com $X \sim U[0, 4]$, $u = (0{,}25 + 0{,}5X)Z$ e $Z \sim N(0, 1)$ independente de X.

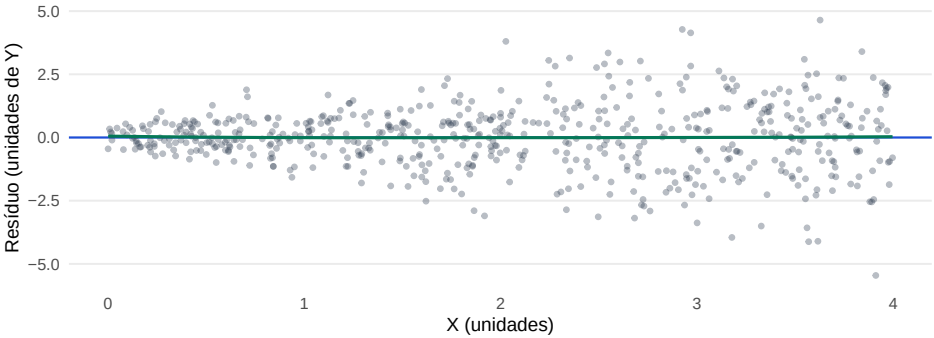


Figura 3: Resíduos em 600 observações sintéticas. A variância do erro aumenta com X; a CEF permanece linear. A linha verde é uma suavização local e a azul marca zero. Fonte: processo gerador descrito.

A mudança da dispersão e a curvatura da média são aspectos diferentes do diagnóstico.

Heterocedasticidade: o caso geral

A formulação geral permite que a variância do erro dependa dos regressores:

$$\mathrm{Var}(\varepsilon_i \mid \mathbf{x}_i) = \sigma^2(\mathbf{x}_i).$$

A homocedasticidade é o caso particular em que $\sigma^2(\mathbf{x}_i) = \sigma^2$ para todos os valores dos regressores.

Consequência para os erros-padrão

Os erros-padrão convencionais usam a hipótese de variância constante. Com heterocedasticidade, podem subestimar ou superestimar a incerteza dos coeficientes.

- Erros-padrão robustos à heterocedasticidade acomodam variâncias diferentes entre observações.
- Com observações independentes e condições usuais para amostras grandes, podem ser usados tanto com heterocedasticidade quanto com homocedasticidade.

Hansen, seções 4.13–4.15. Na aula 9: comparação entre erros-padrão convencionais, HC3 e bootstrap.

Da estimativa de MQO à matriz hat

Partimos da fórmula de MQO, com $\mathbf{X}'\mathbf{X}$ inversível:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

Substituímos $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$:

$$\begin{aligned}\hat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \varepsilon) \\ &= \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon.\end{aligned}$$

Multiplicando por $\mathbf{X}$, obtemos os valores ajustados:

$$\widehat{\mathbf{Y}} = \mathbf{X}\hat{\beta} = \mathbf{X}\beta + \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'}_{\mathbf{H}}\varepsilon.$$

A matriz $\mathbf{H}$ leva $\mathbf{Y}$ a $\widehat{\mathbf{Y}}$: $\widehat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$. Por isso é chamada de matriz *hat* ou matriz de projeção.

Alavancagem e variância dos resíduos

Defina a matriz de projeção e sua diagonal:

$$\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}', \qquad h_{ii} = \mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i.$$

h_{ii} mede o quanto a observação é incomum no conjunto dos regressores. Com $p = k + 1$ coeficientes, $0 \leq h_{ii} \leq 1$ e $\sum_i h_{ii} = p$.

Erros homocedásticos e não correlacionados

$$\mathrm{Var}(\varepsilon \mid \mathbf{X}) = \sigma^2\mathbf{I} \quad \Longrightarrow \quad \mathrm{Var}(\hat{e}_i \mid \mathbf{X}) = (1 - h_{ii})\sigma^2.$$

Mesmo com erros homocedásticos, os resíduos brutos podem ter variâncias diferentes.

Para $h_{ii} < 1$, dividir $\hat{e}_i$ por $\sqrt{1 - h_{ii}}$ corrige essa diferença de escala sob essas condições.

Hansen, seções 3.19 e 4.10. Alavancagem depende de todos os regressores, inclusive indicadoras.

Alavancagem e influência

Cada painel acrescenta um ponto aos mesmos 35 dados de base.

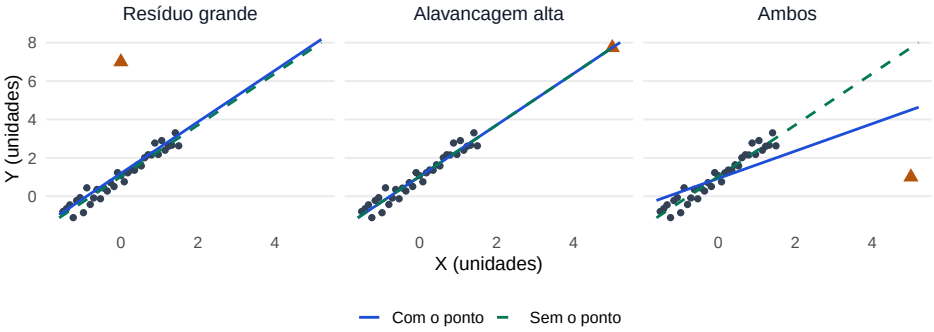


Figura 4: Triângulo: observação acrescentada. Linha contínua: ajuste com o ponto; tracejada: ajuste sem ele. Um resíduo grande e uma alavancagem alta podem ocorrer separadamente. Fonte: dados sintéticos, mesmos eixos nos painéis.

Uma observação é influente para um resultado quando sua retirada o altera de forma substantivamente relevante.

Sensibilidade a uma observação

A inclinação é medida em unidades de Y por unidade de X.

Tabela 2: Sensibilidade da inclinação nos exemplos sintéticos

Ponto acrescentado	h_{ii}	Resíduo	$\hat{\beta}_1 - \hat{\beta}_{1(-i)}$
Resíduo grande	0,028	5,809	0,000
Alavancagem alta	0,481	0,000	0,000
Ambos	0,481	−3,495	−0,629

O que investigar

Conferir registro e unidade de análise; compreender a observação; comparar os resultados com e sem ela e justificar a decisão substantiva.

Uma observação incomum pode conter informação relevante. Um limiar de diagnóstico não determina sua exclusão.

Hansen, seções 3.20–3.21. A influência depende do coeficiente ou previsão de interesse.

Dependência na ordem dos dados

Exemplo sintético: $Y_t = 2 + 1{,}5X_t + u_t$, com X_t independente do erro e $u_t = 0{,}8u_{t-1} + v_t$, $v_t \sim N(0, 1)$ independente ao longo do tempo.

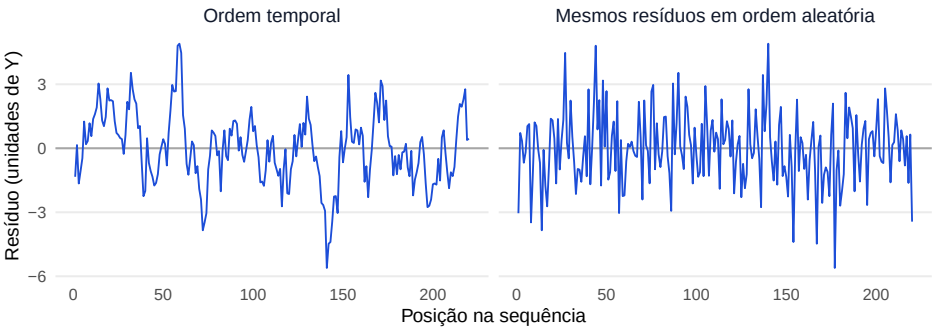


Figura 5: Mesmos 220 resíduos na ordem temporal e em uma ordem aleatória. Reordenar as linhas mantém o ajuste de MQO e pode ocultar a estrutura serial. Fonte: dados sintéticos.

Diagnósticos temporais e espaciais exigem uma ordem ou distância com significado. Um identificador numérico não constitui uma coordenada geográfica.

Dependência dos resíduos: exemplo com intercepto

Considere uma regressão apenas com intercepto, com erros independentes de média zero:

$$Y_i = \mu + \varepsilon_i.$$

MQO estima o intercepto pela média amostral:

$$\hat{\mu} = \bar{Y} = \mu + \bar{\varepsilon}.$$

Substituindo na definição do resíduo:

$$\begin{aligned} \hat{e}_i &= Y_i - \bar{Y} \\ &= (\mu + \varepsilon_i) - (\mu + \bar{\varepsilon}) \\ &= \varepsilon_i - \bar{\varepsilon}. \end{aligned}$$

A dependência é criada pelo ajuste

Todos os resíduos compartilham a mesma $\bar{\varepsilon}$ e somam zero. Com vários regressores, $\hat{\mathbf{e}} = (\mathbf{I} - \mathbf{H})\varepsilon$. Essa dependência, por si só, não exige erros-padrão agrupados.

Dependência nos erros e inferência

No exemplo $u_t = 0{,}8u_{t-1} + v_t$, um choque pode persistir por vários períodos. HC3 acomoda heterocedasticidade, mas não essa dependência serial.

Série temporal: erros-padrão HAC, como Newey–West

HAC significa consistentes sob heterocedasticidade e autocorrelação. Eles incorporam covariâncias entre períodos, sob condições de dependência fraca e amostras grandes. O ajuste de MQO é mantido; mudam os erros-padrão e os intervalos.

- **Ordem e defasagens:** ordene os dados pelo tempo. Escolha quantas defasagens considerar e examine a sensibilidade a essa escolha.
- **Outras estruturas:** com dependência dentro de grupos, use erros-padrão agrupados. Na reamostragem, use grupos inteiros ou blocos de períodos consecutivos.

Em R, para um modelo ajustado com os dados em ordem temporal, com seleção automática de defasagens:

```
sqrt(diag(sandwich::NeweyWest(m)))  # erros-padrão
```

Fonte: documentação de NeweyWest e vcovCL, pacote `sandwich`.

Aplicação: eleições de 2022

Retomamos a base da aula 7. Uma linha representa uma zona eleitoral.

Variáveis e comparação

Y_i: porcentagem de Lula no segundo turno. X_i: porcentagem de Lula no primeiro turno. Cada percentual usa todos os votos válidos do respectivo turno.

Comparamos os modelos $Y_i = \alpha + \beta_1 X_i + \varepsilon_i$ e

$$Y_i = \alpha + \beta_1 X_i + \sum_{g \neq AC} \gamma_g \, 1\{UF_i = g\} + \varepsilon_i.$$

Os gráficos usam as mesmas 2.636 zonas das 27 UFs, com peso igual no ajuste. A observação agregada do Exterior (ZZ) será examinada separadamente.

Objetivo descritivo e preditivo.

Fonte: dados TSE preservados e documentados para o laboratório da aula 7.

Resíduos e valores ajustados

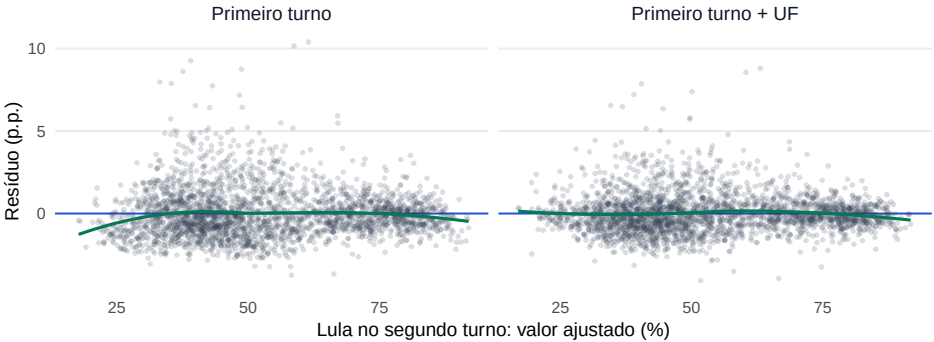


Figura 6: Resíduos dos dois modelos nas mesmas 2.636 zonas das 27 UFs, eleição de 2022. Azul: zero; verde: suavização local. Eixos comuns. Resíduos em pontos percentuais. Fonte: TSE, base preservada do curso.

Leitura do gráfico

Onde há regiões com resíduos predominantemente positivos ou negativos? Como a inclusão de UF altera a estrutura visível e a dispersão?

Magnitude dos resíduos

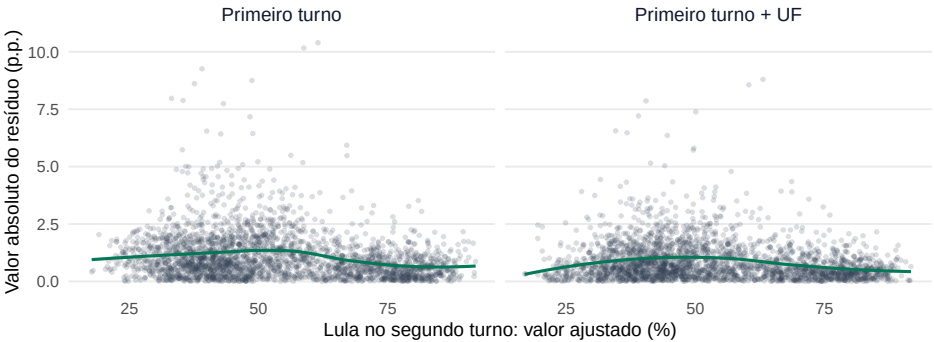


Figura 7: Valor absoluto dos resíduos contra os valores ajustados, nas mesmas zonas e modelos da figura anterior. Verde: suavização local. Eixos comuns; magnitudes em pontos percentuais. Fonte: TSE, eleição de 2022.

Uma mudança na magnitude dos resíduos pode refletir variância condicional variável e também erro de aproximação da média. A leitura conjunta dos dois gráficos ajuda a distinguir essas possibilidades.

Influência na inclinação eleitoral

Modelo com UF. Calculamos a inclinação novamente ao excluir cada zona.

Tabela 3: Quatro maiores mudanças absolutas na inclinação ao excluir uma zona

UF	Zona	h_{ii}	Resíduo (p.p.)	$\Delta\hat{\beta}_1$
CE	121	0,010	8,56	−0,00048
PA	91	0,016	−2,46	0,00040
CE	24	0,010	8,80	−0,00039
SP	1	0,004	3,84	0,00029

$\Delta\hat{\beta}_1 = \hat{\beta}_1 - \hat{\beta}_{1(-i)}$. Inclinação com todas as zonas: $1{,}0111$ p.p. de Y por 1 p.p. de X.

A relevância da mudança depende do uso do modelo. Uma zona pode ser importante para uma previsão específica e pouco importante para essa inclinação comum.

Exterior: ajuste perfeito de uma observação

Incluindo ZZ na regressão com categorias geográficas, há 2.637 linhas. Uma única observação pertence à categoria Exterior.

Consequência da indicadora exclusiva

O intercepto da categoria ajusta exatamente sua observação: $\hat{e}_{ZZ} \simeq 0$ e $h_{ZZ} = 1$. A variância do erro nessa categoria não pode ser estimada a partir de variação interna.

- O resíduo zero decorre da flexibilidade do ajuste para essa observação.
- As correções por $1 - h_{ii}$ ficam indefinidas nesse ponto; HC2, HC3 e exclusão da observação exigem cuidado.
- Nos gráficos anteriores usamos as 27 UFs para comparar modelos na mesma amostra. ZZ permanece preservada e explicitamente discutida.

Hansen, seção 4.16, sobre indicadoras raras. Ajuste perfeito não garante precisão para a previsão de outro ano.

Avaliação de novas zonas da mesma eleição

Divisão única, aleatória dentro de UF: 2121 zonas de treino e 515 de teste. As especificações foram fixadas antes da comparação.

Tabela 4: Erros de previsão em pontos percentuais, eleição de 2022

Modelo	REQM treino	REQM teste	EAM teste
Primeiro turno	1,51	1,39	1,04
Primeiro turno + UF	1,20	1,14	0,85
Primeiro turno + quadrado + UF	1,20	1,14	0,85

REQM: raiz do erro quadrático médio. EAM: erro absoluto médio. Cada zona tem peso igual.

Esta divisão avalia zonas reservadas de 2022. Uma única divisão tem variabilidade e pode aproveitar semelhanças entre zonas. Ela não avalia dependência espacial nem demonstra capacidade de transportar o modelo para 2026.

Diagnóstico e consequência para a análise

Tabela 5: Aspectos do diagnóstico e decisões pertinentes

Aspecto	Consequência a avaliar
Curvatura	Aproximação da CEF e previsão fora da amostra.
Dispersão variável	Estimação da variância e intervalos compatíveis com heterocedasticidade.
Dependência	Unidade de informação, grupos e ordem temporal ou espacial.
Influência	Qualidade dos registros e sensibilidade do resultado de interesse.

Um padrão merece investigação quando pode comprometer o objetivo ou delimitar a interpretação do resultado.

Exploração no R

O mesmo modelo permite examinar média dos resíduos, magnitude e alavancagem.

```
m <- lm(pct_lula_t2 ~ pct_lula_t1 + uf, data = brasil)
plot(fitted(m), resid(m), xlab = "Valor ajustado (%)",
     ylab = "Resíduo (p.p.)")
abline(h = 0, col = "blue")
lines(lowess(fitted(m), resid(m)), col = "darkgreen")
head(sort(hatvalues(m), decreasing = TRUE))
```

Para uma zona relevante, compare o coeficiente ou a previsão com e sem sua observação. Registre o diagnóstico, sua consequência e a justificativa da decisão.

Leituras

Leituras previstas no programa

Hansen, Bruce E. *Econometrics*. Seções 4.10–4.15: resíduos, variância do erro, previsão e erros-padrão.
Shalizi, Cosma R. *The Truth about Linear Regression*. Seções 6.1 e 6.5: diagnósticos dos resíduos e projeção sob especificação incorreta.

Complementos: Hansen, seções 3.19–3.21 (alavancagem e influência) e 4.16 (indicadoras raras); Galdino, *Regressão*, capítulo "Checagem".

Na aula 9: distribuição amostral, erros-padrão convencionais e robustos e bootstrap.