

# Resumindo distribuições

Esperança · momentos · variância · MSE · covariância · correlação

---

Aronow & Miller (2019), cap. 2, §§2.1–2.2.2

FLS 6183 · Métodos Quantitativos de Pesquisa II

26/08/2026

# Ao final, você deve saber calcular – e interpretar

---

## 01 Centro

Explicar esperança como característica da distribuição, não como observação típica.

---

## 03 Associação

Interpretar covariância e correlação como resumos de co-movimento linear.

## 02 Dispersão

Distinguir momento, variância, desvio-padrão, MSE e suas unidades.

---

## 04 Limites

Reconhecer por que correlação zero não significa independência nem causalidade.

# Um resumo não é a distribuição – nem a amostra

---

## Objeto populacional

$$F_X \longrightarrow E[X], V[X], \rho[X, Y]$$

Resumimos uma distribuição complexa por características substantivas, sem supor forma paramétrica.

## Objeto observado

$$x_1, \dots, x_n \longrightarrow \bar{x}, s^2, r$$

Amostras fornecem estatísticas que ajudam a aprender sobre características populacionais.

**Hoje: definimos primeiro o alvo.**

# Esperança é uma média ponderada

---

O operador  $E[\cdot]$  recebe uma variável aleatória; os pesos vêm da distribuição.

**$X$  discreta**

$$E[X] = \sum_x x f_X(x)$$

Cada valor é ponderado por sua probabilidade.

**$X$  contínua**

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx$$

$f_X(x)$  é densidade; probabilidade é área.

**Unidades de  $E[X]$  = unidades de  $X$**

## A esperança pode não ocorrer




Figura 1. Distribuição de um dado justo; a média é 3,5.

$$E[X] = 3,5$$

Nenhuma face mostra 3,5: o centro não precisa ser observável.

$$E[D] = p$$

Para  $D \in \{0, 1\}$ , a esperança é  $\Pr(D = 1)$ .

**Pergunta rápida: se  $E[D] = 0,63$ , o que significa 0,63?**

# Linearidade não exige independência

---

## Função de uma variável

$$E[g(X)] = \sum_x g(x) f_X(x)$$

Por quê?

$$\begin{aligned} E[aX + bY + c] &= E[aX] + E[bY] + E[c] \\ &= aE[X] + bE[Y] + c. \end{aligned}$$

## Combinação linear

$$E[aX + bY + c] = aE[X] + bE[Y] + c$$

## Armadilha

$E[XY] = E[X]E[Y]$  não vem da linearidade. Independência é suficiente, não necessária.

# Momentos resumem a distribuição por meio de potências

---

O índice  $j$  é a **ordem**: elevamos os valores à potência  $j$  e calculamos sua esperança.

**Se  $X$  é discreta**

$$\mu'_j = E[X^j] = \sum_x x^j f_X(x).$$

**1º momento**

**2º momento**

$$\mu'_1 = E[X] = \mu$$

Localiza o centro.

$$\mu'_2 = E[X^2]$$

Ainda **não** é a variância.

**Se  $X$  é contínua**

$$\mu'_j = E[X^j] = \int x^j f_X(x) dx.$$

**3º momento**

**4º momento**

$$\mu'_3 = E[X^3]$$

Média dos cubos.

$$\mu'_4 = E[X^4]$$

Média das quartas potências.

**Podemos tomar potências de  $X$ , de  $X - \mu$  ou de  $Z = \frac{X - \mu}{\sigma}$ : surgem os momentos brutos, centrais e padronizados.**

# Bruto, central e padronizado não são a mesma coisa

---

Em todos os casos, calculamos o momento de ordem  $j$ ; muda a variável elevada à potência.

## Bruto

$$\mu'_j = E[X^j]$$

Nada foi removido: depende da origem e tem unidades  $u^j$ .

$$\mu'_1 = \mu; \mu'_2 \neq \sigma^2 \text{ em geral.}$$

## Central

$$\mu_j = E[(X - \mu)^j]$$

Subtrair  $\mu$  remove o centro, mas conserva as unidades  $u^j$ .

$$\mu_1 = 0; \mu_2 = \sigma^2.$$

## Padronizado

$$m_j = E[Z^j]$$

$$Z = \frac{X - \mu}{\sigma}$$

Dividir por  $\sigma$  remove também a escala e as unidades.

$$m_1 = 0; m_2 = 1.$$

**Momentos resumem centro, dispersão e aspectos da forma. Uma lista finita não reconstitui toda a distribuição.**

# Padronizar produz $m_j = \mu_j / \sigma^j$

---

Defina  $\mu = E[X]$ ,  $\sigma = \sqrt{V[X]}$  e suponha  $\sigma > 0$ .

## 1 Centralize

$$\mu_j = E[(X - \mu)^j].$$

Remove a localização, mas  $\mu_j$  ainda tem unidades  $u^j$ .

## 2 Padronize

$$Z = \frac{X - \mu}{\sigma}.$$

Agora  $E[Z] = 0$ ,  $V[Z] = 1$  e  $Z$  não tem unidade.

## 3 Tome o momento de $Z$

$$\begin{aligned} m_j &= E[Z^j] \\ &= E\left[\left(\frac{X - \mu}{\sigma}\right)^j\right] \\ &= \frac{E[(X - \mu)^j]}{\sigma^j} = \frac{\mu_j}{\sigma^j}. \end{aligned}$$

**O denominador é  $\sigma^j$  porque toda a razão é elevada a  $j$ . A divisão cancela as unidades  $u^j$ .**

## Depois de remover centro e escala, os momentos registram a forma

---

$$m_j = E[Z^j] = \frac{\mu_j}{\sigma^j}, \quad Z = \frac{X - \mu}{\sigma}.$$

$$j = 2$$

**Escala fixada**

$$m_2 = \frac{\mu_2}{\sigma^2} = 1.$$

A padronização já fixa a dispersão de  $Z$ .

$$j = 3$$

**Assimetria**

$$\gamma_1 = m_3 = \frac{\mu_3}{\sigma^3}.$$

A potência ímpar preserva o sinal: indica o lado da cauda mais longa.

$$j = 4$$

**Curtose**

$$\beta_2 = m_4 = \frac{\mu_4}{\sigma^4}.$$

A quarta potência enfatiza valores distantes; registra caudas e concentração.

**Depois de igualar centro e escala,  $m_3$  e  $m_4$  ainda distinguem formas. Um conjunto finito de momentos não identifica sozinho toda a distribuição.**

## Uniforme: mesma probabilidade em todo o intervalo

$$Z \sim U(-\sqrt{3}, \sqrt{3})$$

$$E[Z] = 0,$$

$$\mu_2 = \frac{(\sqrt{3})^2}{3} = 1,$$

$$\gamma_1 = 0,$$

$$\beta_2 = \frac{(\sqrt{3})^4}{5} = \frac{9}{5} = 1,8.$$

Simétrica e limitada: não há valores além de  $\pm\sqrt{3}$ .




Figura 2. Histograma simulado; linha azul: densidade uniforme.

## Normal: mesmo centro e variância, outra forma

$$Z \sim \mathcal{N}(0, 1)$$

$$E[Z] = 0,$$

$$\mu_2 = 1,$$

$$\gamma_1 = 0,$$

$$\beta_2 = 3.$$

Também é simétrica, mas não é limitada: as caudas continuam além de  $\pm 2$ .




Figura 3. Histograma de 30.000 sorteios; linha azul: densidade normal teórica.

## Poisson: padronizar não elimina a assimetria

$$X \sim \text{Pois}(3), \quad Z = \frac{X - 3}{\sqrt{3}}$$

$$E[Z] = 0,$$

$$\mu_2 = 1,$$

$$\gamma_1 = \frac{1}{\sqrt{3}} \approx 0,58,$$

$$\beta_2 = 3 + \frac{1}{3} \approx 3,33.$$

A variável é discreta e conserva uma cauda mais longa à direita.




Figura 4. Poisson(3) padronizada; laranja:  $|z| > 2$ .

## Os primeiros dois momentos não bastam para descrever a forma

| Distribuição           | $E[Z]$ | $V[Z]$ | $\gamma_1$ | $\beta_2$ | O que vemos           |
|------------------------|--------|--------|------------|-----------|-----------------------|
| Uniforme padronizada   | 0,00   | 1,00   | 0,00       | 1,80      | simétrica e limitada  |
| Normal padronizada     | 0,00   | 1,00   | 0,00       | 3,00      | simétrica com caudas  |
| Poisson(3) padronizada | 0,00   | 1,00   | 0,58       | 3,33      | assimétrica > direita |

**As três têm média 0 e variância 1. O terceiro e o quarto momentos registram diferenças que os dois primeiros escondem.**

*Tabela 1. Momentos padronizados e forma visual de três distribuições.*

## Da definição à fórmula computacional da variância

---

$$V[X] = E[(X - E[X])^2]$$

**1** Expanda

**2** Use linearidade

**3** Simplifique

$$E[X^2 - 2XE[X] + E[X]^2] \quad E[X^2] - 2E[X]E[X] + E[X]^2 \quad E[X^2] - E[X]^2$$

$$V[X] = E[X^2] - E[X]^2$$

**Passo-chave:**  $E[X]$  é um número e sai da esperança. Não confunda  $E[X^2]$  com  $E[X]^2$ .

## Após transformar $X$ , acompanhe também a unidade

Seja  $Z = aX + c$ . A constante  $a$  também pode representar uma conversão de unidade;  $Z$  é medido em  $u_Z$ . Para MSE e RMSE, transforme igualmente o alvo:  $z_0 = ax_0 + c$ .

Tabela 2. Valor e unidade das medidas depois da transformação  $Z = aX + c$ .

| Medida de $Z$ | Fórmula depois da transformação | Unidade depois da transformação |
|---------------|---------------------------------|---------------------------------|
| $E[Z]$        | $aE[X] + c$                     | $u_Z$                           |
| $V[Z]$        | $a^2V[X]$                       | $u_Z^2$                         |
| $\sigma[Z]$   | $ a \sigma[X]$                  | $u_Z$                           |
| $MSE_Z(z_0)$  | $a^2MSE_X(x_0)$                 | $u_Z^2$                         |
| $RMSE_Z(z_0)$ | $ a RMSE_X(x_0)$                | $u_Z$                           |

**Se  $X$  está em reais e  $Z = 100X$  está em centavos, média, DP e RMSE ficam em centavos; variância e MSE, em centavos ao quadrado.**

## Desigualdade de Chebyshev: garantia sem supor a forma

---

Para qualquer número real  $k > 0$ , a probabilidade de  $X$  estar a pelo menos  $k$  desvios-padrão de sua média é, no máximo,  $1/k^2$ .

### Em símbolos

$$\Pr\{|X - E[X]| \geq k\sigma[X]\} \leq \frac{1}{k^2}.$$

Equivalentemente, a probabilidade de ficar **dentro** de  $k$  desvios-padrão é

$$\Pr\{|X - E[X]| < k\sigma[X]\} \geq 1 - \frac{1}{k^2}.$$

Aqui,  $k > 0$  é o número escolhido de desvios-padrão e  $\sigma[X]$  é o DP de  $X$ .

**Chebyshev promete menos porque vale para qualquer distribuição com variância finita.**

### Exemplo: $k = 2$

$$1 - \frac{1}{2^2} = 0,75.$$

**Pelo menos 75% fica dentro de  $2\sigma$ .**

Se  $X$  é Normal, a probabilidade dentro dos mesmos  $2\sigma$  é

$$\Phi(2) - \Phi(-2) \approx 0,9545,$$

isto é, aproximadamente 95,45%.

## Chebyshev dá um IC se conhecemos a variância correta

---

Suponha que  $\hat{\theta}$  seja não viesado para  $\theta$  e que  $v = V[\hat{\theta}]$  seja conhecido. Escolha uma margem  $t > 0$ , nas unidades de  $\hat{\theta}$ , que torne o limite igual a  $\alpha$ .

$$\Pr\{|\hat{\theta} - \theta| \geq t\} \leq \frac{v}{t^2} = \alpha \quad \implies \quad t = \sqrt{\frac{v}{\alpha}},$$

$$\Pr\left\{\theta \in \left[\hat{\theta} - \sqrt{\frac{v}{\alpha}}, \hat{\theta} + \sqrt{\frac{v}{\alpha}}\right]\right\} \geq 1 - \alpha.$$

Para uma média i.i.d. com variância populacional  $\sigma^2$  conhecida: margem de 95%  
 $= \sqrt{20} \sigma / \sqrt{n} \approx 4,47 \sigma / \sqrt{n}.$

Sob normalidade, a margem exata com  $\sigma$  conhecida seria  $1,96 \sigma / \sqrt{n}.$

# “Pior cenário” em quê? Forma não é estrutura de dependência

---

## Por que não usar sempre?

- ▶ com o mesmo erro-padrão,  $4,47 > 1,96$ : o intervalo é muito mais largo;
- ▶ normalmente não conhecemos  $V[\hat{\theta}]$ ;
- ▶ trocar a variância verdadeira por uma estimativa elimina a garantia automática;
- ▶ hipóteses adicionais permitem intervalos mais informativos.

**Pode ser maior? Sim, mas não necessariamente. Com o mesmo SE, Chebyshev é mais largo. Com SEs diferentes, a ordem é ambígua:  $1,96 SE_{rob} > 4,47 SE_{iid}$  se  $SE_{rob}/SE_{iid} > 2,28$ .**

## O que é o “pior caso”?

Todas as distribuições com o mesmo centro e a mesma  $V[\hat{\theta}]$ .

**Não cobre erro  $V[\hat{\theta}]$  por ignorar heterocedasticidade, clusters ou dependência temporal.**

# MSE mede distância quadrática a um alvo

---

Queremos avaliar quão bem uma variável aleatória  $X$  aproxima um valor fixo  $c$ .

## Erro quadrático médio

$$\text{MSE}(c) = E[(X - c)^2]$$

Unidades:  $u^2$

## RMSE

$$\text{RMSE}(c) = \sqrt{E[(X - c)^2]}$$

Raiz do MSE · unidades:  $u$

$$\text{MSE}(0) = E[X^2] \quad \cdot \quad \text{MSE}(E[X]) = V[X]$$

# Decomposição do MSE: centralize e expanda

---

Escreva  $\mu = E[X]$ . Queremos separar a flutuação de  $X$  ao redor de  $\mu$  da distância entre  $\mu$  e o alvo  $c$ .

## 1 Some e subtraia $\mu$

$$X - c = (X - \mu) + (\mu - c).$$

## 2 Eleve ao quadrado

$$(X - c)^2 = (X - \mu)^2 + 2(X - \mu)(\mu - c) + (\mu - c)^2.$$

**O termo do meio conecta flutuação e deslocamento. A esperança mostrará por que ele desaparece.**

## MSE: tome expectativas nos passos 3 e 4

---

**3** Aplique  $E[\cdot]$  termo a termo

$$E[(X - c)^2] = E[(X - \mu)^2] + 2(\mu - c)E[X - \mu] + (\mu - c)^2.$$

**4** Use  $E[X - \mu] = 0$

$$\text{MSE}(c) = V[X] + (E[X] - c)^2$$

**Flutuação**  $V[X]$       +      **deslocamento ao quadrado**  $(E[X] - c)^2$

## Aplicação: o MSE de um estimador

---

Suponha um estimador de  $\theta$ ,  $\hat{\theta}$ . Qual é o MSE do meu estimador?

Use a fórmula anterior:

$$\text{MSE}(c) = V[X] + (E[X] - c)^2$$

Agora substitua  $X = \hat{\theta}$  e  $c = \theta$ :

$$\text{MSE}(\hat{\theta}) = V[\hat{\theta}] + (E[\hat{\theta}] - \theta)^2.$$

$$\text{MSE}(\hat{\theta}) = V[\hat{\theta}] + \text{Viés}(\hat{\theta})^2$$

## Onde o MSE é mínimo?

---

Parta novamente da decomposição geral:

$$\text{MSE}(c) = \underbrace{V[X]}_{\text{não depende de } c} + \underbrace{(E[X] - c)^2}_{\geq 0}.$$

- ▶ A variância permanece constante quando mudamos  $c$ .
- ▶ O segundo termo atinge seu menor valor, zero, quando  $c = E[X]$ .

$$\begin{aligned} c^* &= E[X] \\ \text{MSE}(c^*) &= V[X] \end{aligned}$$

**Em termos do estimador:** mantida a variância, o MSE é mínimo quando o viés é zero.

## Covariância resume co-movimento linear

---

$$\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])]$$

- ▶ produto positivo: os dois desvios têm o mesmo sinal;
- ▶ produto negativo: os desvios têm sinais opostos;
- ▶ a covariância é a média desses produtos.

### Unidades

Se  $X$  é medido em dólares e  $Y$  em pontos de alinhamento,

$\text{Cov}[X, Y]$  **usa dólares**  $\times$  **pontos.**

**Logo, a magnitude depende das duas escalas.** O sinal é comparável; o valor bruto, em geral, não.

## Exercício: derive a forma útil da covariância

---

Defina  $\mu_X = E[X]$  e  $\mu_Y = E[Y]$ . Parta de

$$\text{Cov}[X, Y] = E[(X - \mu_X)(Y - \mu_Y)].$$

### Objetivo

$$\text{Cov}[X, Y] = E[XY] - E[X]E[Y].$$

#### Dica

Expanda o produto. Aplique linearidade. Retire  $\mu_X$  e  $\mu_Y$  da esperança. Quais termos se cancelam?

## Solução: três termos colapsam em um

---

### 1 Expanda o produto

$$(X - \mu_X)(Y - \mu_Y) = XY - \mu_Y X - \mu_X Y + \mu_X \mu_Y.$$

### 2 Aplique a esperança

$$E[XY] - \mu_Y E[X] - \mu_X E[Y] + \mu_X \mu_Y.$$

### 3 Substitua $E[X] = \mu_X$ e $E[Y] = \mu_Y$

$$\text{Cov}[X, Y] = E[XY] - \mu_X \mu_Y = E[XY] - E[X]E[Y].$$

## Variância de uma soma contém covariância

---

$$V[X + Y] = V[X] + 2\text{Cov}[X, Y] + V[Y]$$

### **Simetria**

$$\text{Cov}[X, Y] = \text{Cov}[Y, X]$$

### **Mudança de escala**

$$\text{Cov}[aX + c, bY + d] = ab \text{Cov}[X, Y]$$

### **Constante**

$$\text{Cov}[X, c] = 0$$

### **Se a covariância é zero**

$$V[X + Y] = V[X] + V[Y]$$

**Erro comum: a última igualdade exige covariância zero.**

## Correlação remove unidades; inclinação não

$$\rho[X, Y] = \frac{\text{Cov}[X, Y]}{\sigma[X]\sigma[Y]}$$

A correlação está definida quando  $\sigma[X] > 0$  e  $\sigma[Y] > 0$ .

**Adimensional** e limitada a  $[-1, 1]$ .

O sinal indica direção; o módulo resume intensidade linear, não importância substantiva.

**Na regressão linear simples com intercepto,**

$$\beta_1 = \text{Cov}[X, Y]/V[X] = \rho[X, Y] \sigma[Y]/\sigma[X].$$

**Desafio:** se  $Y^* = 100Y$ , derive por que  $\rho[X, Y^*] = \rho[X, Y]$ , mas  $\beta_1^* = 100\beta_1$ .

### Transformações

Se  $a, b \neq 0$  e ambas as correlações estão definidas,

$$\begin{aligned}\rho[aX + c, bY + d] \\ = \text{sgn}(ab)\rho[X, Y]\end{aligned}$$

Somar constantes não muda  $\rho$ ; uma escala negativa muda o sinal.

## Independência implica covariância zero

$$X \perp Y \implies \text{Cov}[X, Y] = 0$$

Se  $\sigma[X] > 0$  e  $\sigma[Y] > 0$ , a correlação está definida e também vale  $\rho[X, Y] = 0$ .

**Mas a volta é falsa:**

$$\rho[X, Y] = 0 \text{ não implica } X \perp Y$$




Figura 6.  $X$  simétrico em torno de zero e  $Y = X^2$ : dependência determinística, correlação zero.

**Correlação zero elimina apenas a inclinação linear média.**

# A teoria organiza a pergunta do lab

---

**01**

**Brasil**

**pré/pós-2009**

Descrever distribuições.

**02**

**Comércio e  
votos**

Medir associação  
China-alinhamento.

**03**

**Donor pool**

Comparar com o  
conjunto de referência.

**04**

**Extensão em  
painel**

Indicador: China é o  
principal destino.

**No lab: primeiro descrevemos, depois quantificamos associação e  
comparamos distribuições.**