

Laboratório - Aula 2

Distribuições, momentos e associação descritiva nos votos Brasil-China

FLS 6183 - Métodos Quantitativos de Pesquisa II

26 de agosto de 2026

Sumário

1	Objetivos	1
2	Escopo e unidade de análise	2
3	Roteiro de 80 minutos	2
4	Importação	2
4.1	Primeiro contato com a base	3
5	Validação da base	3
5.1	Dimensões, ausências e chaves	3
6	Distribuição da convergência	4
7	Média, variância e desvio-padrão	5
7.1	Conexão com erro quadrático médio	5
8	Antes e depois de 2009	6
9	Covariância e correlação	7
10	A agregação anual muda o que vemos	8
11	Interpretação substantiva	8
12	Entregável da dupla	8
13	Próxima progressão do projeto	9

1 Objetivos

Ao final do laboratório, você deverá ser capaz de:

1. importar uma base e identificar corretamente sua unidade de análise;
2. verificar dimensões, ausências, chaves duplicadas e regras lógicas;
3. calcular frequências, média, variância e desvio-padrão;
4. relacionar a média de uma variável binária a uma proporção;
5. calcular e interpretar covariância e correlação;

6. comparar descritivamente dois períodos sem transformar a diferença em uma afirmação sobre efeitos.

Pergunta do dia: como se distribui a convergência direta dos votos de Brasil e China na Assembleia Geral das Nações Unidas entre 1997 e 2016, antes e depois de 2009?

2 Escopo e unidade de análise

A fonte preservada contém registros de votações nominais da Assembleia Geral. A base-mãe forma uma grade completa de **96 unidades por 1.813 votações**, totalizando 174.048 linhas.

Há um ponto importante sobre o universo de países:

- são **96 unidades totais**: Brasil e 95 países do *donor pool*;
- não existem 96 donors mais o Brasil na lista autoritativa atual;
- a China não é uma dessas 96 unidades: seu voto funciona como referência para calcular a convergência direta.

Hoje filtraremos apenas o Brasil. Cada linha da base do laboratório é uma votação nominal em que os votos de Brasil e China foram observados. Portanto:

$$\text{convergente}_i = \begin{cases} 1, & \text{se Brasil e China deram o mesmo voto na votação } i; \\ 0, & \text{se deram votos diferentes.} \end{cases}$$

Os votos válidos são **yes**, **no** ou **abstain**. O resultado descreve igualdade direta entre os dois registros; ele não mede proximidade ideal, apoio diplomático ou influência.

3 Roteiro de 80 minutos

Tabela 1: Roteiro de 80 minutos e produtos esperados.

Etapa	Tempo	Produto
Importação e unidade de análise	10 min	Uma frase definindo o que representa cada linha
Dimensões, ausências e duplicatas	15 min	Tabela curta de validação
Frequências da variável binária	10 min	Contagem e percentual de convergência
Média, variância e desvio-padrão	15 min	Tabela de momentos
Comparação pré/pós-2009	15 min	Tabela e figura descritivas
Covariância, correlação e interpretação	10 min	Parágrafo com unidades e limites
Entrega	5 min	PDF curto, código e conclusão

4 Importação

Use caminhos relativos ao projeto. Isso permite que o mesmo código funcione em computadores diferentes.

```
library(readr)
library(dplyr)
library(here)
```

```

dados <- readr::read_csv(
  here::here(
    "projeto_agna",
    "data",
    "processed",
    "brasil_convergencia_china_1997_2016.csv"
  ),
  locale = readr::locale(encoding = "UTF-8"),
  show_col_types = FALSE
)

dados <- dados |>
  dplyr::select(
    rcid,
    data,
    ano,
    periodo_2009,
    pos_2009,
    tema,
    voto_brasil,
    voto_china,
    convergente
  )

```

4.1 Primeiro contato com a base

```

dim(dados)
dplyr::glimpse(dados)
utils::head(dados, 6)

```

Antes de calcular qualquer estatística, responda:

1. O que representa uma linha?
2. Qual variável identifica unicamente uma votação?
3. A base contém todos os registros da Assembleia ou somente pares com ambos os votos observados?

Resposta esperada: uma linha representa uma votação nominal com votos observados de Brasil e China; rcid é a chave; a base contém 1.762 pares válidos, não todas as 1.813 votações da janela.

5 Validação da base

5.1 Dimensões, ausências e chaves

```

dim(dados)

dados |>
  dplyr::summarise(
    dplyr::across(
      dplyr::everything(),
      ~ sum(is.na(.x))
    )
  )

```

```

)
)|>
tidyr::pivot_longer(
  cols = dplyr::everything(),
  names_to = "variavel",
  values_to = "n_ausentes"
)

sum(duplicated(dados$rcid))
sum(!dados$ano %in% 1997:2016)
sum(!dados$convergente %in% c(0, 1))

```

Tabela 2: Validação lógica e estrutural das bases da Aula 2.

Checagem	Valor	Esperado	Status
Unidades totais na base-mãe	96	96	PASS
Unidades do donor pool	95	95	PASS
Brasil na lista autoritativa	1	1	PASS
China na lista de unidades	0	0	PASS
Anos cobertos	20	20	PASS
Votações nominais na janela	1813	1813	PASS
Linhas país x votação	174048	174048	PASS
Chaves país x votação duplicadas	0	0	PASS
Pares válidos Brasil-China	1762	1762	PASS
Chaves rcid duplicadas no laboratório	0	0	PASS
Ausências no resultado convergente	0	0	PASS
Valores do resultado fora de 0/1	0	0	PASS

Todas as doze checagens passam. Observe a diferença entre dois tipos de ausência:

- na base-mãe, um país ou a China pode não ter voto observado em determinada votação;
- na base do laboratório, esses casos já foram excluídos para que **convergente** tenha um denominador inequívoco.

6 Distribuição da convergência

Uma tabela de frequências deve sempre informar contagem e percentual.

```

freq_convergencia <- dados |>
  dplyr::count(convergente, name = "n") |>
  dplyr::mutate(
    resultado = dplyr::if_else(
      convergente == 1,
      "Convergente",
      "Divergente"
    ),
    percentual = 100 * n / sum(n)
  )

```

```
) |>
dplyr::select(resultado, n, percentual)
```

Tabela 3: Frequências da convergência direta Brasil-China, 1997-2016.

Resultado	Votações	Percentual
Divergente	350	19,9%
Convergente	1412	80,1%

Em 1.762 votações com o par observado, Brasil e China convergiram em 1.412, ou **80,1%**.

7 Média, variância e desvio-padrão

Para uma variável qualquer X , a média observada é

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i.$$

Quando X assume somente 0 e 1, somar X_i é o mesmo que contar os casos iguais a 1. Por isso, a média de `convergente` é a proporção de votações convergentes.

```
media_convergencia <- mean(dados$convergente)
variancia_amostral <- var(dados$convergente)
desvio_padrao_amostral <- sd(dados$convergente)

variancia_empirica_N <- mean(
  (dados$convergente - media_convergencia)^2
)
```

Há duas convenções próximas, mas não idênticas:

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2$$

é a variância retornada por `var()`; já

$$m_2 = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2$$

é o segundo momento central empírico. Para uma variável binária, $m_2 = p(1 - p)$. Aqui, `var(convergente)` é 0,15927 e o momento com denominador N é 0,15918.

7.1 Conexão com erro quadrático médio

Se previrmos a mesma constante para todas as votações, a média observada minimiza o erro quadrático médio:

Tabela 4: Média, variância e desvio-padrão das variáveis binárias.

Variável	Média	Variância (N-1)	DP (N-1)	Variância (N)
convergente	0,8014	0,1593	0,3991	0,1592
pos_2009	0,3871	0,2374	0,4872	0,2372

$$MSE(a) = \frac{1}{N} \sum_{i=1}^N (X_i - a)^2.$$

Tabela 5: Erro quadrático médio de três preditores constantes.

Preditor	Valor previsto	MSE
Media observada	0,8014	0,1592
Sempre prever convergencia	1,0000	0,1986
Sempre prever divergencia	0,0000	0,8014

8 Antes e depois de 2009

O corte é substantivamente importante para a sequência do curso, mas nesta aula funciona apenas como uma forma de organizar a distribuição observada.


```
resumo_perodo <- dados |>
  dplyr::group_by(perodo_2009) |>
  dplyr::summarise(
    n_pares_validos = dplyr::n(),
    n_convergentes = sum(convergente == 1),
    n_divergentes = sum(convergente == 0),
    taxa_convergencia = mean(convergente),
    .groups = "drop"
  )
```

Tabela 6: Convergência direta antes e depois de 2009.

Período	Pares válidos	Convergentes	Divergentes	Convergência
1997-2008	1080	849	231	78,6%
2009-2016	682	563	119	82,6%

A convergência observada é maior no período pós-2009

Diferença descritiva: 3,9 pontos percentuais



Fonte: unvotes 0.3.0. Denominador: pares com votos válidos de Brasil e China; comparação estritamente descritiva.

Figura 1: Convergência direta dos votos de Brasil e China antes e depois de 2009.

A taxa observada é 78,6% em 1997-2008 e 82,6% em 2009-2016. A diferença é **3,9 pontos percentuais**. A descrição não controla mudanças na composição temática das votações, na agenda anual ou em outras características do período.

9 Covariância e correlação

Defina $\text{pos_2009} = 1$ para 2009-2016 e 0 para 1997-2008. A covariância amostral é

$$\text{Cov}(X, Z) = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})(Z_i - \bar{Z}).$$

Seu valor depende das unidades de X e Z . A correlação padroniza a covariância:

$$r_{XZ} = \frac{\text{Cov}(X, Z)}{s_X s_Z}.$$

```
cov(dados$convergente, dados$pos_2009)
cor(dados$convergente, dados$pos_2009)
```

Tabela 7: Associação entre o período pós-2009 e a convergência direta.

Covariância	Correlação	Diferença (p.p.)
0,0094	0,0481	3,9

A correlação é 0,048: positiva, mas muito pequena. Para duas variáveis binárias, ela resume a diferença entre quatro células de uma tabela 2 x 2; não revela por que os períodos diferem.

10 A agregação anual muda o que vemos

As médias por ano mostram heterogeneidade que a comparação de apenas duas barras esconde.



Figura 2: Convergência direta dos votos de Brasil e China por ano, 1997-2016.

O valor de 2016, por exemplo, é inferior ao de vários anos anteriores. Portanto, “pós-2009” não significa uma trajetória monotônica. A agregação em dois períodos responde a uma pergunta diferente da série anual.

11 Interpretação substantiva

Uma conclusão adequada para esta aula seria:

Entre 1997 e 2016, Brasil e China deram o mesmo voto em 1.412 dos 1.762 registros nominais nos quais ambos os votos foram observados, uma convergência de 80,1%. A taxa foi de 78,6% em 1997-2008 e 82,6% em 2009-2016, diferença descritiva de 3,9 pontos percentuais. A correlação entre o indicador de período e a convergência foi 0,048. Como a composição das votações e outras condições também variam no tempo, esses números descrevem o padrão observado e não atribuem a mudança a um mecanismo específico.

Evite frases como “2009 aumentou a convergência” ou “o comércio causou maior alinhamento”. Ainda não construímos um desenho capaz de sustentar essas afirmações.

12 Entregável da dupla

Entregue um PDF de duas a quatro páginas contendo:

1. uma frase precisa sobre a unidade de análise e o denominador;
2. uma tabela numerada com as frequências de **convergente**;
3. uma tabela numerada com média, variância e desvio-padrão;
4. uma figura numerada comparando os dois períodos;
5. covariância e correlação entre **convergente** e **pos_2009**;
6. um parágrafo de 120 a 160 palavras com resultado, unidades e limites.

Inclua o código R em arquivo separado e use `dplyr::select()` sempre que selecionar colunas.

13 Próxima progressão do projeto

A sequência futura será associacional e ocorrerá em quatro passos:

1. **Cross-sections por ano:** relacionar maior fluxo ou participação do comércio com a China a maior alinhamento de voto, mantendo claro o ano e o denominador.
2. **Painel de vários países:** acompanhar a associação ao longo do tempo nas 96 unidades totais.
3. **Comparadores:** contrastar o Brasil com os 95 países do donor pool nos quais a China não se tornou o principal destino no arquivo atual.
4. **Extensão do paper:** somente depois, tratar o indicador “China = principal destino” como o tratamento definido no desenho original.

Os campos comerciais do `synth_data.rds` estão preservados na base-mãe, mas sua escala transformada precisa ser documentada antes de qualquer interpretação substantiva. Nenhum desses campos é usado na Aula 2.